

什么是 Paxos 协议



扫码试看/订阅

《ZooKeeper实战与源码剖析》视频课程

Paxos 算法做什么

Paxos 算法是一个一致性算法，作用是让 Asynchronous non-Byzantine Model 的分布式环境中的各个 agent 达成一致。

我打一个比方，7 个朋友要决定晚上去哪里吃饭。一致性算法就是保证要么这 7 个朋友达成一致选定一个地方去吃饭，要么因为各种异常情况达不成一致，但是不能出现一些朋友选定一个地方，另外一些朋友选定另外一个地方的情况。

Asynchronous non-Byzantine Model

一个分布式环境由若干个 agent 组成，agent 之间通过传递消息进行通讯：

- agent 以任意的速度运行，agent 可能失败和重启。但是 agent 不会出 Byzantine fault 。
- 消息需要任意长的时间进行传递，消息可能丢失，消息可能会重复。但是消息不会 corrupt 。

Paxos 算法中的 agent 角色

client :发送请求给 Paxos 算法服务。

proposer :发送 prepare 请求和 accept 请求。

acceptor :处理 prepare 请求和 accept 请求。

learner :获取一个 Paxos 算法实例决定的结果。

Paxos 算法伪代码

```
proposer
=====
propose(v):
    while not decided:
        // 阶段 1a
        choose n, unique and higher than any n seen so far
        send prepare(n) to all servers including self
        if prepare_ok(n, na, va) from majority:
            // 阶段 2a
            v' = va with highest na; choose own otherwise
            send accept(n, v') to all
            if accept_ok(n) from majority:
                send decided(v') to all

acceptor
=====
np: 承诺过或者接受过的最大提案号
na, va: 接受过的最大提案号和对应的值

// 阶段 1b
promise(n):
    if n > np
        np = n
        reply promise_ok(n, na, va)
    else
        reply promise_reject

// 阶段 2b
accept(n, v):
    if n >= np
        np = n
        na = n
        va = v
        reply accept_ok(n)
    else
        reply accept_reject
```

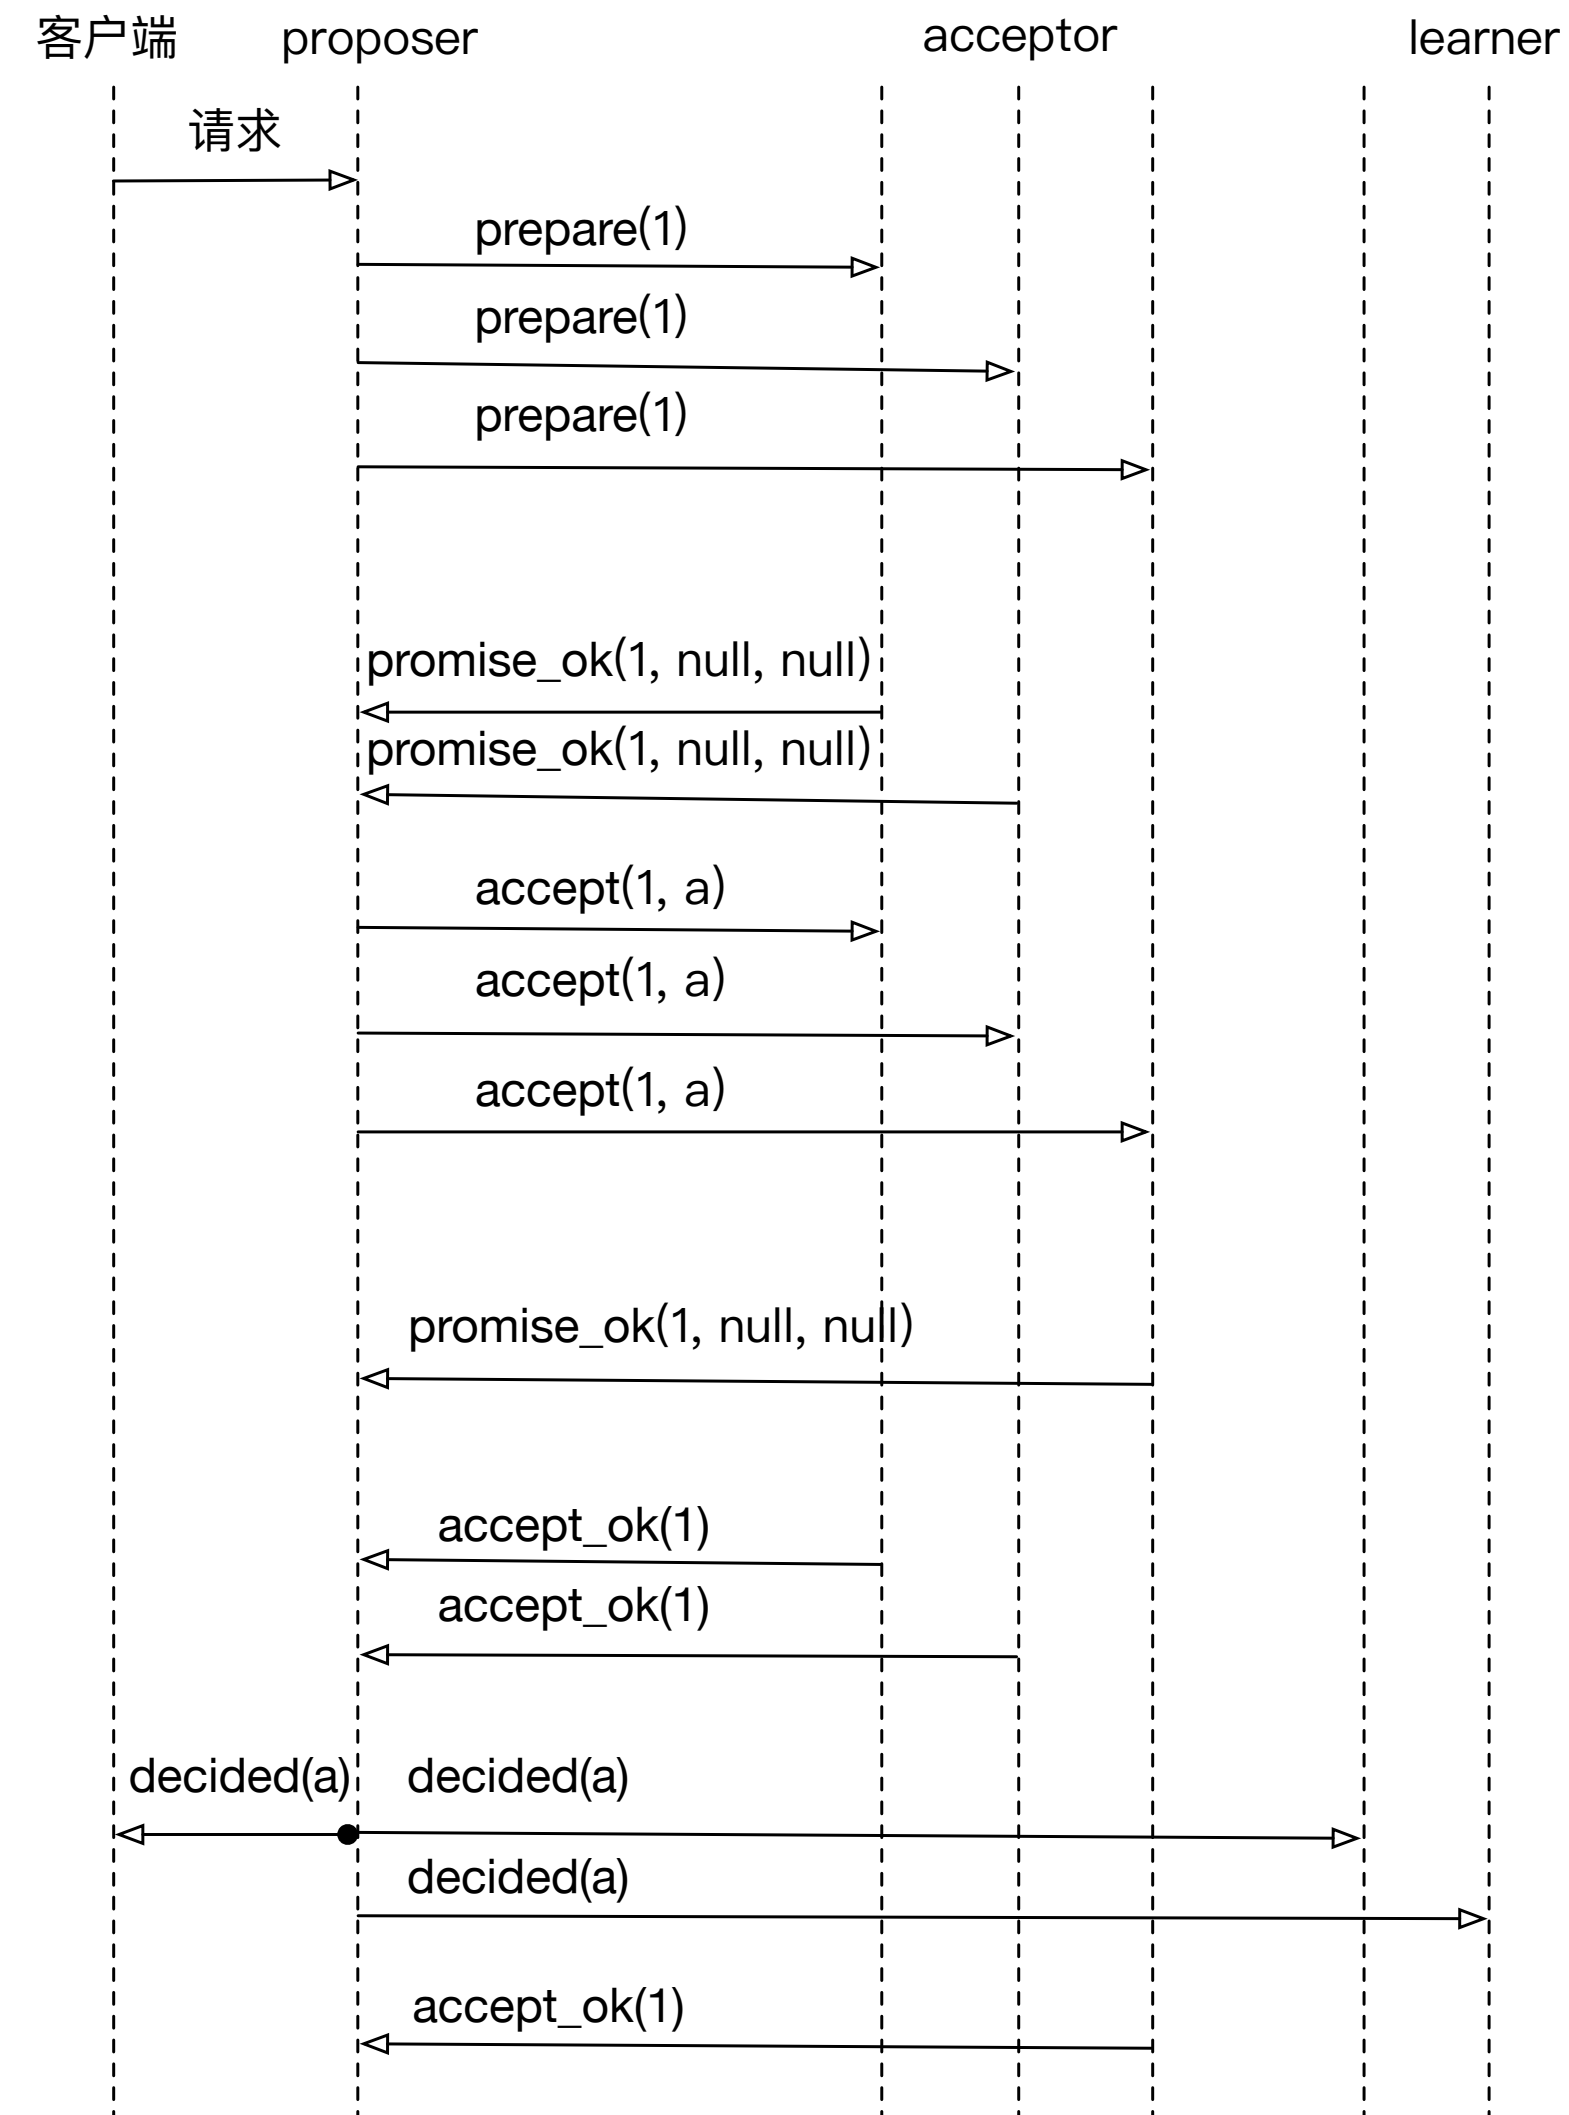

Paxos 算法描述

一个 Paxos 算法实例正常运行的前提是大多数 acceptor 正常运行。换句话说就是 Paxos 提供允许少数 acceptor 失败的容错能力。

子阶段	描述
阶段 1a 准备(prepare)	选择一个提案号码(proposal number) n ，发送 prepare(n)消息给 Paxos 集群中所有的 acceptor。这个 n 需要大于这个 proposer 以前使用过的所有提案号。
阶段 1b 承诺(promise)	如果 prepare 消息中的提案号大于 acceptor 承诺过或者接受过的最大提案号 n_p ，也就是说 acceptor 没有承诺过不小于 n 的 prepare 消息，那么把 n_p 更新为 n 。如果 acceptor 以前接受过提案，返回的消息需要包括接受过的最大提案号和对应的值。
阶段 2a 发起接受(accept)请求	一个 proposer 在接受到 Paxos 组中大多数 acceptor 的 promise_ok 消息之后，进入这个阶段。如果有 promise_ok 消息包含 n_a 和 v_a ，把 v' 设为具有最高 n_a 值的 v_a 。否则的话，proposer 自己决定 v' 。之后 acceptor 把 accept(n, v')消息发送给所有的 acceptor。
阶段 2b 处理接受请求	如果 accept 消息中的提案号大于等于 acceptor 承诺过或者接受过的最大提案号 n_p ，也就是说 acceptor 没有接受过大于 n 的 prepare 消息或者 accept 消息，acceptor 把 n_p 和 n_a 更新为 n ，把 v_a 更新为 v 。

Paxos 算法的消息流

以下是一个 Paxos 算法实例的完成的消息流：

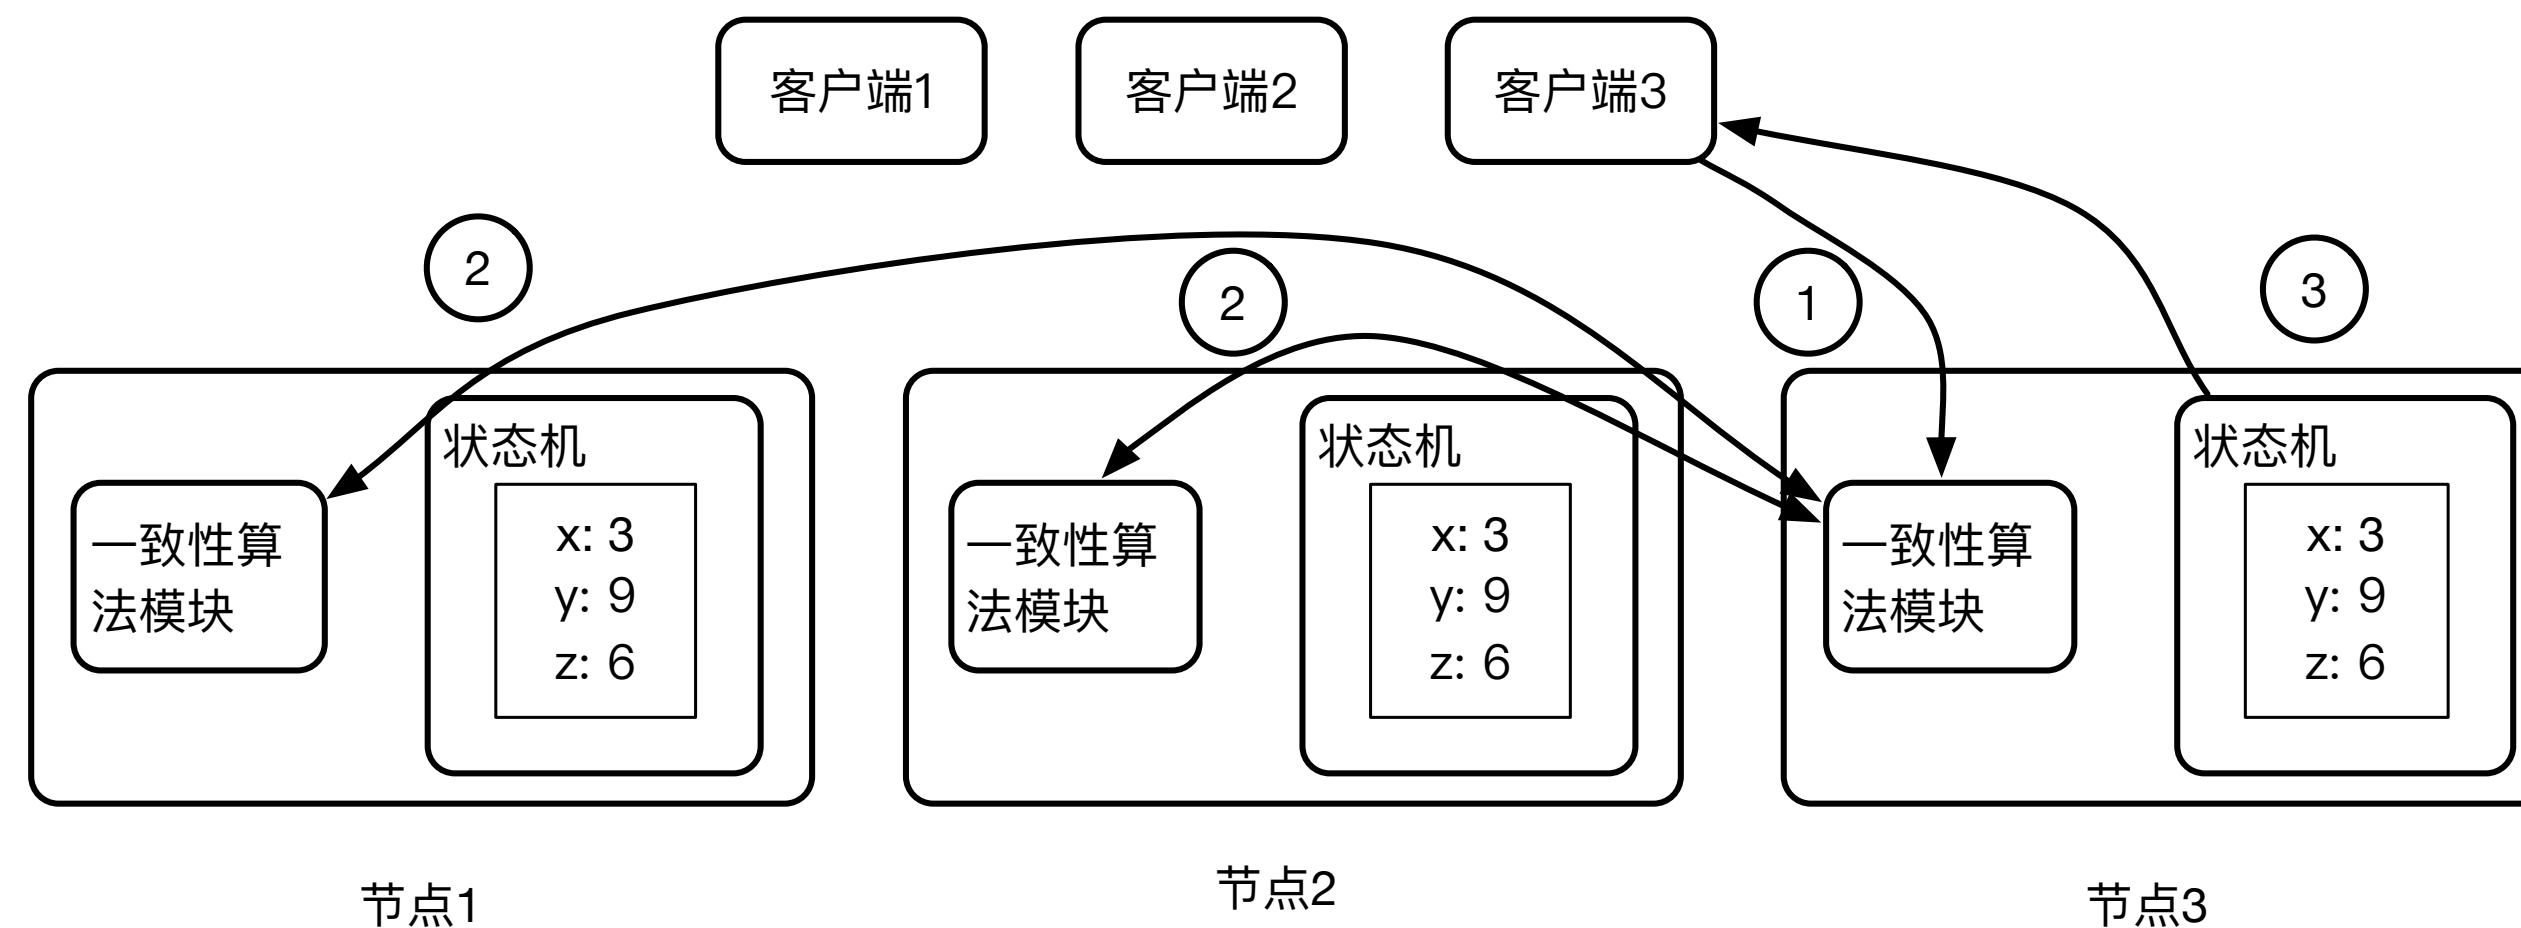


复制状态机 (Replicated State Machine)

Paxos 算法可以用来实现复制状态机的一致性算法模块。

这里面的状态机是一个 KV 系统。通过复制状态机可以把它变成一个容错的 3 节点分布式 KV 系统。下面是处理 $z=6$ 这个写操作的过程：

1. 客户端 3 发送一个 $z=6$ 请求给节点 3 的一致性算法模块。
2. 节点 3 的一致性算法发起一个算法实例。
3. 如果各个节点的一致性算法模块能一起达成一致，节点 3 把 $z=6$ 应用到它的状态机，并把结果返回给客户端 3。



MultiPaxos

基本的 Paxos 算法在决定一个值的时候需要的执行两个阶段，这涉及大量消息交换。MultiPaxos 算法的提出就是为了解决这个问题。MultiPaxos 保持一个长期的 leader，这样决定一个值只需要执行第二阶段。一个典型的 Paxos 部署通常包括奇数个服务器，每个服务器都有一个 proposer，一个 acceptor 和一个 learner。

比较 Chubby 和 ZooKeeper

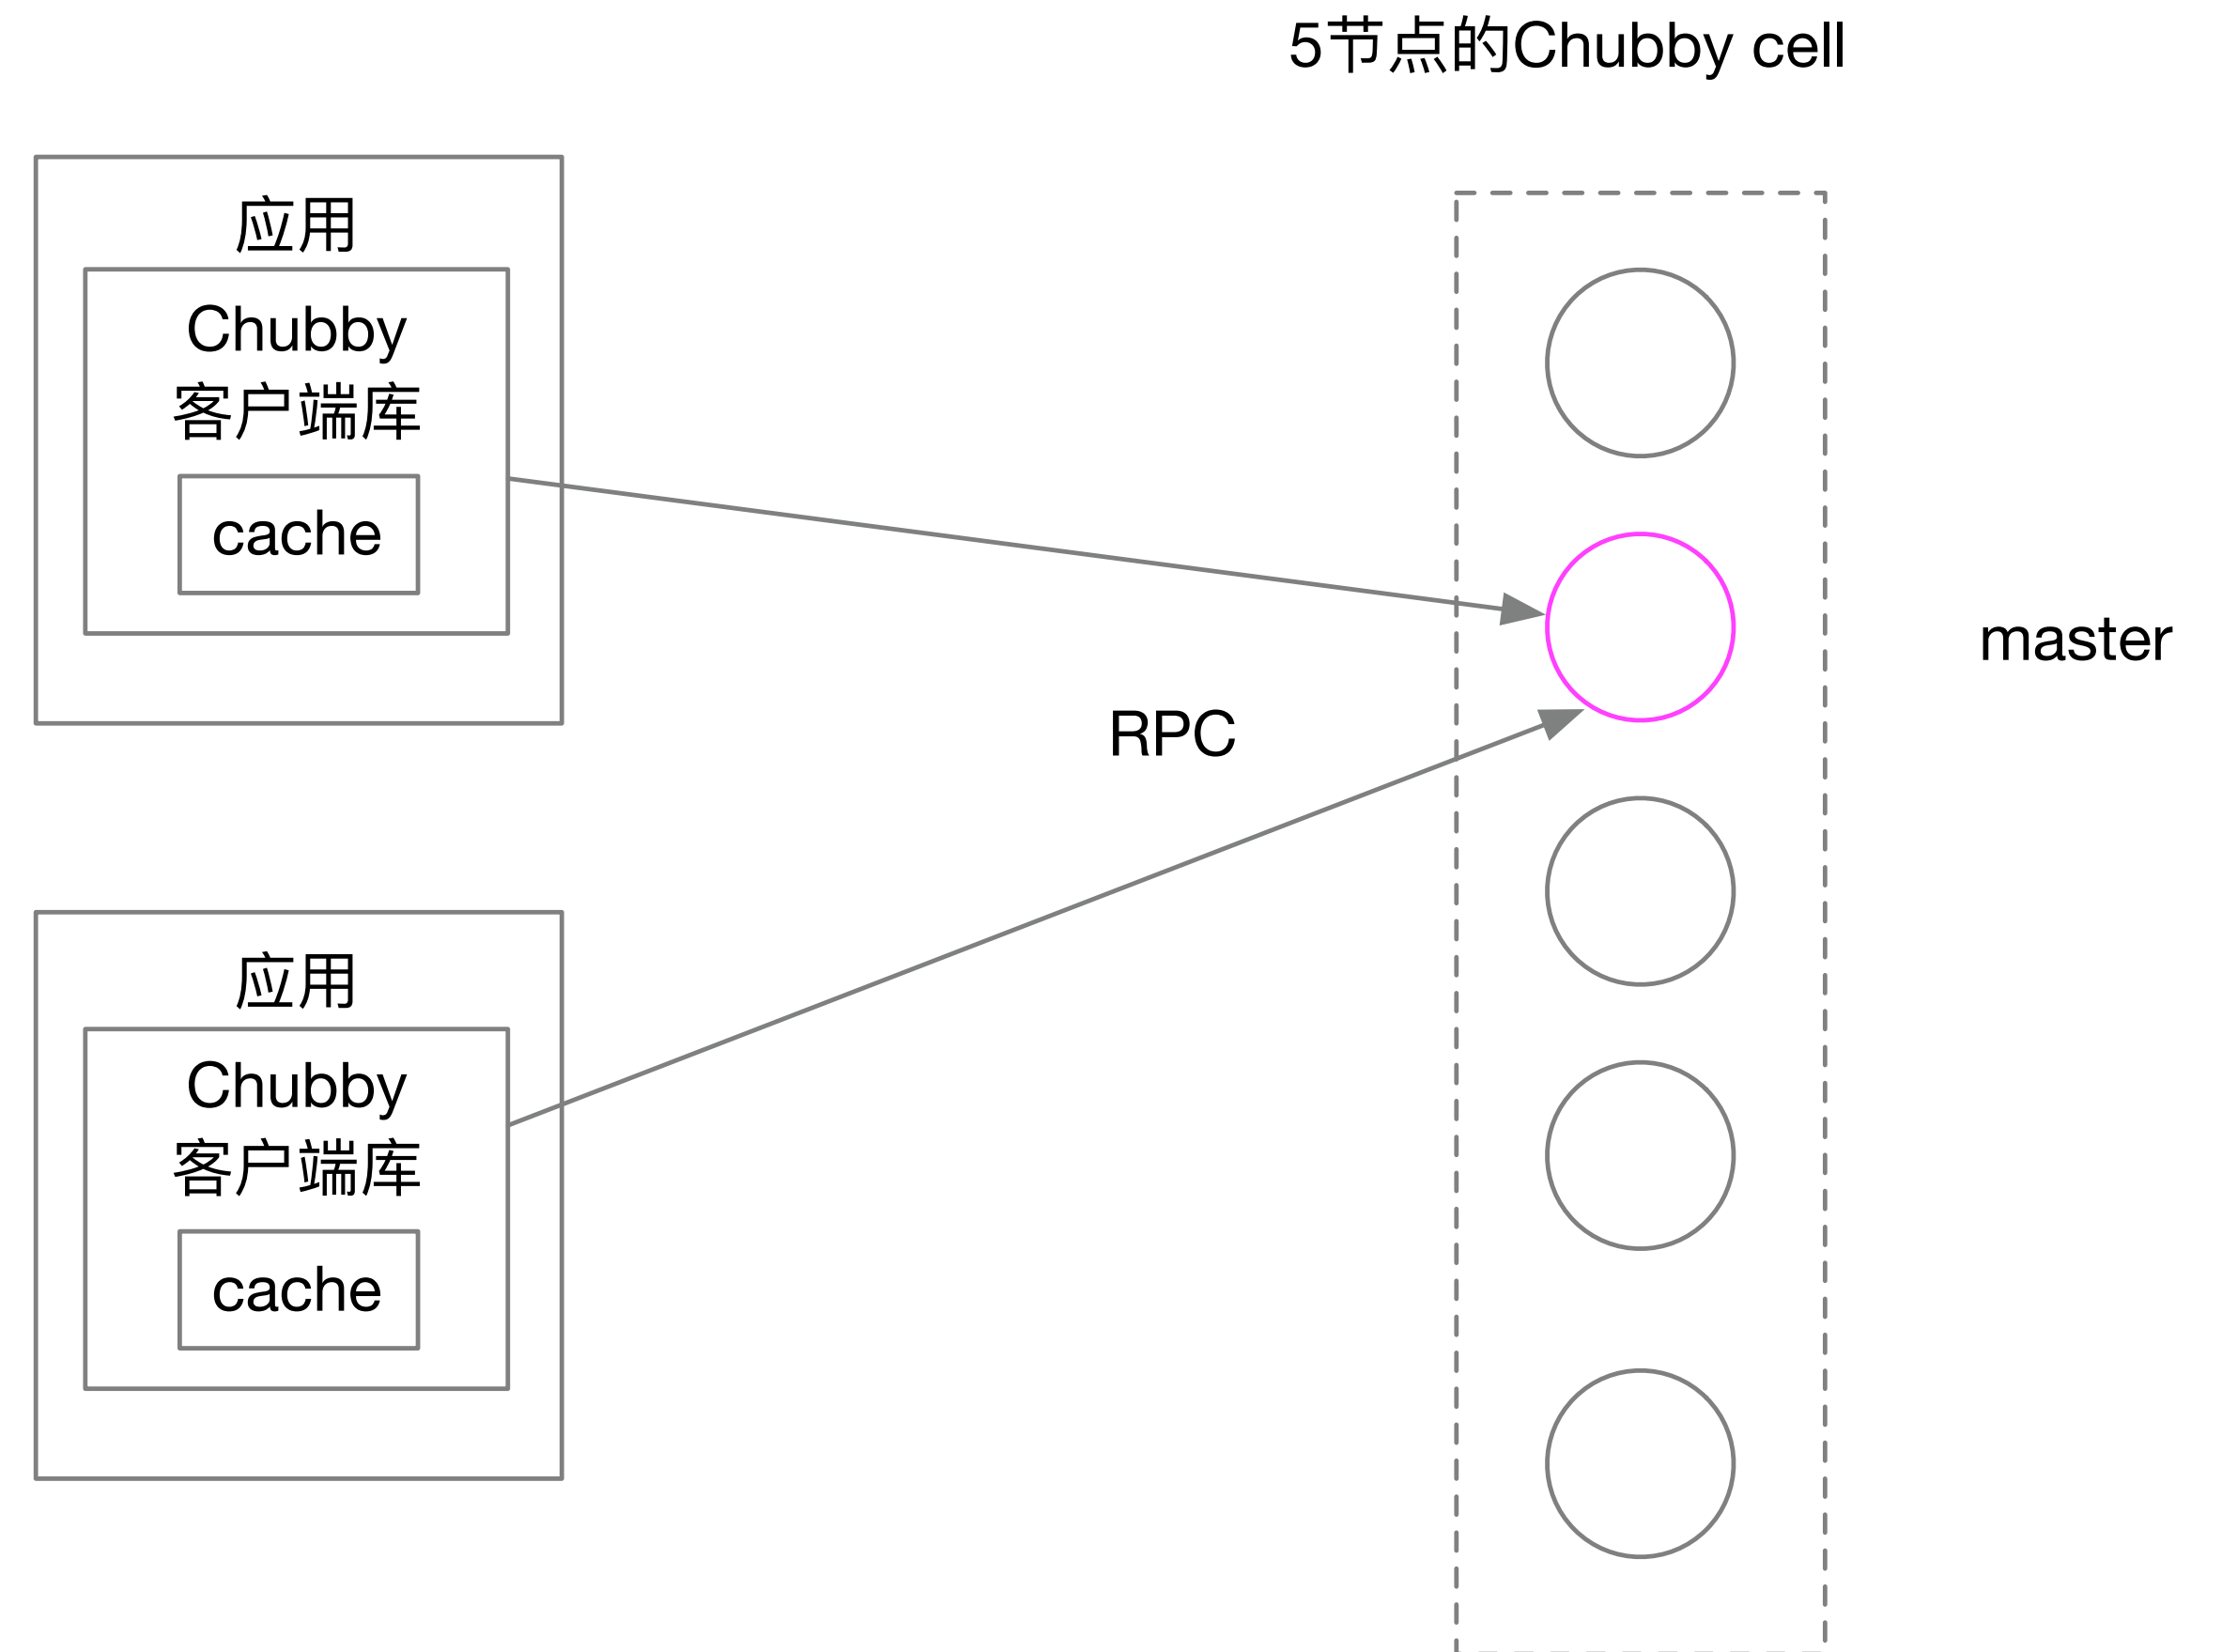
什么是 Chubby

Chubby 是一个分布式锁系统，广泛应用于 Google 的基础架构中，例如知名的 GFS 和 Bigtable 都用 Chubby 来做协同服务。

ZooKeeper 借鉴了很多 Chubby 的设计思想，所以它们之间有很多相似之处。

Chubby 系统架构

- 一个 Chubby 的集群叫作一个 cell，由多个 replica 实例组成，其中一个 replica 是整个 cell 的 master。所有的读写请求只能通过 master 来处理。
- 应用通过引入 Chubby 客户端库来使用 Chubby 服务。Chubby 客户端在和 master 建立 session 之后，通过发 RPC 给 master 来访问 Chubby 数据。
- 每个客户端维护一个保证数据一致性的 cache。

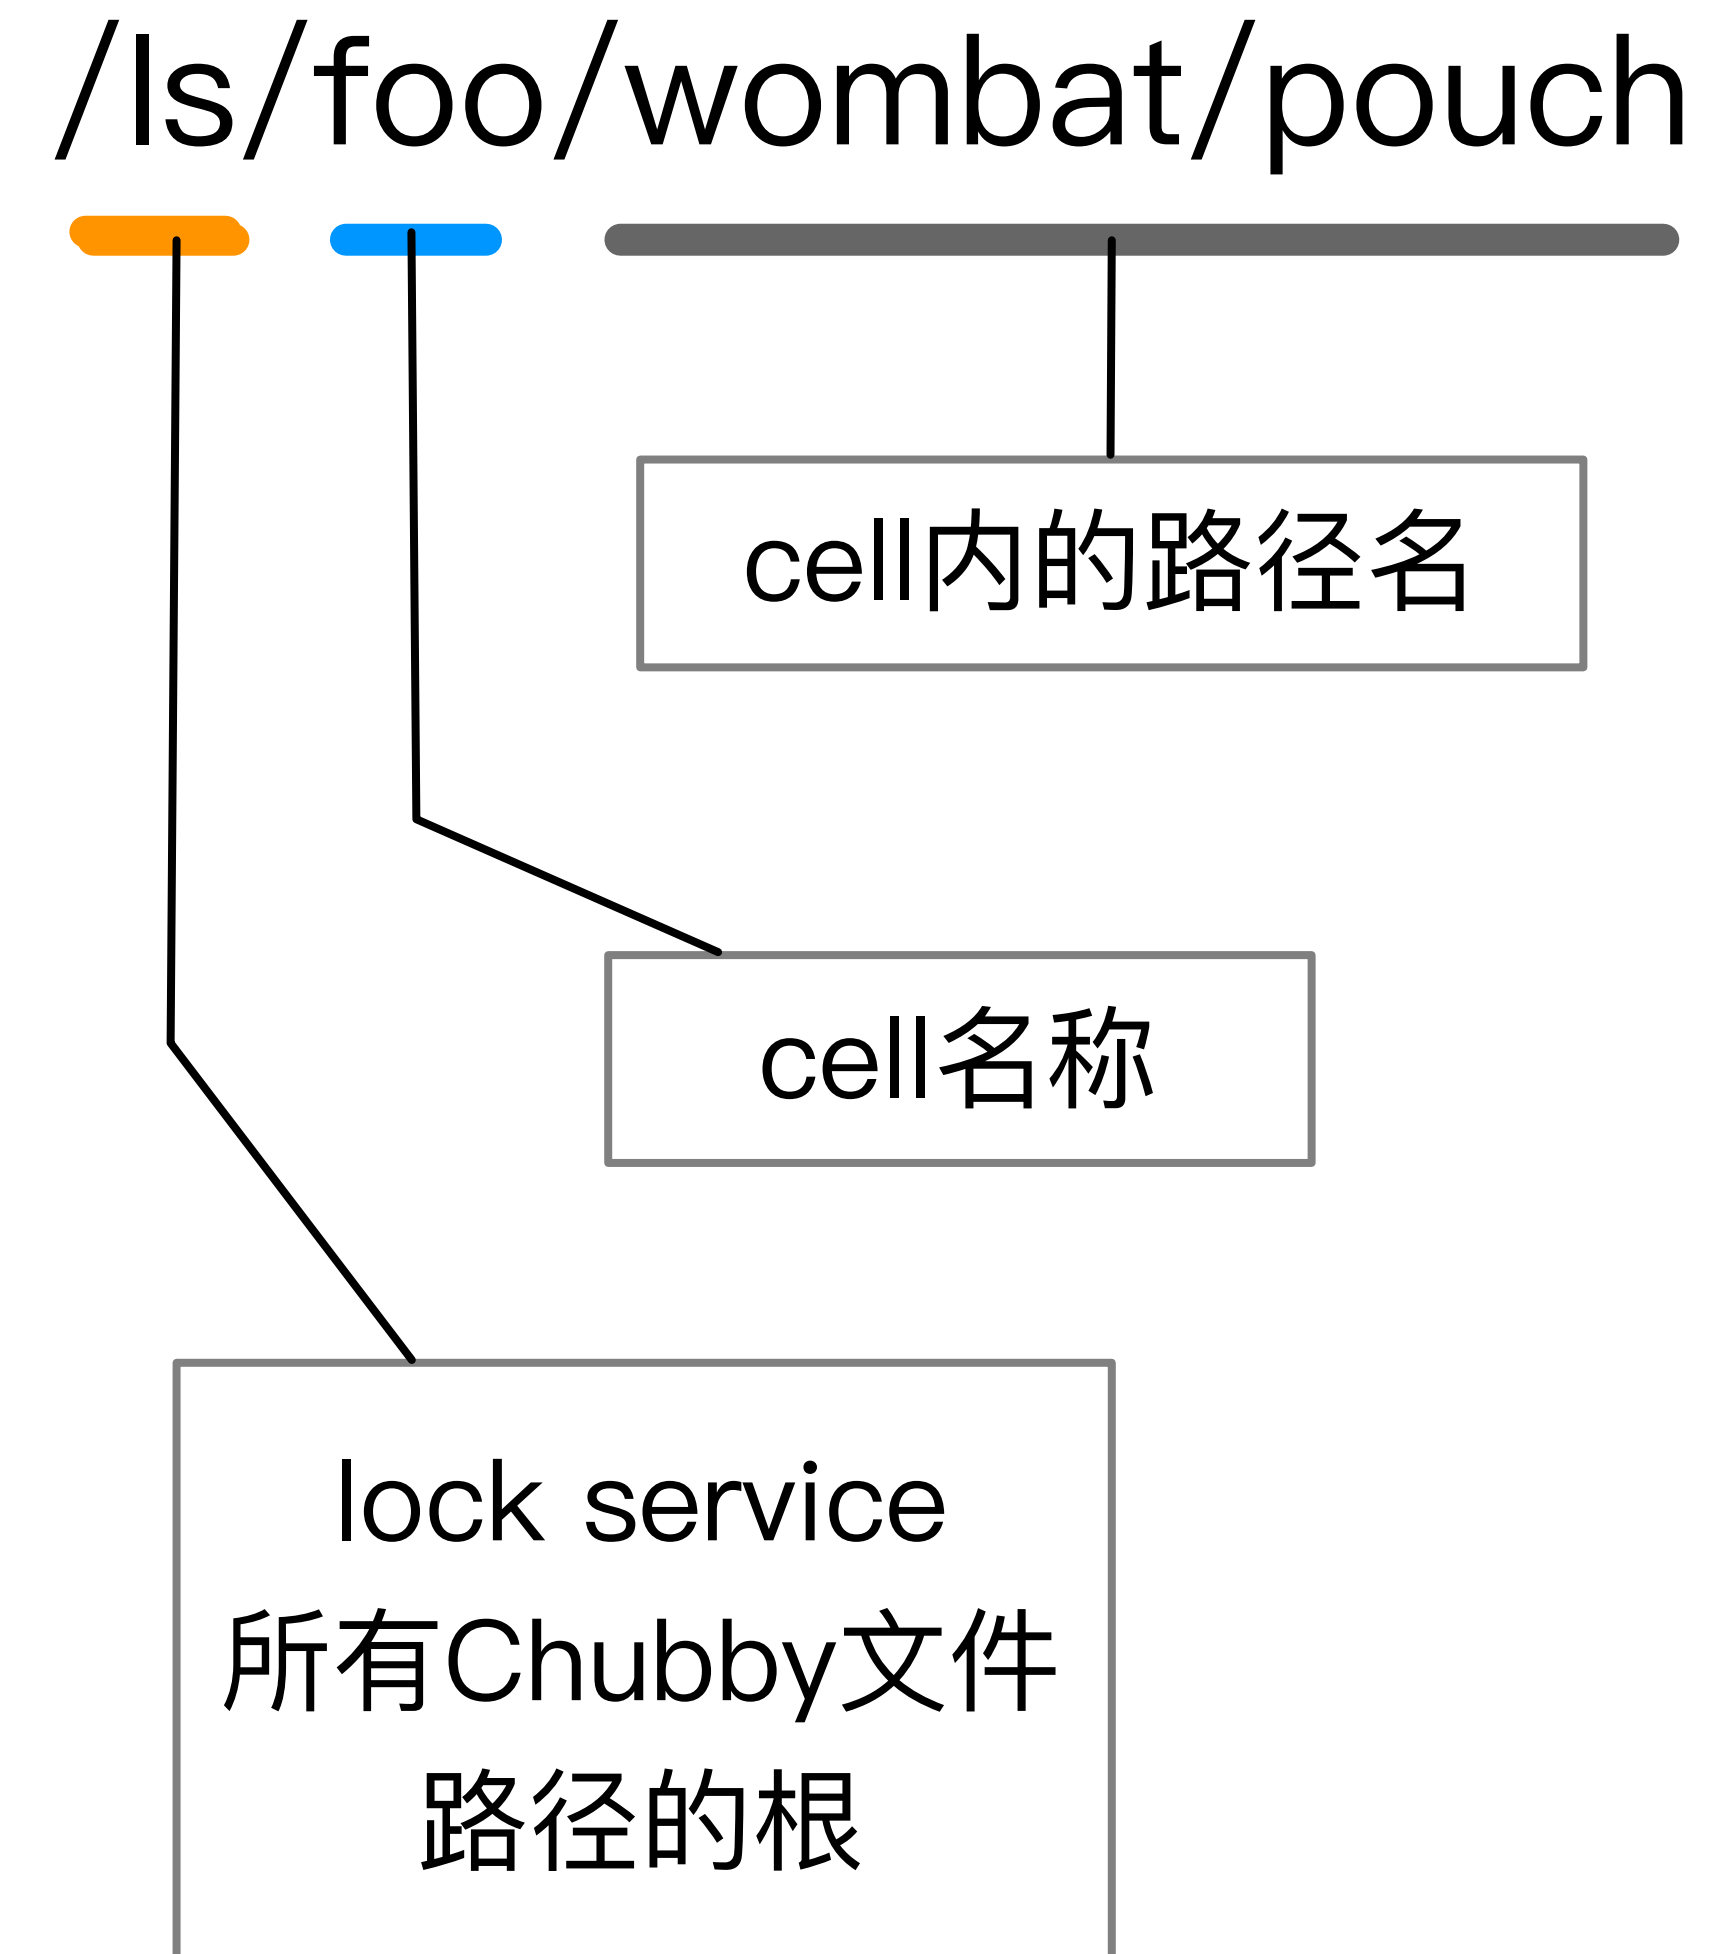


数据模型

Chubby 使用的是层次数据模型，可以看做一个简化的 UNIX 文件系统：

- Chubby 不支持部分内容的读写。
- Chubby 不支持 link 。
- Chubby 不支持依赖路径的文件权限。

不同于 ZooKeeper，Chubby 的命名空间是由多个 Chubby cell 构成的。



Chubby API

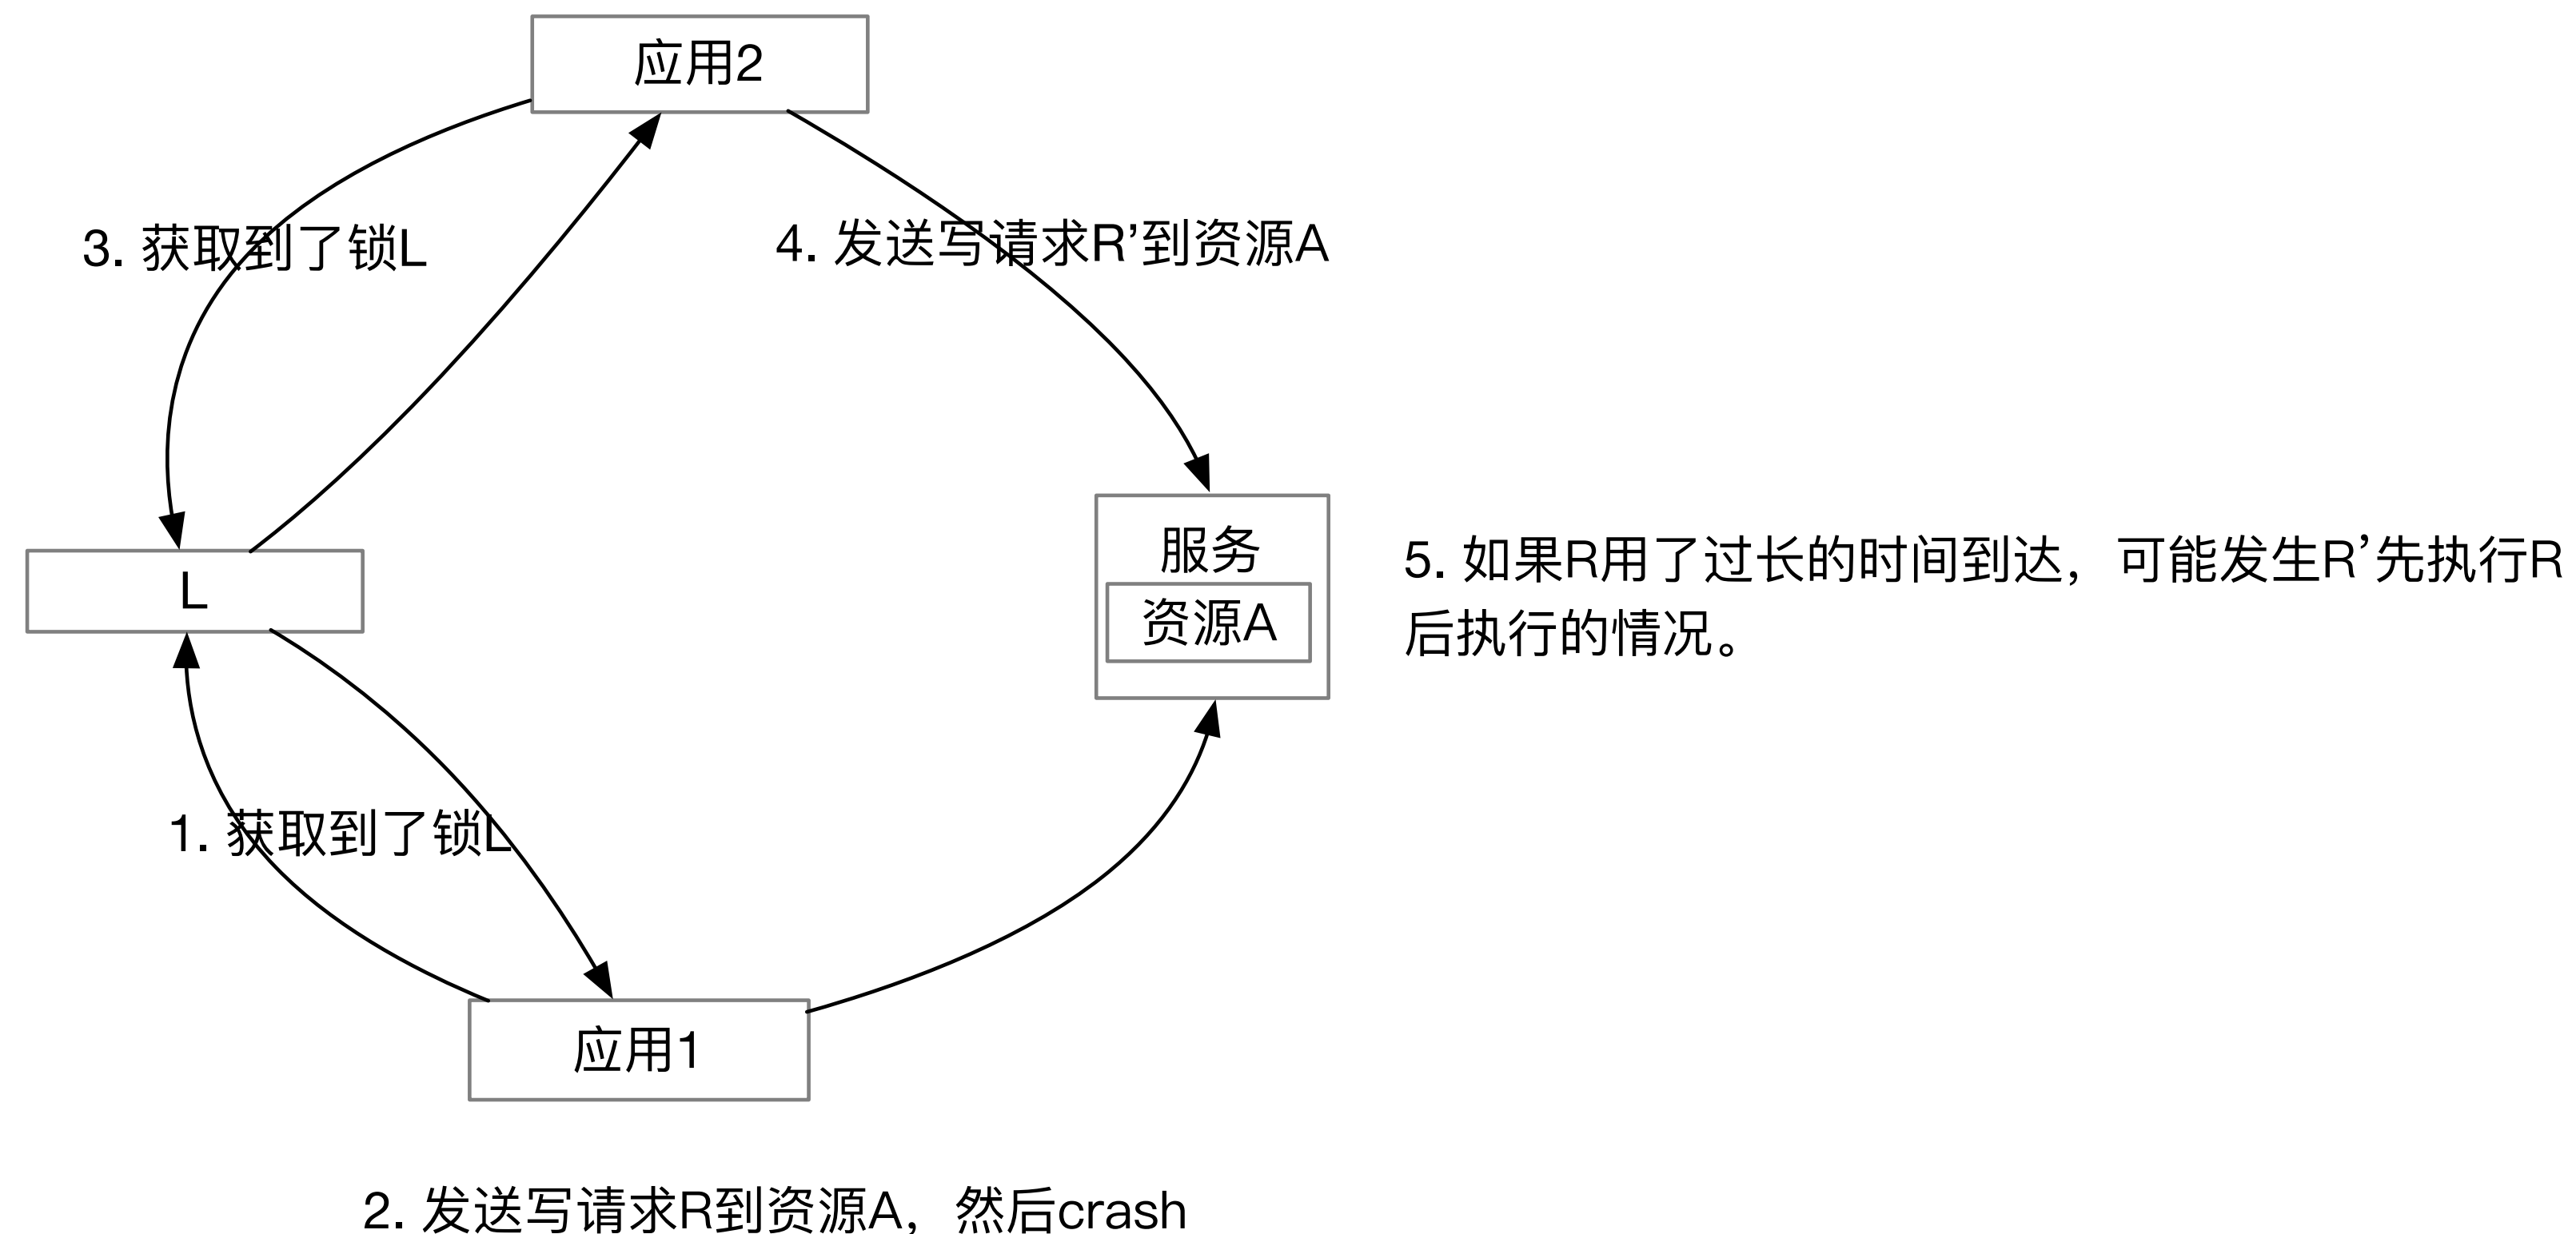
与 ZooKeeper 不同，Chubby 的 API 有一个文件句柄的概念。

- `Open()`：唯一使用路径名访问文件的 API，其他 API 都使用一个文件句柄。
- `Close()`：关闭文件句柄。
- `Poison()`：取消文件句柄上正在进行的操作，主要用于多线程场景。
- 文件操作 API：`GetContentsAndStat()`，`SetContents()`，`Delete()`。
- 锁 API：`Acquire()`，`TryAcquire()`，`Release()`，`GetSequencer()`，`SetSequencer()`，`CheckSequencer()`。

和 ZooKeeper 一样，Chubby 的 API 提供了事件通知机制、API 的异步和同步版本。

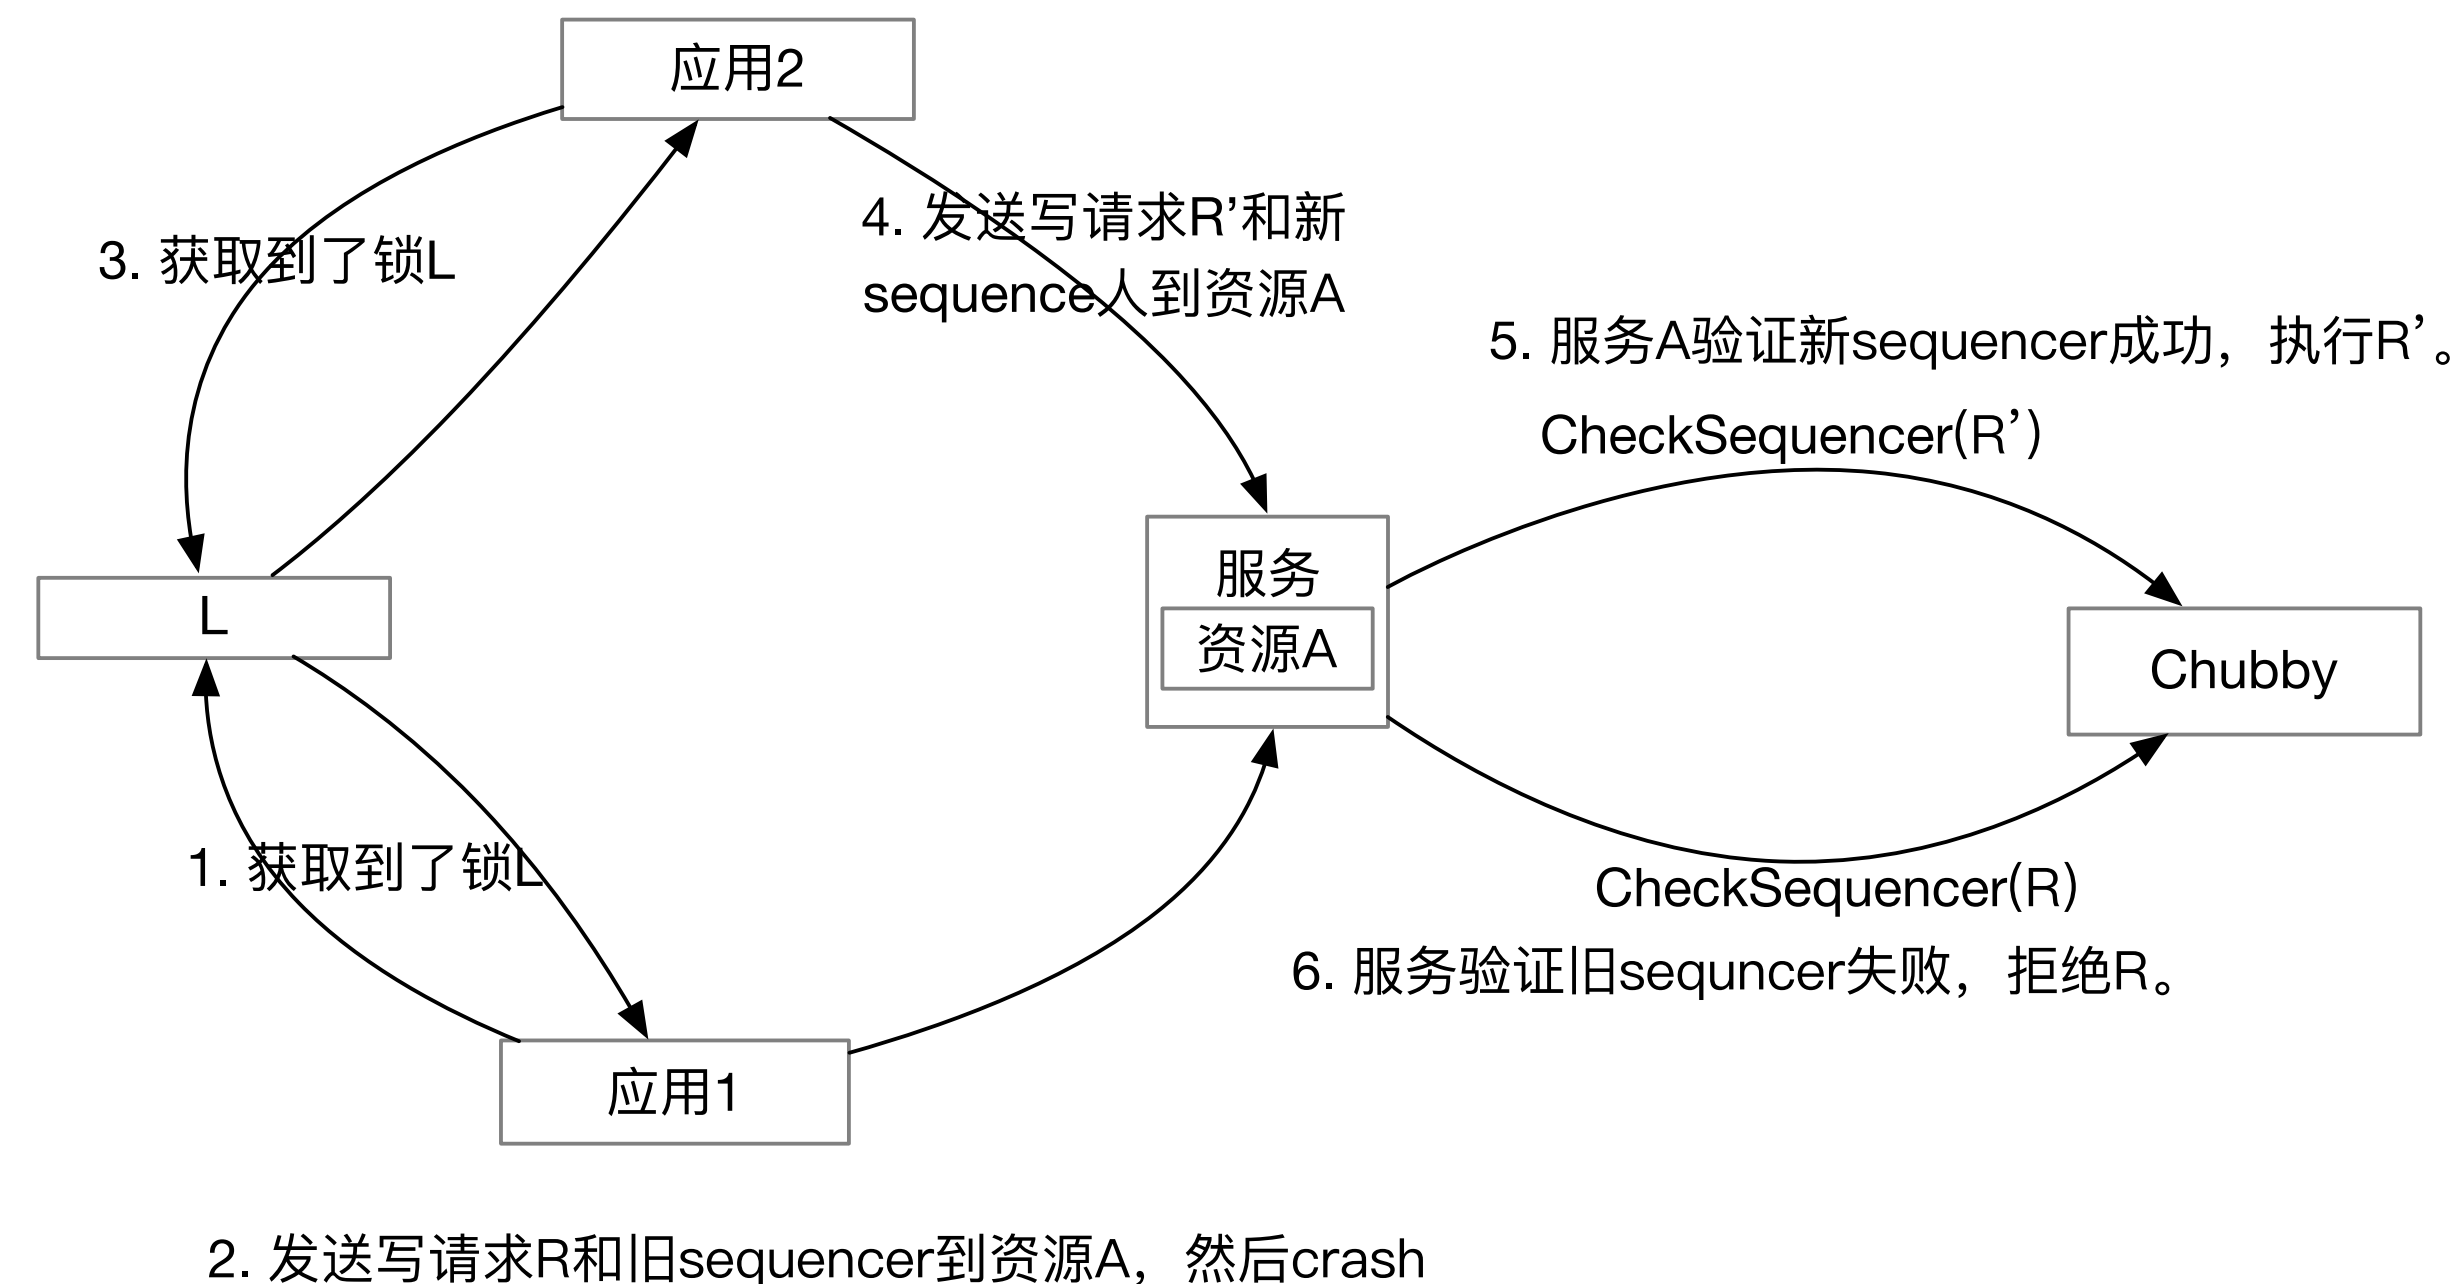
Locking

Chubby 使用 Advisory locking 。由于通信的不确定性和各种节点失败，分布式环境中的锁是非常复杂的。例如在下图所示的场景中，Chubby 锁 L 用来保护资源 A，但是会出现操作请求执行顺序颠倒的情况。



解决方案 1-Sequencer

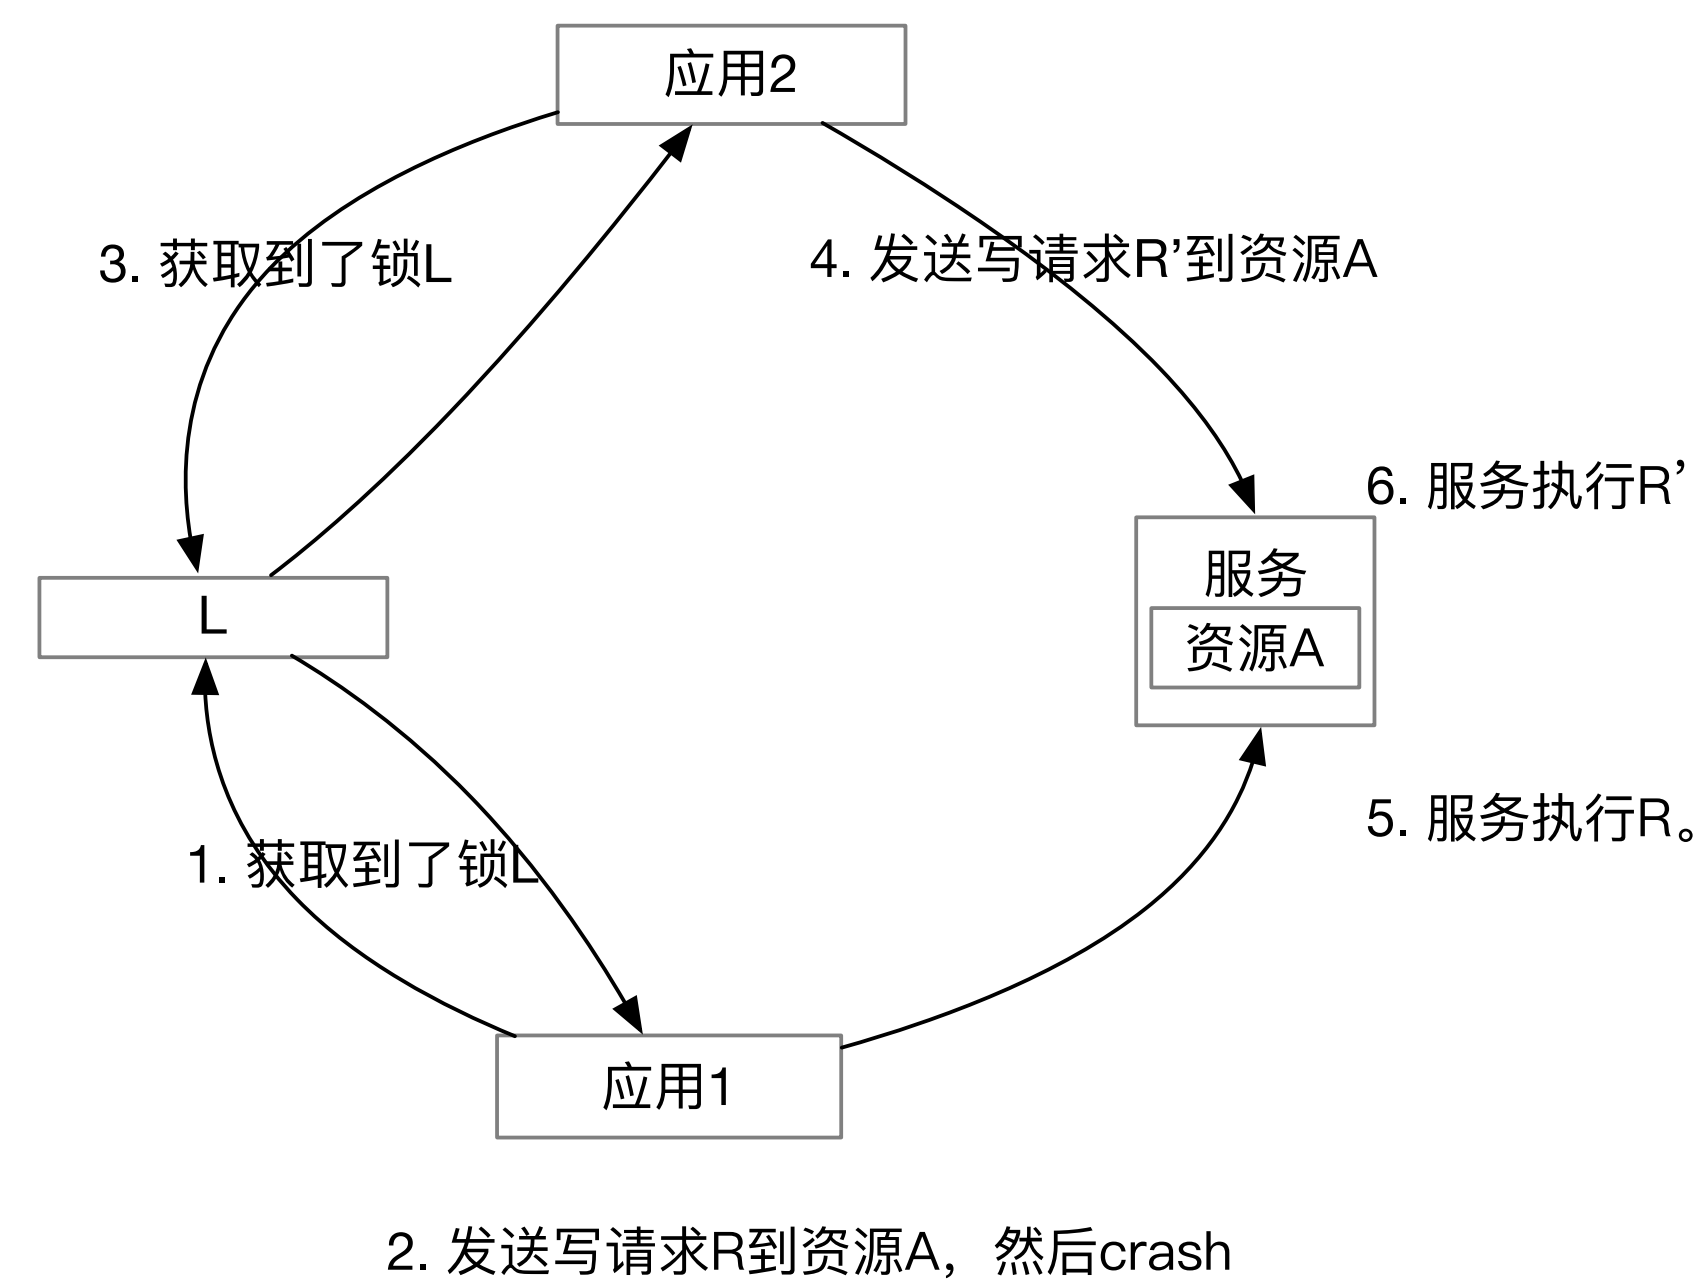
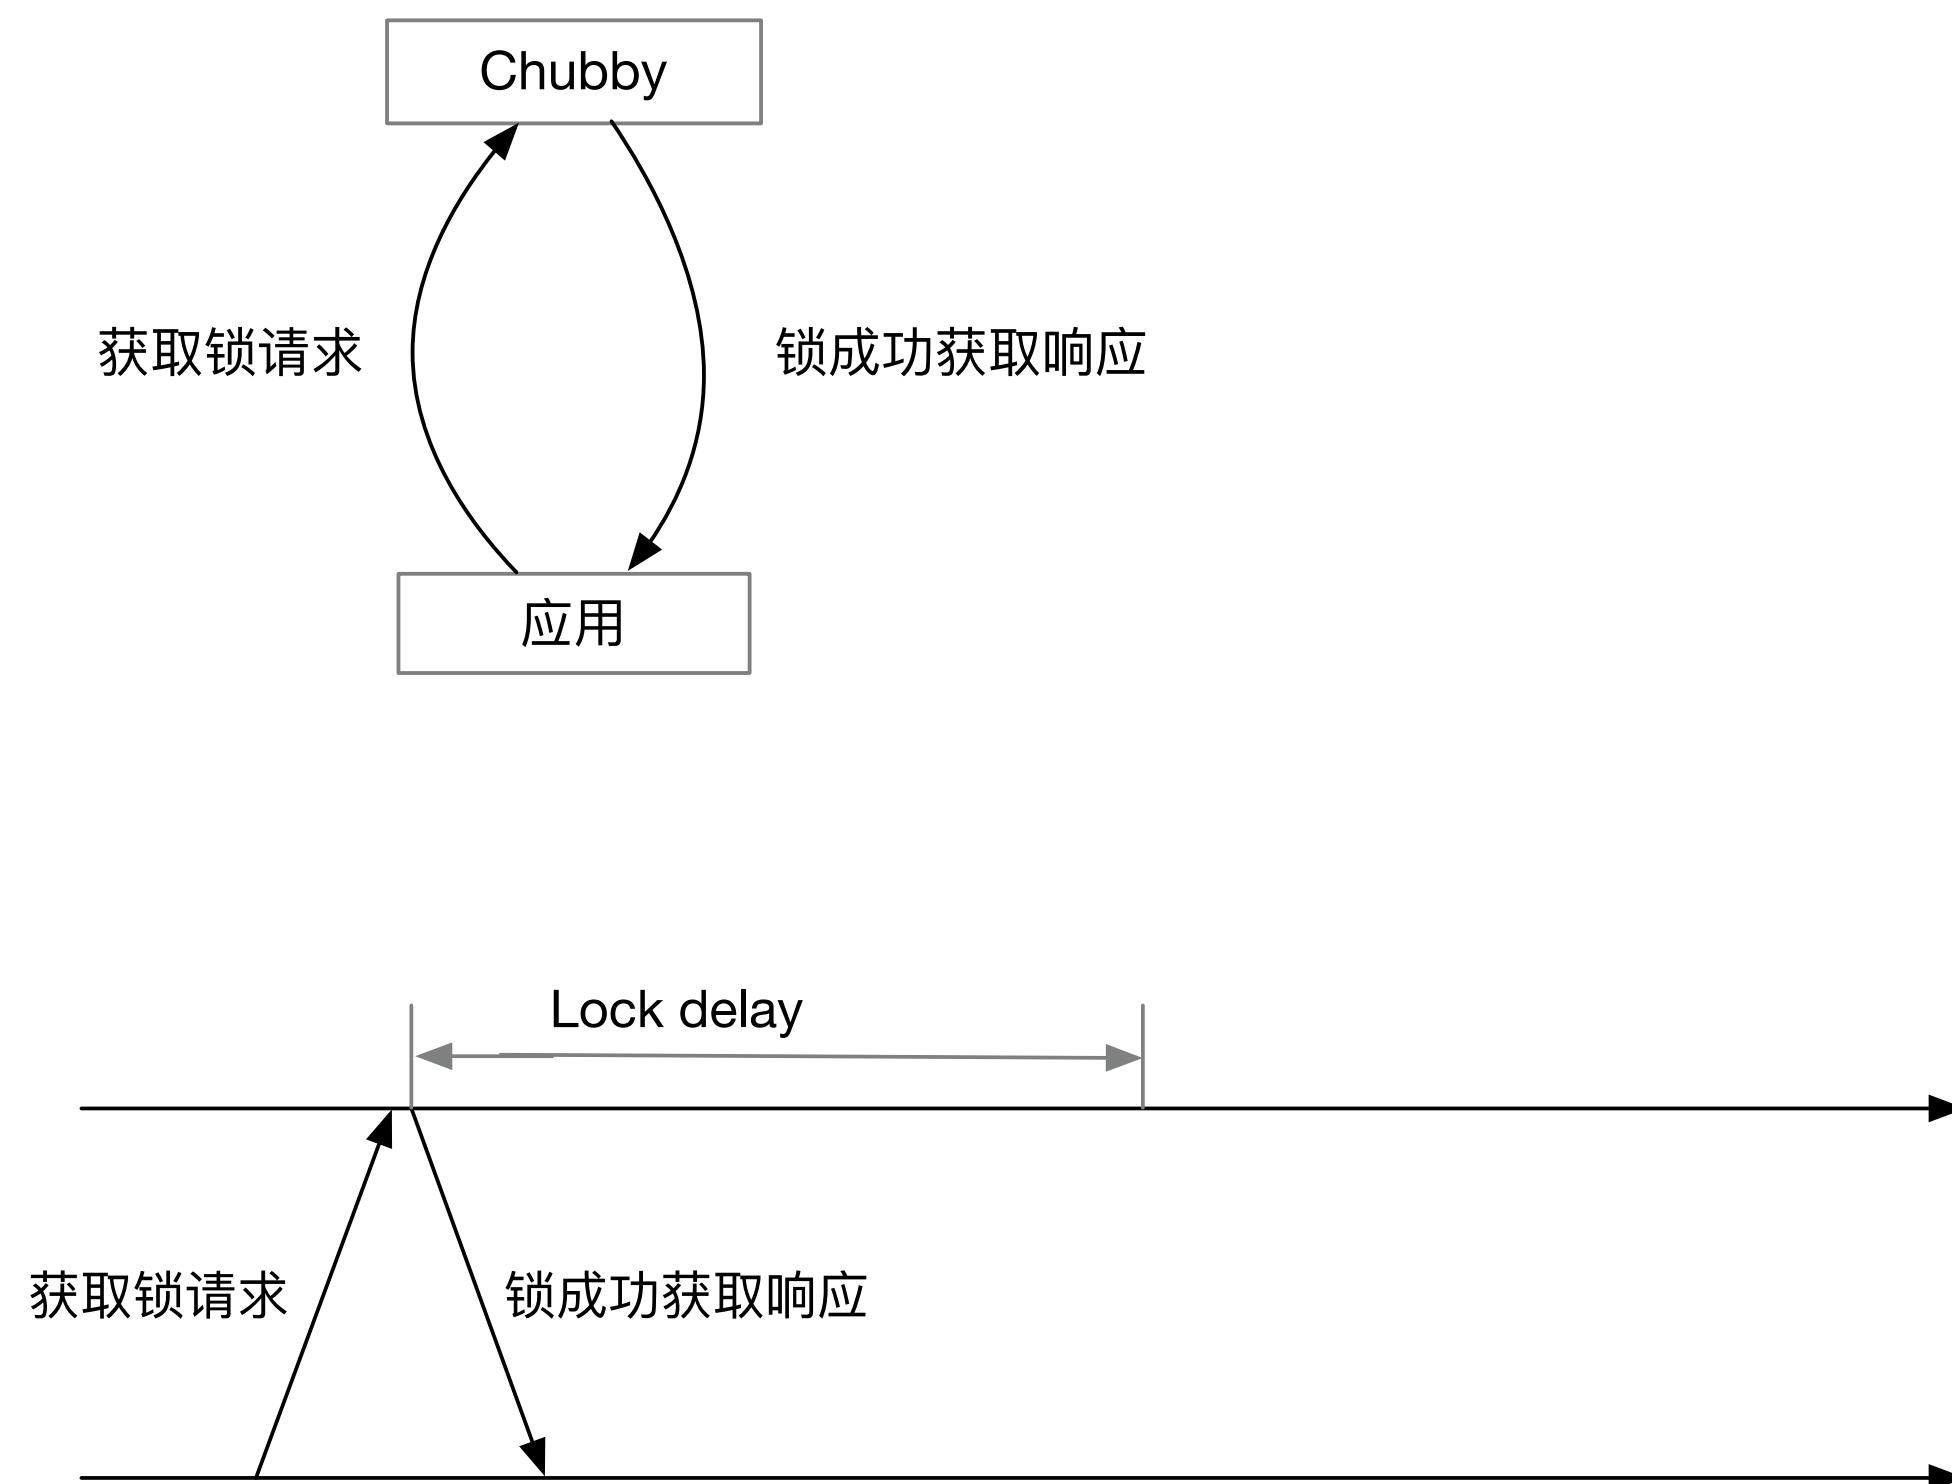
一个锁持有者可以使用 GetSequencer() API 向 Chubby 请求一个 sequencer。之后锁持有者发送访问资源的请求时，把 sequencer 一起发送给资源服务。资源服务会对 sequencer 进行验证，如果验证失败，就拒绝资源访问请求。sequencer 包含的数据有锁的名称、锁的模式和 lock generation number。



ZooKeeper 锁 recipe 里面表示锁请求的 znode 的序列号可以用作 sequencer，从而也可以实现解决方案 1。

解决方案 2-lock delay

如果锁 L 的持有者失败了或者访问不到 Chubby cell 中的节点了，Chubby 不会立刻处理对锁 L 的请求。Chubby 会等一段时间（默认1分钟）才会把锁 L 分配给其他的请求。这样也可以保证应用 2 在更晚的时刻获得到锁 L，从而在更晚的时刻发送请求 R'，保证 R 先于 R' 执行。

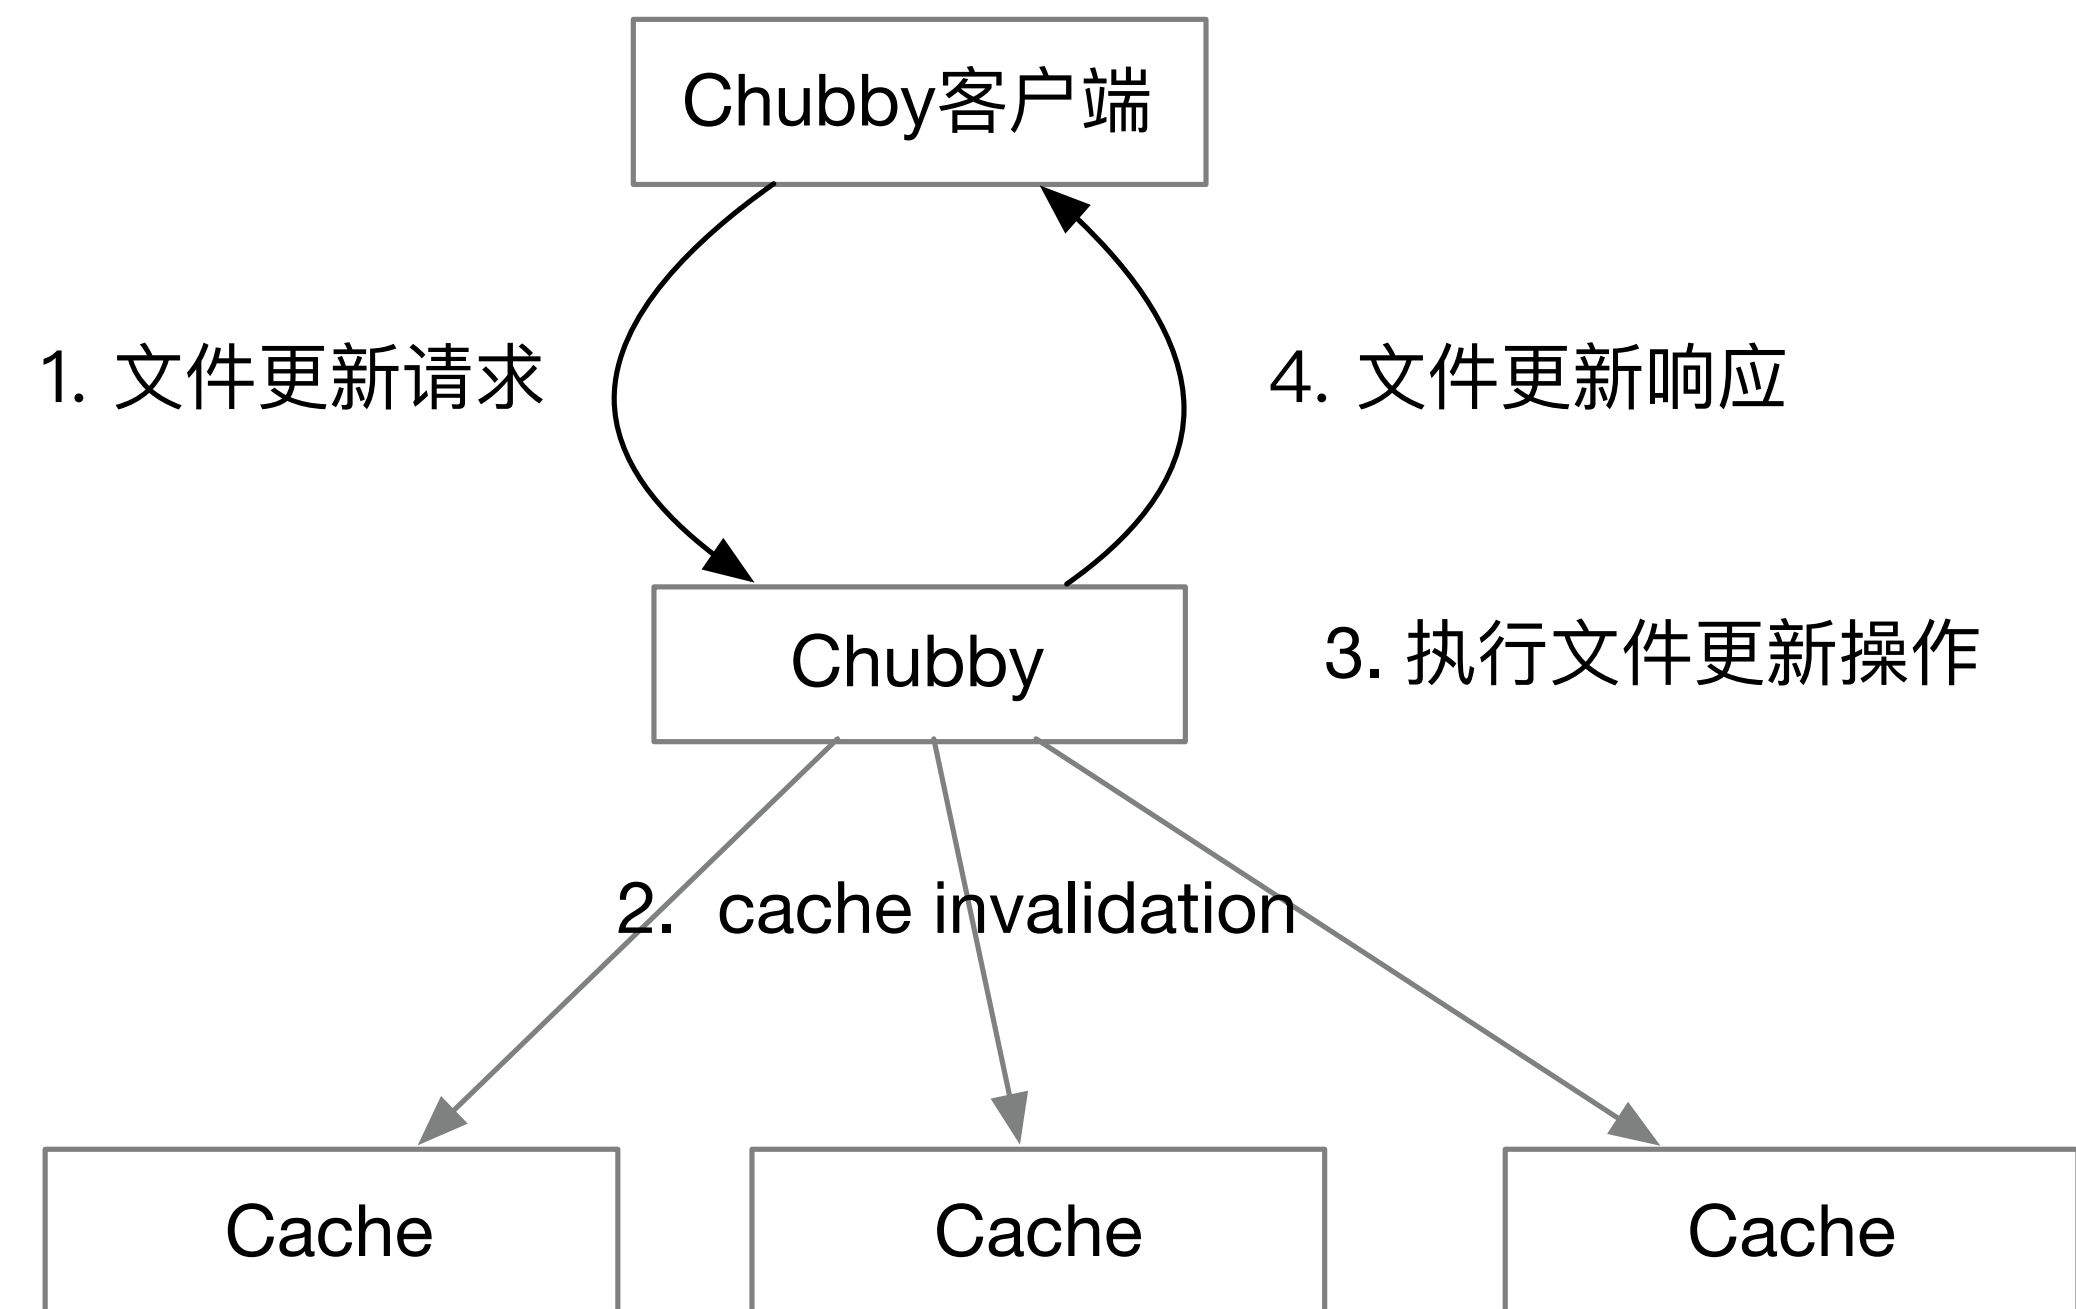


cache

Chubby 的客户端维护一个 write-through 的 cache，能保证 cache 中的数据 and Chubby 节点上的数据是一致的。master 只有在所有的 cache 失效之后（收到客户端 cache invalidation 的响应或者客户端的 lease 失效了），才进行文件更新操作。

lease 是客户端维持 session 有效的时间段。如果过了这段时间，客户端还没有 renew lease 的话，客户端停止任何 Chubby 的操作，并断开 session。

ZooKeeper 没有办法提供和 Chubby 一样的 cache。原因是 ZooKeeper 是先更新再发通知，没有办法避免 cache 中有旧数据。



相同之处

- Chubby 的文件相当于 ZooKeeper 的 znode 。Chubby 的文件和 znode 都是用来存储少量数据。
- 都只提供文件的全部读取和全部写入。
- 都提供类似 UNIX 文件系统的 API 。
- 都提供接收数据更新的通知，Chubby 提供 event 机制，ZooKeeper 提供 watch 机制。
- 它们的客户端都通过一个 session 和服务端进行交互。
- 写操作都是通过 leader/master 来进行。
- 都支持持久性和临时性数据。
- 都使用复制状态机来做容错。

不同之处

Chubby	ZooKeeper
Chubby 内置对分布式锁的支持。	ZooKeeper 本事不提供锁，但是可以基于 ZooKeeper 的基本操作来实现锁。
读操作也必须通过 master 节点来执行。相应的，Chubby 保证的数据一致性强一些，不会有读到旧数据的问题。	读操作可以通过任意节点来执行。相应的，ZooKeeper 保证的数据一致性弱一些，有读到旧数据的问题。
Chubby 提供一个保证数据一致性的 cache。有文件句柄的概念。	ZooKeeper 不支持文件句柄，也不支持 cache，但是可以通过 watch 机制来实现 cache。但是这样实现的 cache 还是有返回旧数据的问题。
Chubby 基本操作不如 ZooKeeper 的强大。	ZooKeeper 提供更强大的基本操作，例如对顺序性节点的支持，可以用来实现更多的协同服务。
Chubby 使用 Paxos 数据一致性协议。	ZooKeeper 使用 Zab 数据一致性协议。

Raft 协议解析

什么是 Raft

Raft 是目前使用最为广泛的一致性算法。例如新的协同服务平台 etcd 和 Consul 都是使用的 Raft 算法。

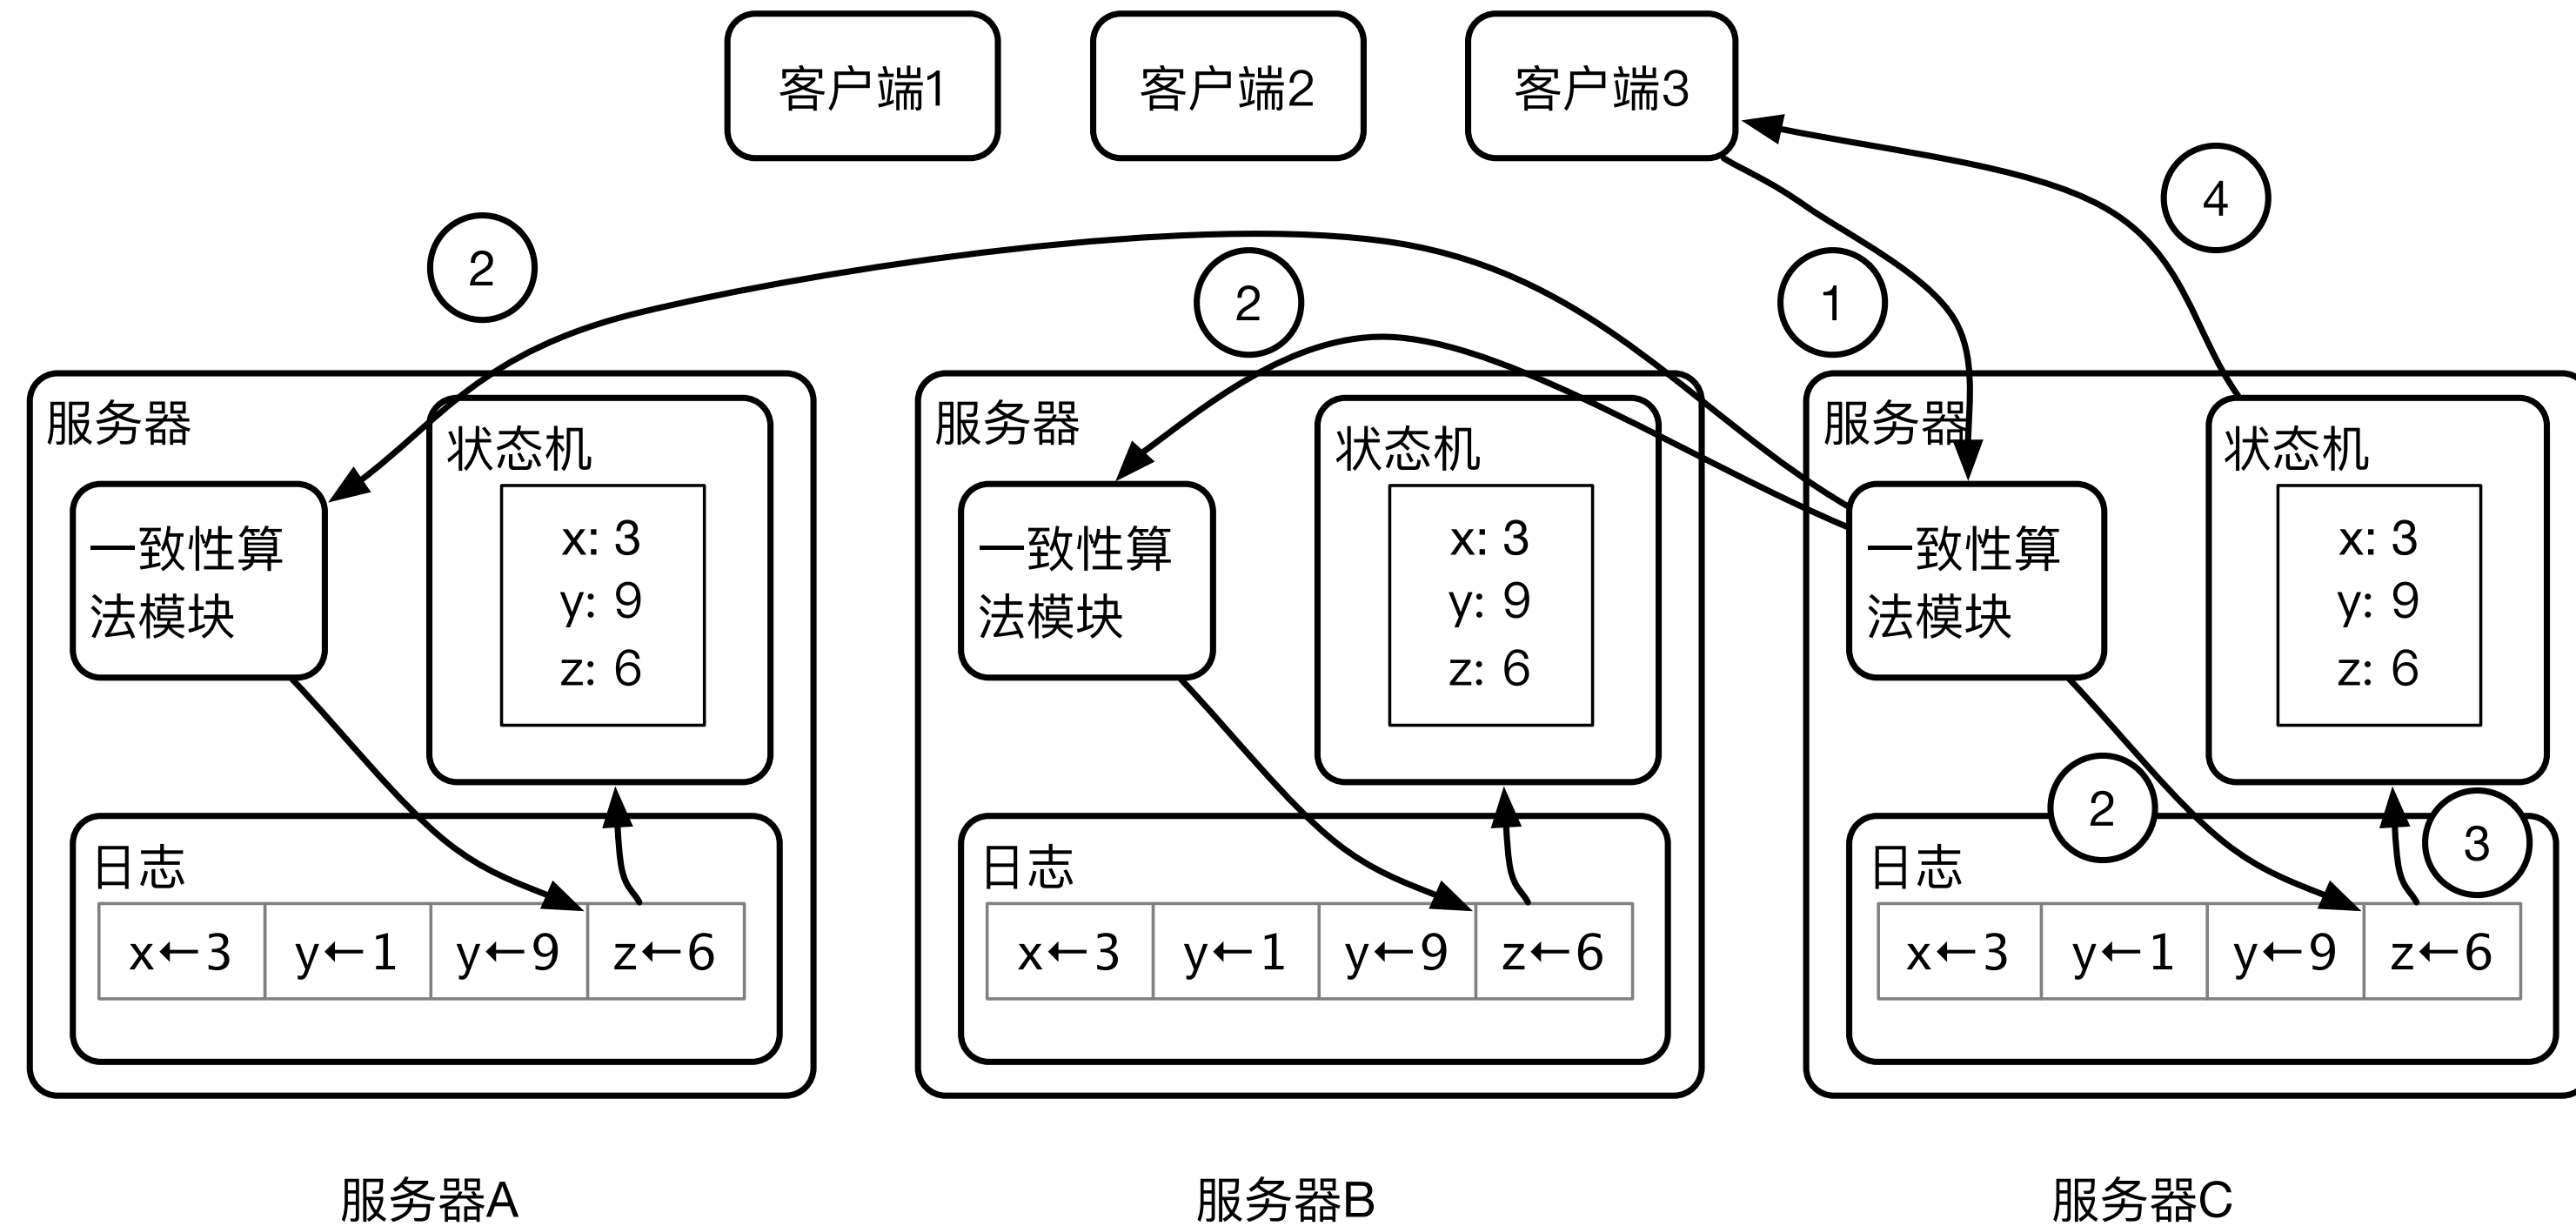
在 Raft 出现之前，广泛使用的一致性算法是 Paxos。Paxos 的基本算法解决的是如何保证单一客户端操作的一致性，完成每个操作需要至少两轮的消息交换。和 Paxos 不同，Raft 有 leader 的概念。Raft 在处理任何客户端操作之前必须选举一个 leader，选举一个 leader 需要至少一轮的消息交换。但是在选取了 leader 之后，处理每个客户端操作只需要一轮消息交换。

Raft 论文描述了一个基于 Raft 的复制状态机的整体方案，例如 Raft 论文描述了日志复制、选举机制和成员变更等这些复制状态机的各个方面。相反 Paxos 论文只是给了一个一致性算法，基于 Paxos 的系统都要自己实现这些机制。

基于 Raft 的复制状态机系统架构

右图展示了执行一条客户端写命令的过程
($z \leftarrow 6$ 表示把 6 写入 z)：

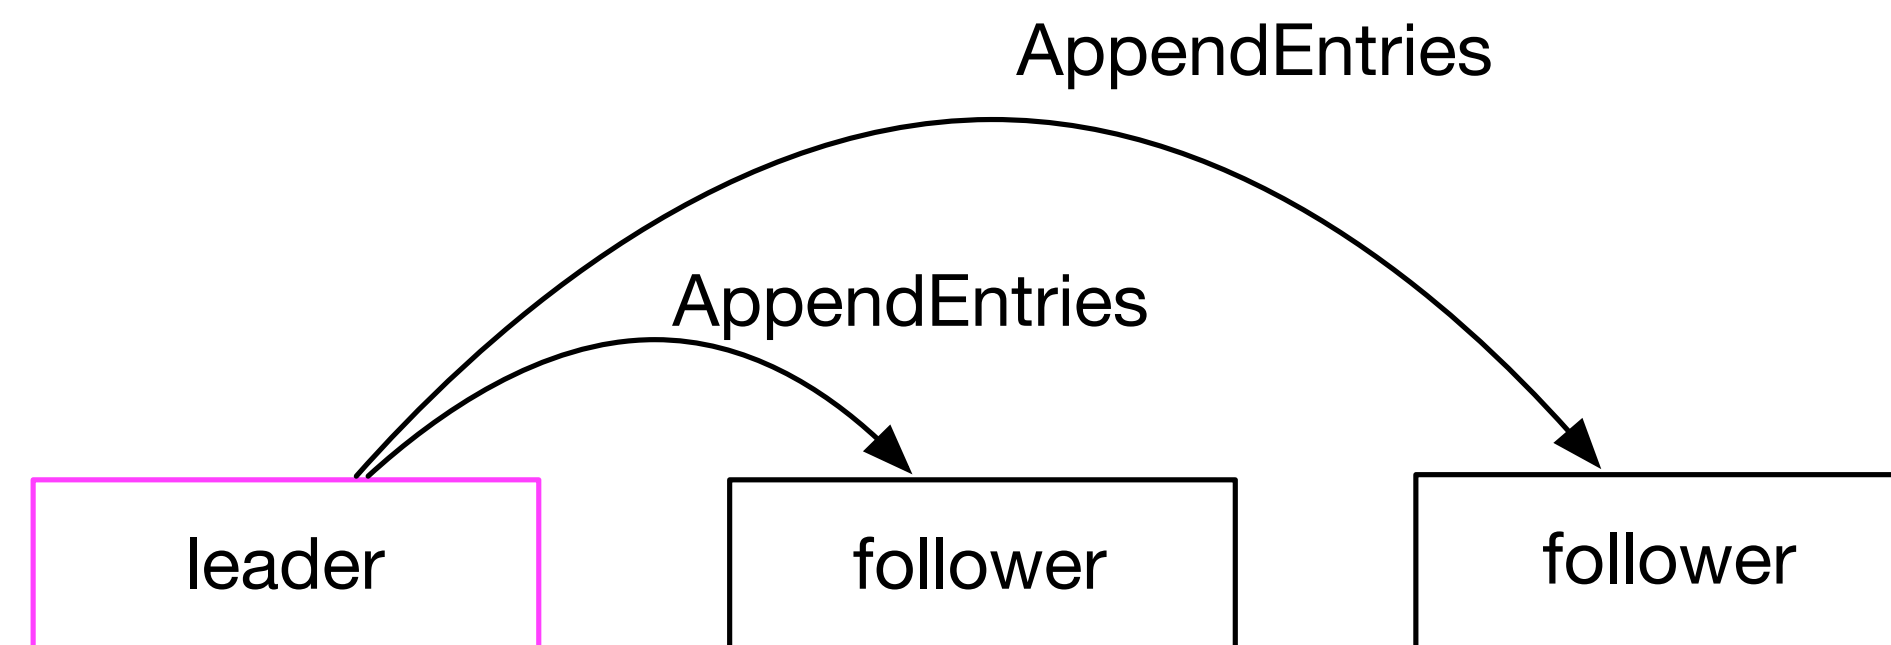
1. 客户端 3 发送一个状态机命令 $z \leftarrow 6$ 给服务器 C 的一致性算法模块。
2. 一致性算法模块把状态机命令写入服务器 C 的日志，同时发送日志复制请求给服务器 A 和服务器 B 的一致性算法模块。服务器 A 和服务器 B 的一致性算法模块在接收到日志复制请求之后，分别在给子的服务器上写入日志，然后回复服务器 C 的一致性算法模块。
3. 服务器 C 的一致性算法模块在收到服务器 A 和 B 对日志复制请求的回复之后，让状态机执行来自客户端的命令。
4. 服务器 C 的状态机把命令执行结果返回给客户端 3。



Raft 日志复制

一个 Raft 集群包括若干服务器。服务器可以处于以下三种状态：leader、follower 和 candidate。只有 leader 处理来自客户端的请求。follower 不会主动发起任何操作，只会被动的接收来自 leader 和 candidate 的请求。在正常情况下，Raft 集群中有一个 leader，其他的都是 follower。leader 在接受到一个写命令之后，为这个命令生成一个日志条目，然后进行日志复制。

leader 通过发送 AppendEntries RPC 把日志条目发送给 follower，让 follower 把接收到的日志条目写入自己的日志文件。另外 leader 也会把日志条目写入自己的日志文件。日志复制保证 Raft 集群中所有的服务器的日志最终都处于同样的状态。



Raft 的日志复制对应的就是 Paxos 的 accept 阶段，它们是很相似的。

日志条目的提交

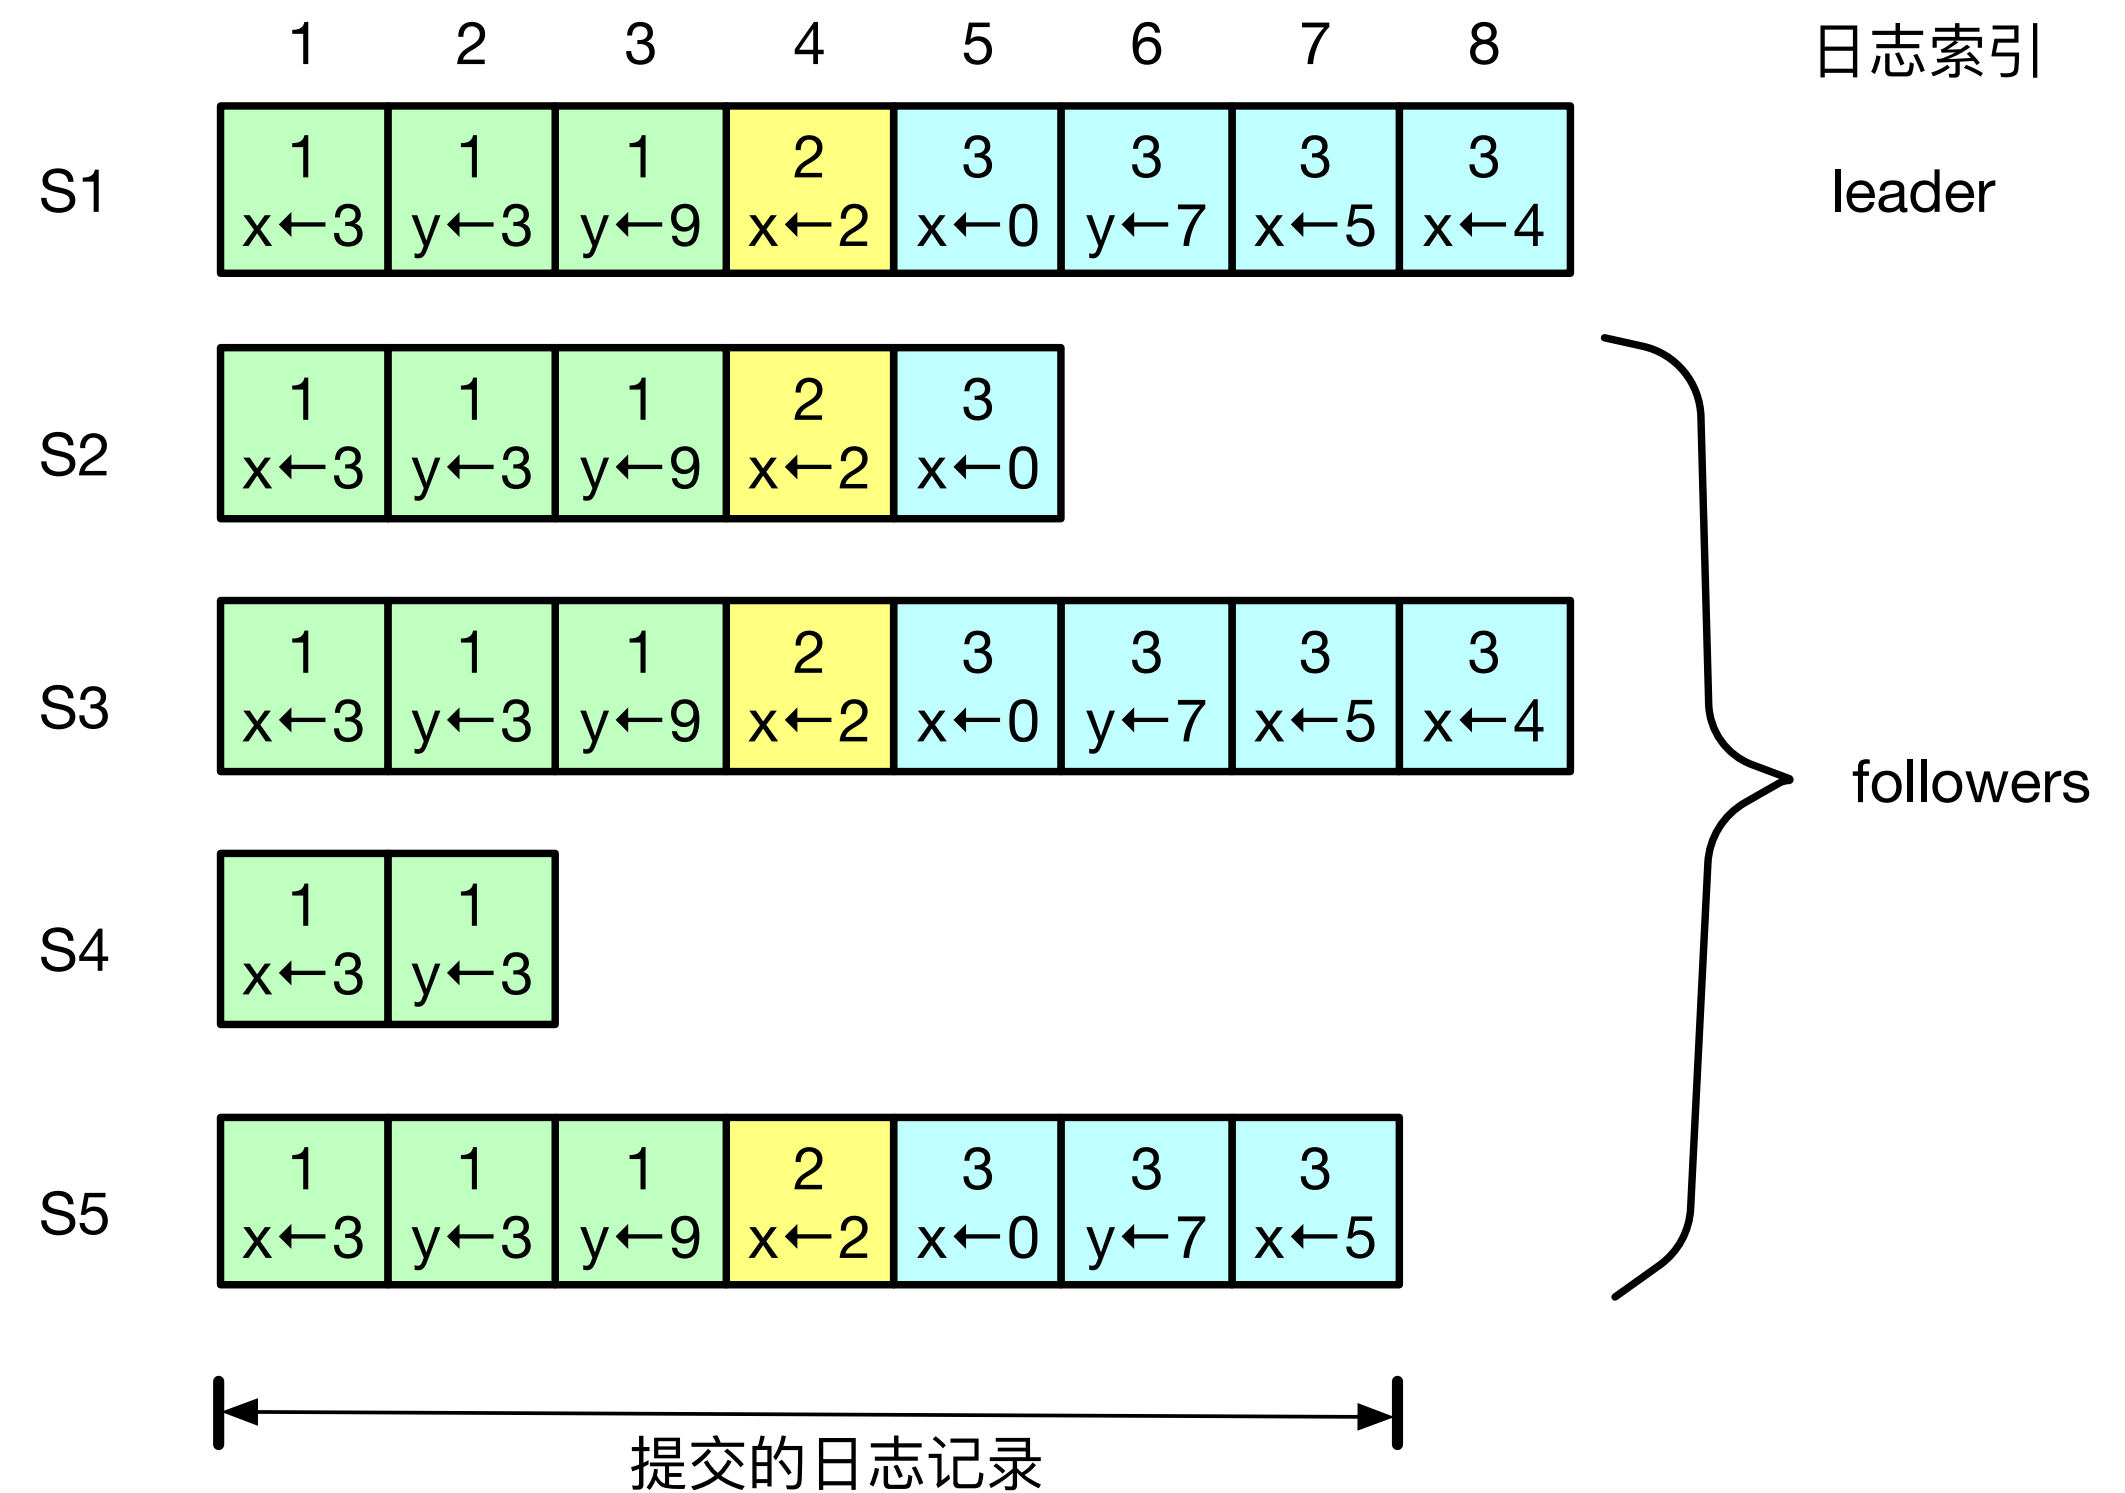
leader 只有在客户端请求被提交以后，才可以在状态机执行客户端请求。提交意味着集群中多数服务器完成了客户端请求的日志写入，这样做是为了保证以下两点：

- 容错：在数量少于 Raft 服务器总数一半的 follower 失败的情况下，Raft 集群仍然可以正常处理来自客户端的请求。
- 确保重叠：一旦 Raft leader 响应了一个客户端请求，即使出现 Raft 集群中少数服务器的失败，也会有一个服务器包含所有以前提交的日志条目。

Raft 日志复制示例

右图表示的是一个包括 5 个服务器的 Raft 集群的日志格式，S1 处于 leader 状态，其他的服务器处于 follower 状态。每个日志条目由一条状态机命令和创建这条日志条目的 leader 的 term 组成。每个日志条目有对应的日志索引，日志索引表示这条日志在日志中的位置。

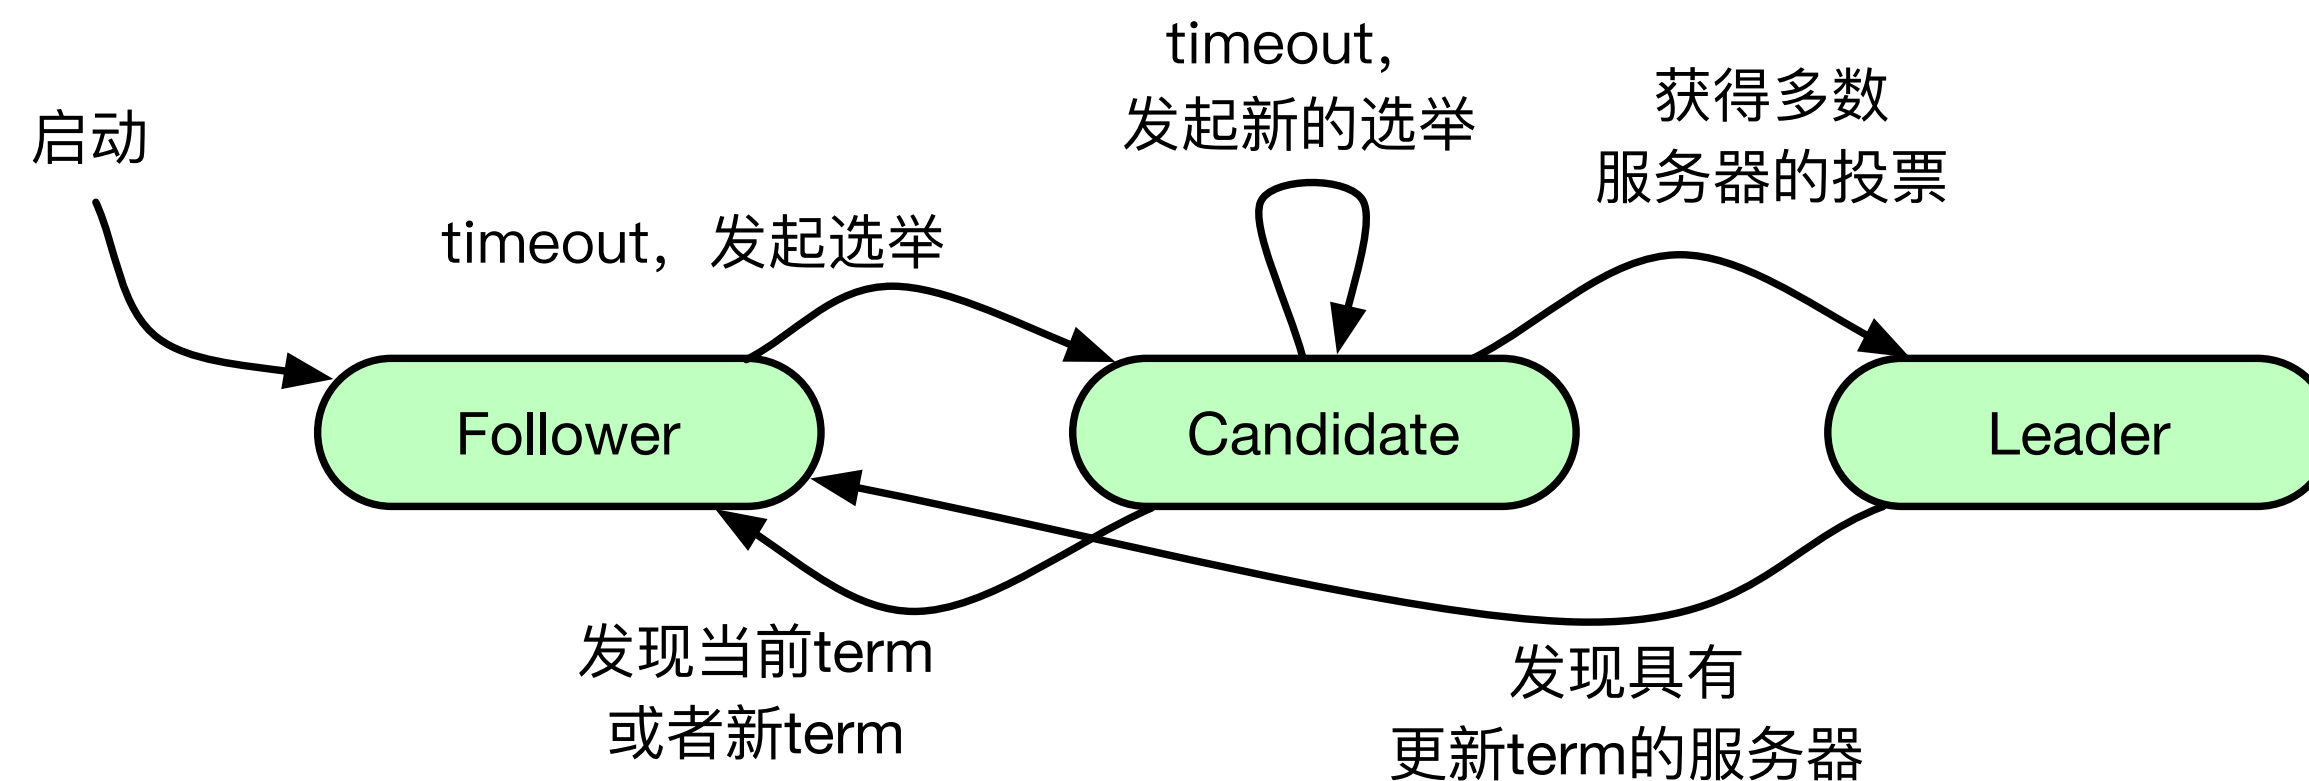
Raft 集群中提交的日志条目是 S5 上面的所有日志条目，因为这些日志条目被复制到了集群中的大多数服务器。



Raft选举算法

Raft 使用心跳机制来触发 leader 选取。一个 follower 只要能收到来自 leader 或者 candidate 的有效 RPC，就会一直处于 follower 状态。leader 在每一个 election timeout 向所有 follower 发送心跳消息来保持自己的 leader 状态。如果 follower 在一个 election timeout 周期内没有收到心跳信息，就认为目前集群中没有 leader。此时 follower 会对自己的 currentTerm 进行加一操作，并进入 candidate 状态，发起一轮投票。它会给自己投票并向其他所有的服务器发送 RequestVote RPC，然后会一直处于 candidate 状态，直到下列三种情形之一发生：

1. 这个 candidate 赢得了选举。
2. 另外一台服务器成为了 leader。
3. 一段时间之内没有服务器赢得选举。在这种情况下，candidate 会再次发起选举。



Raft 的选举对应的就是 Paxos 的 prepare 阶段，它们是很相似的。

日志匹配


Raft 日志条目具备以下日志匹配属性：

1. 如果两个服务器上的日志条目有的相同索引和 term，那么这两个日志条目存储的状态机命令是一样的。
2. 如果两个服务器上的日志条目有的相同索引和 term，那么这两个日志从头到这个索引是完全一样的。

如果 Raft 处于复制状态，每个 follower 的日志是 leader 日志的前缀，显然日志匹配属性是满足的。在一个新的 leader 出来之后，follower 的日志可能和 leader 的日志一致，也可能处于以下三种不一致状态：

1. follower 与 leader 相比少一些日志条目。
2. follower 与 leader 相比多一些日志条目。
3. 包含（1）和（2）两种不一致情况。

例如在右图中，follower (a) 和 follower (b) 属于不一致情况 1，follower (c) 和 follower (d) 属于不一致情况 2，follower (e) 和 follower (f) 属于不一致情况 3。

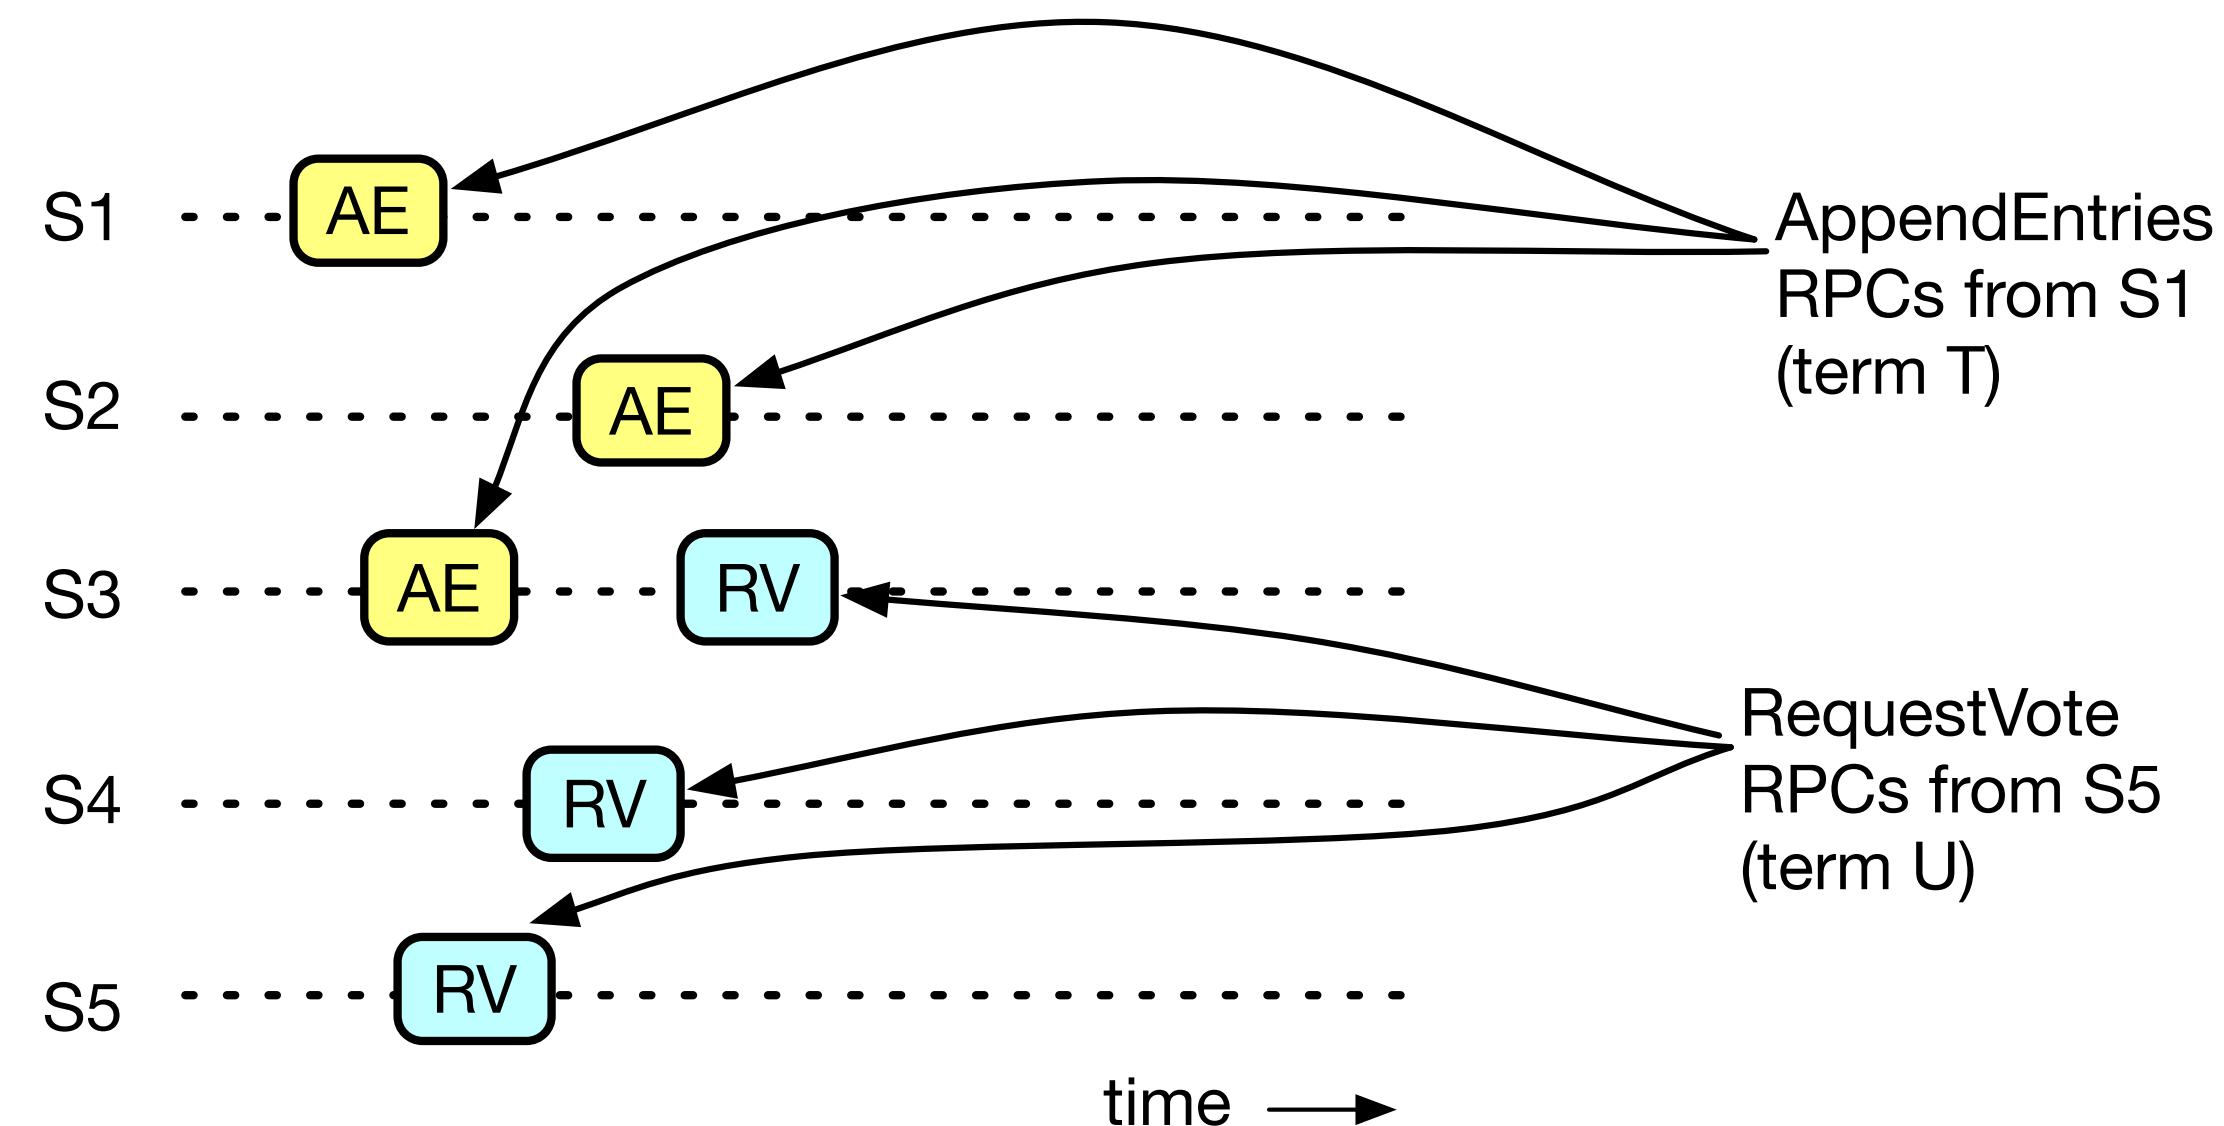


如何保证一个新 term 的 leader 保存了所有提交的日志条目

以下两点保证新 term 的 leader 保存了所有提交的日志条目：


1. 日志条目只有复制到了多个服务器上，才能提交。
2. 一个 candidate 只有赢得了多个服务器的 vote，才能成为 leader。并且要求只有 candidate 的日志比自己的新的时候才能 vote。

下图的 Raft 集群有 5 个服务器：S1、S2、S3、S4、S5。S1 是 leader。S1 把一条日志复制了 S1、S2 和 S3 之后，提交这一条日志。以后发生了选举，S5 成了新 term U 的 leader。上面两点保证一定有一个服务器收到了这条日志并参与了 term U 的投票，这里是 S3。第 2 点又保证 S5 的日志比 S3 的新，所以 S5 必定保存了这条日志。



状态机命令的提交点

前面我说过，一条日志在被复制到多个服务器之后就可以提交。但这是一种不准确的说法。下图解释了为什么 leader 不能靠检查一条日志是否复制到了大多数服务器上来确定旧 term 的日志条目是否已经提交。



准确的说法：Raft 不会通过计算旧 term 的日志条目被复制到了多少台服务器来决定是否它已经被提交，只有当前 term 的日志条目提交状态可以这么决定。如果当前 term 的日志条目被提交，那么基于日志匹配属性，我们知道之前的日志条目也都被间接的提交了。

集群成员更新

我们把 Raft 集群中的机器集合称为集群配置。到目前位置，我们都假定集群配置是固定的。但在实际环境中，我们会经常需要更改配置，例如更换故障的机器或者更改日志的复制级别。我们希望 Raft 集群能够接受一个集群配置变更的请求，然后自动完成集群变更。而且在集群配置的变更中，Raft 集群可以继续提供服务。另外集群配置的变更还要做到一定程度的容错。

Raft 提供一个两阶段的集群成员更新机制。

什么是 etcd

什么是 etcd

etcd 是一个高可用的分布式 KV 系统，可以用来实现各种分布式协同服务。etcd 采用的一致性算法是 raft，基于 Go 语言实现。

etcd 最初由 CoreOS 的团队研发，目前是 Cloud Native 基金会的孵化项目。

为什么叫 etcd：etc来源于 UNIX 的 /etc 配置文件目录，d 代表 distributed system。

etcd 应用场景

典型应用场景：

- Kubernetes 使用 etcd 来做服务发现和配置信息管理。
- Openstack 使用 etcd 来做配置管理和分布式锁。
- ROOK 使用 etcd 研发编排引擎。

etcd 和 ZooKeeper 覆盖基本一样的协同服务场景。ZooKeeper 因为需要把所有的数据都要加载到内存，一般存储几百MB的数据。etcd使用bbolt存储引擎，可以处理几个GB的数据。

MVCC

etcd 的数据模型是 KV模型，所有的 key 构成了一个扁平的命名空间，所有的 key 通过字典序排序。

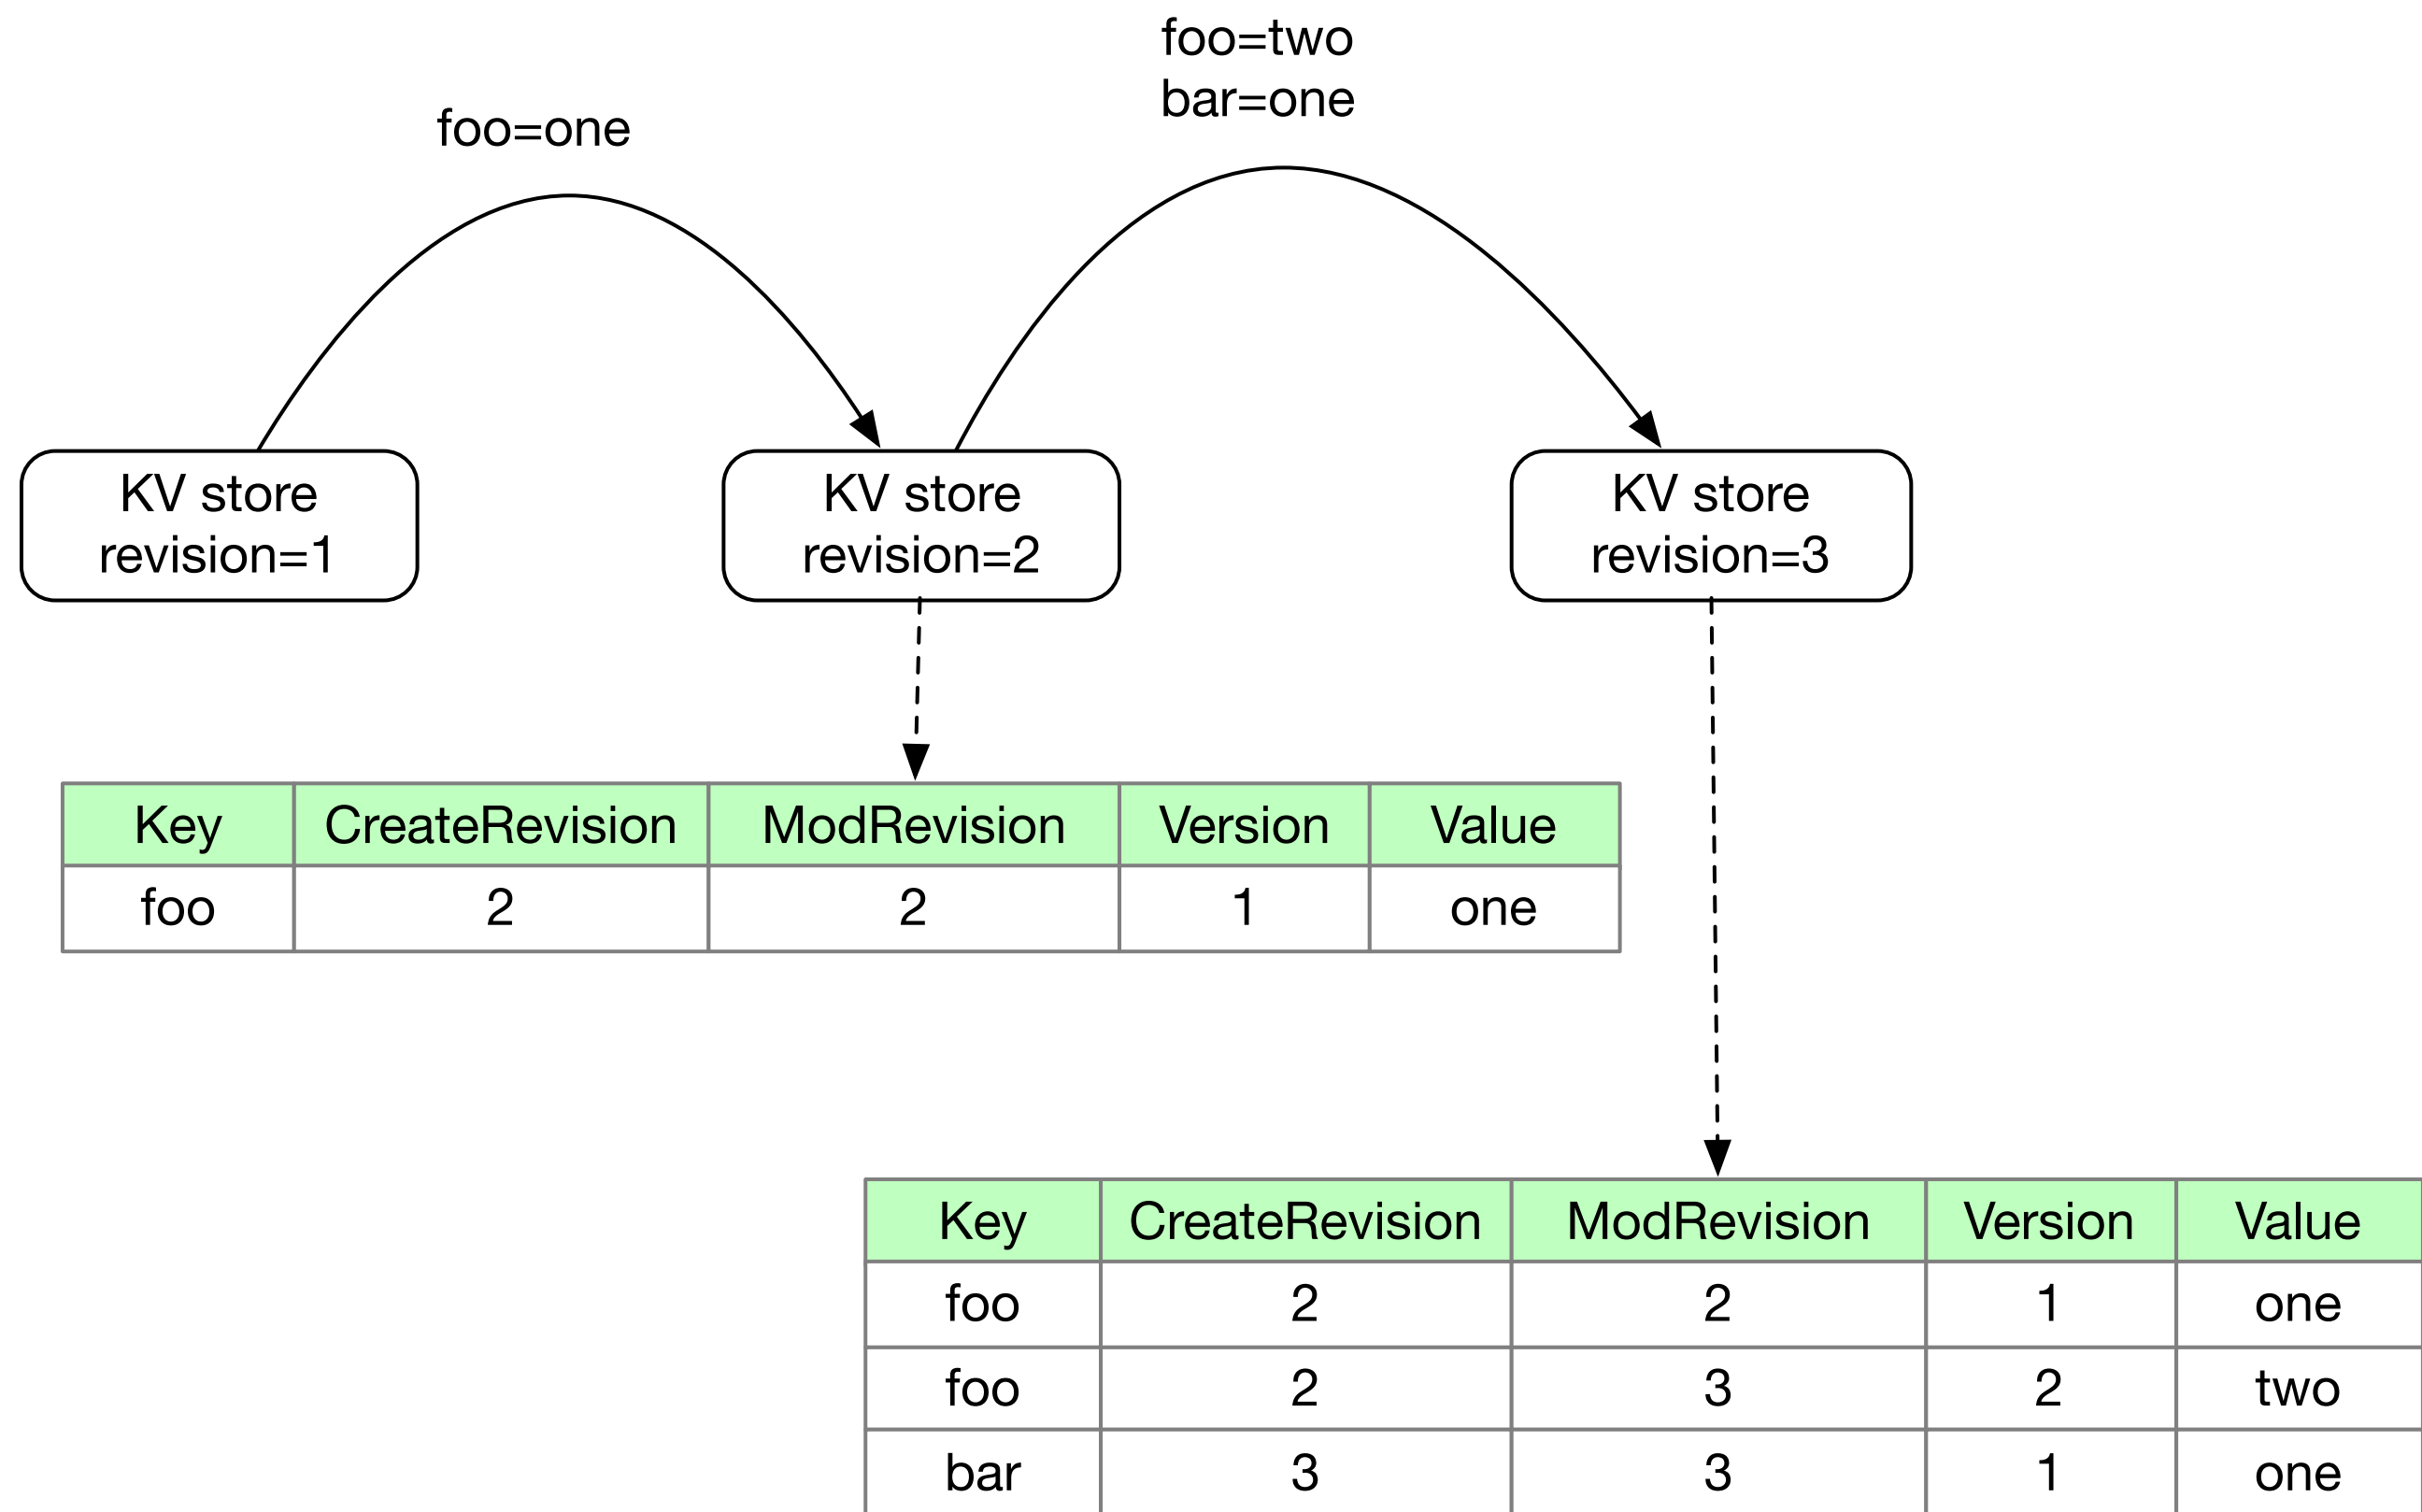
整个 etcd 的 KV 存储维护一个递增的64位整数。etcd 使用这个整数位为每一次 KV 更新分配一个 revision。每一个 key 可以有多个 revision。每一次更新操作都会生成一个新的 revision。删除操作会生成一个 tombstone 的新的 revision。如果 etcd 进行了 compaction，etcd 会对 compaction revision 之前的 key-value 进行清理。整个 KV 上最新的一次更新操作的 revision 叫作整个 KV 的 revision。

Key	CreateRevision	ModRevision	Version	Value
foo	10	10	1	one
foo	10	11	2	two
foo	10	12	3	three

CreateRevision 是创建 key 的 revision；ModRevision 是更新 key 值的 revision；Version 是 key 的版本号，从 1 开始。

etcd 状态机

可以把 etcd 看做一个状态机。Etcd 的状态是所有的 key-value, revision 是状态的编号, 每一个状态转换是若干个 key 的更新操作。



etcd 数据存储

- etcd 使用 bbolt 进行 KV 的存储。bbolt 使用持久化的 B+-tree 保存 key-value 。三元组 (major、sub、type) 是 B+-tree 的 key, major 是的 revision, sub 用来区别一次更新中的各个 key, type 保存可选的特殊值 (例如 type 取值为 t 代表这个三元组对应的是一个 tombstone) 。这样做的目的是为加速某一个 revision 上的 range 查找。
- 另外 etcd 还维护一个 in-memory 的 B-tree 索引, 这个索引中的 key 是 key-value 中的 key 。

安装配置 etcd

下面列出的是在 macOS 上安装配置 etcd 的步骤：

- 从 <https://github.com/etcd-io/etcd/releases> 下载 etcd-v3.4.1-darwin-amd64.zip。
- 把 etcd-v3.4.1-darwin-amd64.zip 解压到一个本地目录 {etcd-dir} 。
- 把 {etcd-dir} 加到 PATH 环境变量。
- 创建一个目录 {db-dir} 用来保存 etcd 的数据文件。
- 因为我们要使用最新的 v3 API，把 export ETCDCTL_API=3 加到 ~/.zshrc。

使用 etcdctl

在 {db-dir} 目录运行 etcd 启动 etcd 服务，让后在另外一个终端运行：

- `etcdctl put foo bar`
- `etcdctl get foo`
- `etcdctl del foo`

`etcdctl get "" --prefix=true` 可以用来扫描 etcd 的所有数据。`etcdctl del "" --prefix=true` 可以用来删除 etcd 中的所有数据。

使用 etcd HTTP API

除了使用 etcdctl 工具访问 etcd，我们可以使用 etcd HTTP Rest API。

- `http POST http://localhost:2379/v3/kv/put <<< '{"key": "Zm9v",
"value": "YmFy"}'`
- `http POST http://localhost:2379/v3/kv/range <<< '{"key": "Zm9v"}'`

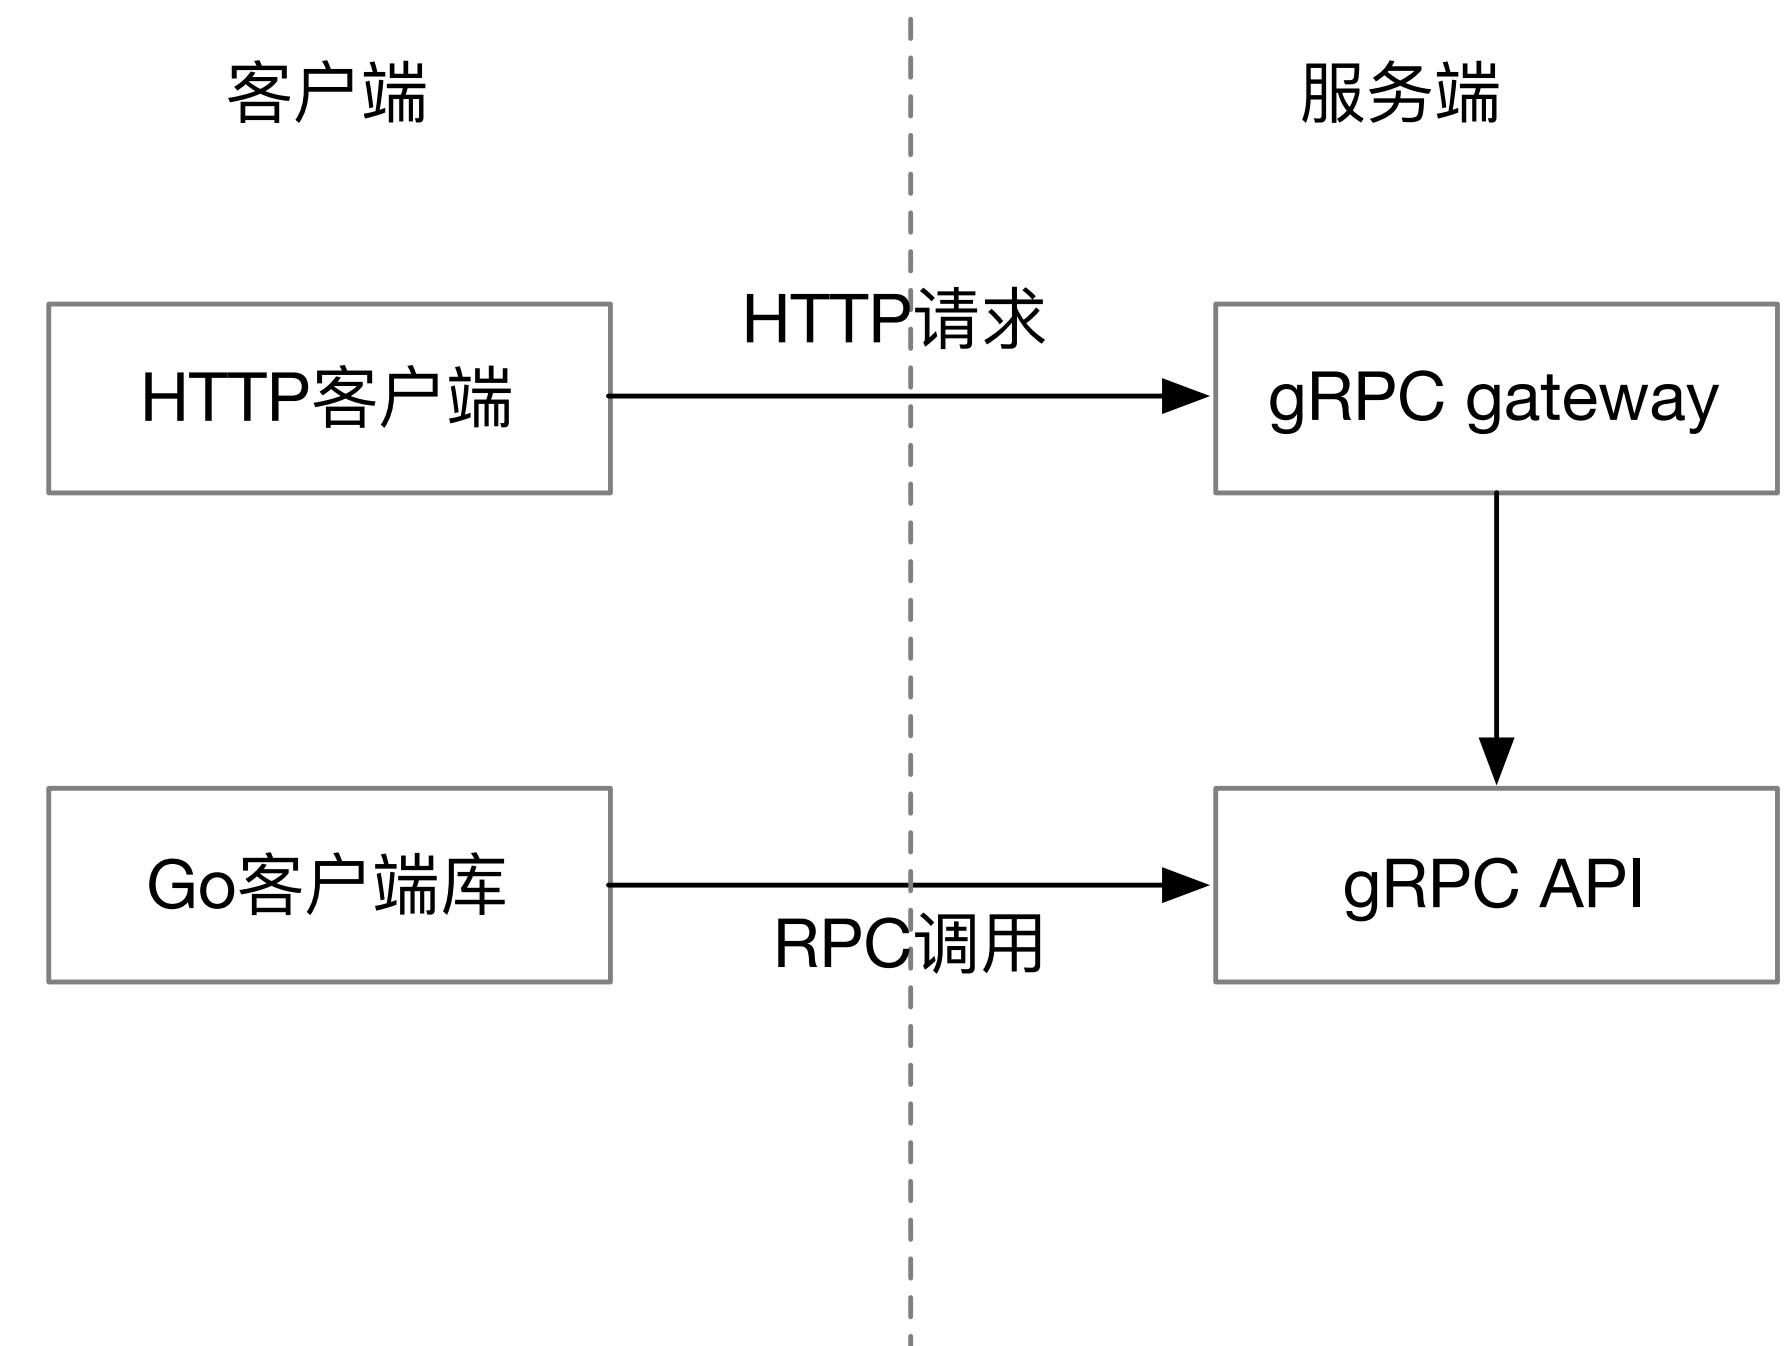
Zm9v 是 foo 的 base64 编码，YmFy 是 bar 的 base64 编码。和 etcdctl 相比，etcd HTTP API 返回的数据更多，可以帮助我们学习 etcd API 的行为。

etcd API: KV 部分

etcd API

etcd 使用 gRPC 提供对外 API。Etcd 官方提供一个 Go 客户端库。Go 客户端库是对 gRPC 调用的封装，对于其他常见语言也有[第三方提供的客户端库](#)。另外 etcd 还用 gRPC gateway 对外提供了 HTTP API。可见 etcd 提供了丰富的客户端接入方式。ZooKeeper 的 RPC 是基于 jute 的，客户端只有 Java 版和 C 语言班，接入方式相少一些。

和 ZooKeeper 的客户端库不同，etcd 的客户端不会自动和服务端建立一个 session，但是可以使用 Lease API 来实现 session。



etcd API

etcd 使用 gRPC 提供对外 API。etcd 的 API 分为三大类：

- KV: key-value 的创建、更新、读取和删除。
- Watch: 提供监控数据更新的机制。
- Lease: 用来支持来自客户端的 keep-alive 消息。

Response Header

所有的 RPC 响应都有一个 response header, Protobuf response header 包含以下信息:

- cluster_id: 创建响应的etcd集群 ID。
- member_id: 创建响应的etcd节点 ID。
- revision: 创建响应时 etcd KV 的 revision。
- raft_term: 创建响应时的 raft term。

KeyValue

Key-value 是 etcd API 处理的最小数据单元，一个 Protobuf KeyValue 消息包含如下信息：

- key: key 的类型为字节 slice。
- create_revision: key-value 的创建 revision。
- mod_revision: key-value 的修改 revision。
- version: key-value 的版本，从1开始。
- value: value 的类型为字节 slice。
- lease: 和 key-value 关联的 lease ID。0代表没有关联的 lease。

Key Range

key range $[key, range_end)$ 代表从 key (包含) 到 range_end (不包含) 的 key 的区间。etcd API 使用可以 range 来检索 key-value。

- $[x, x + '\x00')$ 代表单个 key a, 例如 $['a', 'a\x00')$ 代表单个 key 'a'。对应 ZooKeeper, 可以用 $['/a', '/a\x00')$ 表示 '/a' 这个节点。
- $[x, x+1)$ 代表前缀为 x 的 key, 例如 $['a', 'b')$ 代表所有前缀为 'a' 的 key。对应 ZooKeeper, 可以用 $['/a/', '/a0')$ 来表示目录 '/a' 下所有的子孙节点, 但是没有办法使用 range 表示 '/a' 下的所有孩子节点。
- $['\x00', '\x00')$ 代表整个的 key 空间。
- $[a, '\x00')$ 代表所有不小于 a (非 '\x00') 的 key。

KV 服务

KV 服务主要包含以下 API:

- Range: 返回 range 区间中的 key-value。
- Put: 写入一个 key-value。
- DeleteRange: 删除 range 区间中的 key-value。
- Txn: 提供一个 If/Then/Else 的原子操作，提供了一定程度的事务支持。

Range 和 DeleteRange 操作的对象是一个 key range，Put 操作的对象是单个的 key，Txn 的 If 中进行比较的对象也是单个的 key。

Range API

etcd 的 Range 默认执行 linearizable read，但是可以配置成 serializable read。ZooKeeper 的数据读取 API 只支持 serializable read。

示例代码展示

Put API

示例代码展示

DeleteRange API

示例代码展示

etcd API: Watch 和 Lease 部分

Txn API

Txn 是 etcd kv 上面的 If/Then/Else 原子操作。如果 If 中的 Compare 的交为 true, 执行 Then 中的若干 RequestOp, 否则执行 Else 中的若干 RequestOp。

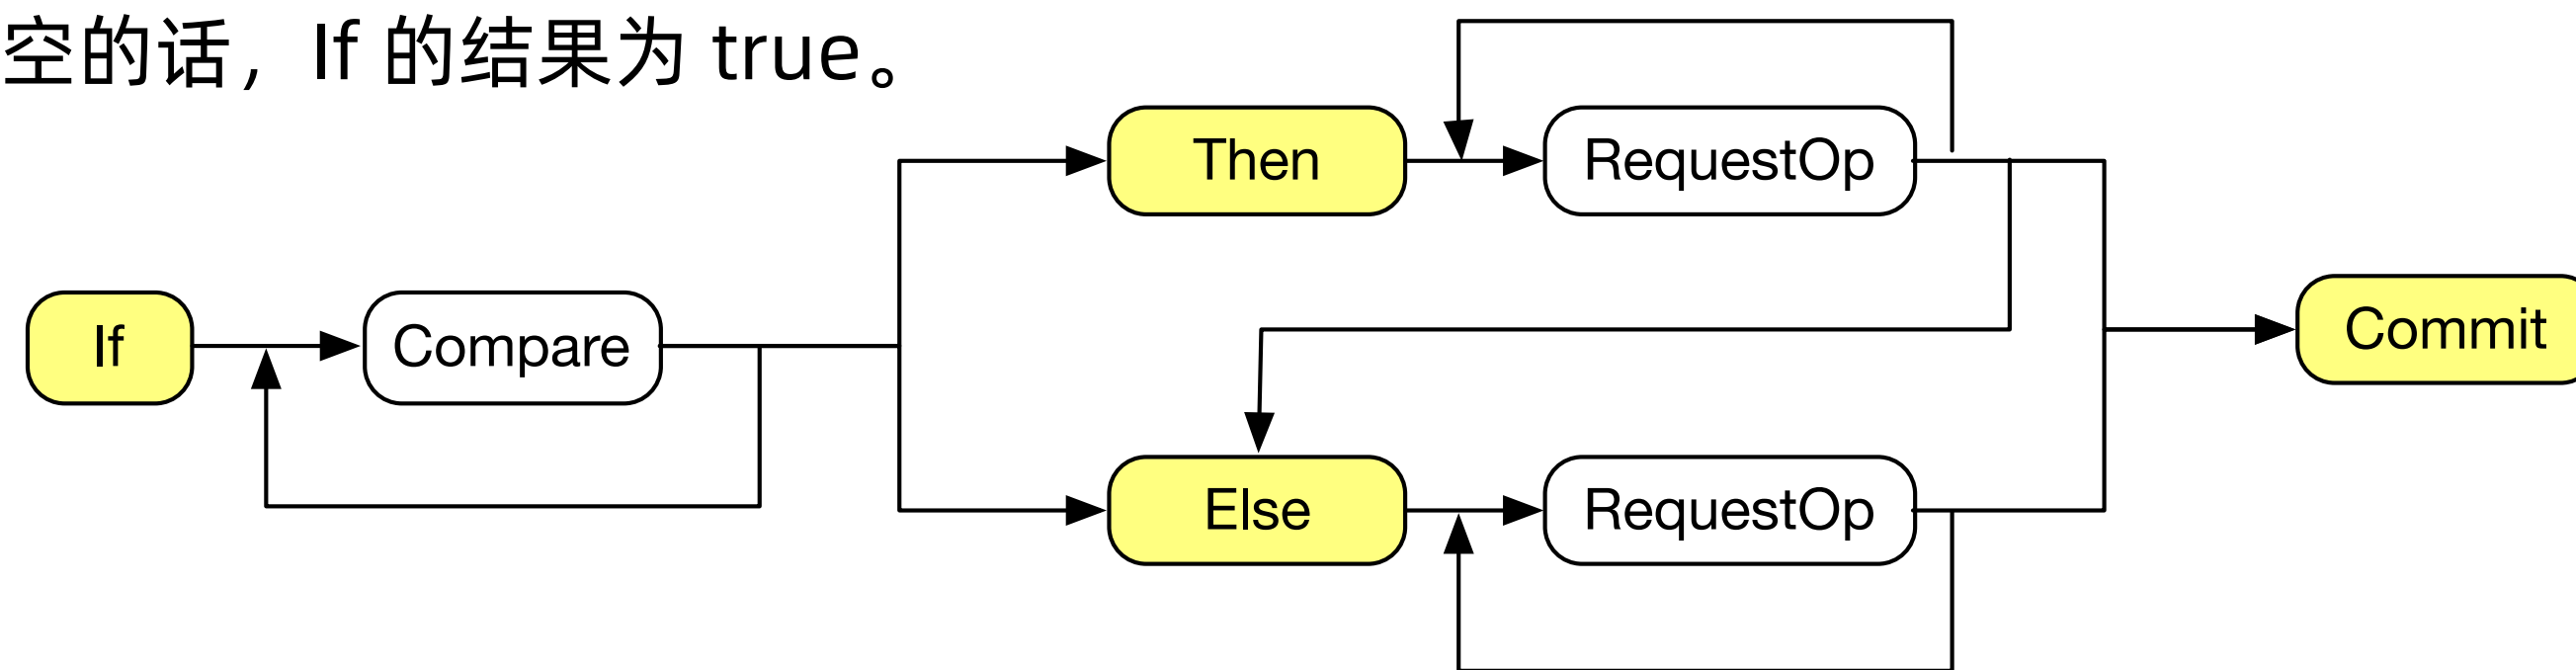
- 多个 Compare 可以使用多个 key。
- 多个 RequestOp 可以用来操作不同的 key, 后面的 RequestOp 能读到前面 RequestOp 的执行结果。所有的更新 RequestOp 对应一个 revision。不能有多个更新的 RequestOp 操作一个 key。

Txn API 提供一个更新整个 etcd kv 的原子操作。Txn 的 If 语句检查 etcd kv 中若干 key 的状态, 然后根据检查的结果更新整个 etcd kv。

Txn API 语法图

下图是简化的 Txn API 语法图。因为你缺少某个语句和语句为空是等价的，省略了缺少 If 语句、Then 语句和 Else 语句的情况。

- 如果 Then 为空或者 Else 为空，Txn 只有一个分支。
- 如果 If 为空的话，If 的结果为 true。



ZooKeeper 对应 etcd Txn API 的 API 是条件更新。条件更新对应的语法图如下图所示。可以看出 Txn 要比条件更新灵活很多。条件更新只能对一个节点 A 的版本做比较，如果比较成功对 A 节点做 setData 或者 delete 操作。



ZooKeeper 另外还有一个 Transaction API，可以原子执行一个操作序列，但是没有 Txn API 的条件执行操作的机制。

Txn API 示例代码展示

Watch API

Watch API 提供一个监控 etcd KV 更新事件的机制。etcd Watch 可以从一个历史的 revision 或者当前的 revision 开始监控一个 key range 的更新。

ZooKeeper 的 Watch 机制只能监控一个节点的当前时间之后的更新事件，但是 ZooKeeper 的 Watch 支持提供了对子节点更新的原生支持。etcd 没有对应的原生支持，但是可以用通过一个 key range 来监控一个目录下所有子孙的更新。

Watch API 示例代码展示

Lease API

Lease 是用来检测客户端是否在线的机制。客户端可以通过发送 LeaseGrantRequest 消息向 etcd 集群申请 lease，每个 lease 有一个 TTL (time-to-live)。客户端可以通过发送 LeaseKeepAliveRequest 消息来延长自己的 lease。如果 etcd 集群在 TTL 时间内没有收到来自客户端的 keep alive 消息，lease 就会过期。另外客户端也可以通过发送 LeaseRevokeRequest 消息给 etcd 集群来主动的放弃自己的租约。

可以把一个 lease 和一个 key 绑定在一起。在 lease 过期之后，关联的 key 会被删除，这个删除操作会生成一个 revision。

客户端可以通过不断发送 LeaseKeepAliveRequest 来维持一个和 etcd 集群的 session。和 lease 关联的 key 和 ZooKeeper 的临时性节点类似。

Lease API 示例代码展示

使用 etcd 实现分布式队列

队列基础

队列是一种 FIFO 的数据结构。队列首先可以用来保存元素入队的顺序，图的广度优先搜索算法就是用队列来保存访问节点的顺序。队列还可以用来做生产者和消费者的处理，把同步操作异步化。

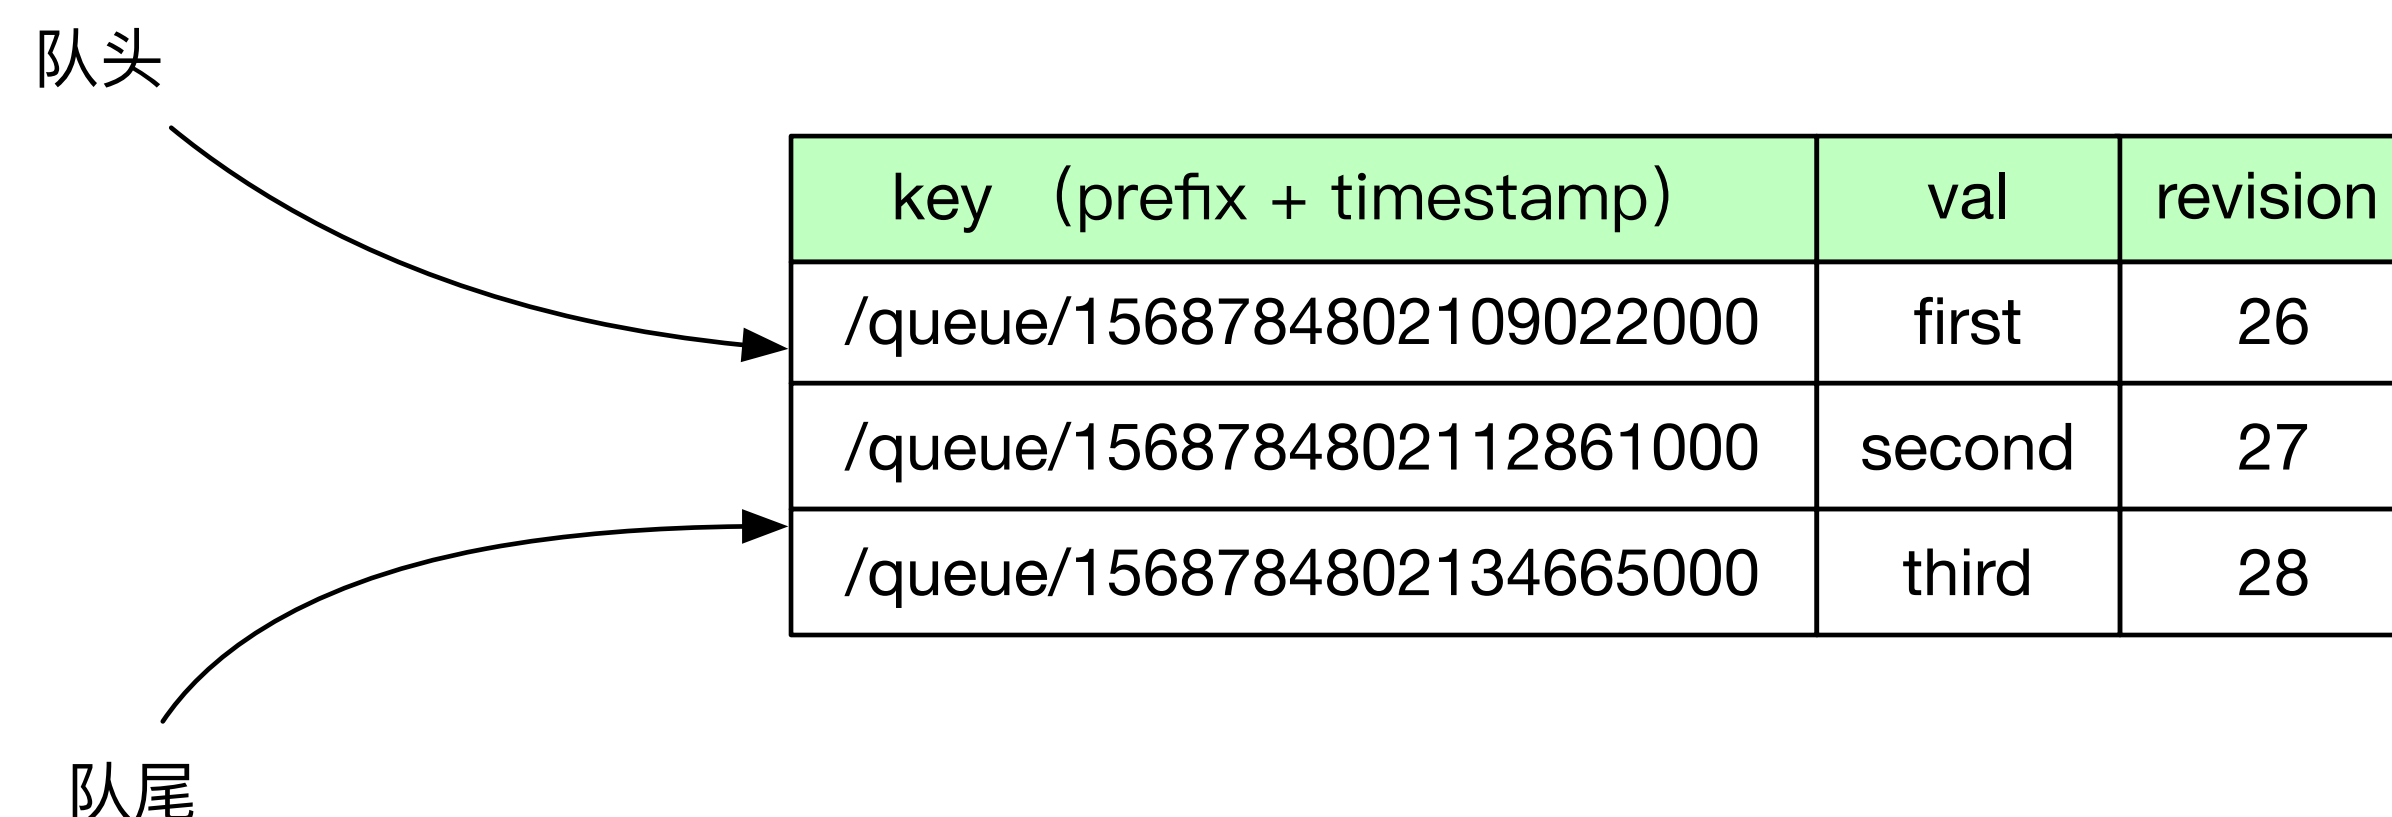
并发队列支持的入队和出队操作的并发执行，例如 Java 的 BlockingQueue。

分布式队列也是一种并发队列，但是分布式队列的生产者和消费者可以是独立的 agent。例如 Kafka 就是一个分布式消息队列。



设计

使用 key 为某一固定前缀（例如 queue/）来表示队列中的元素。ModRevision 的大小表示元素在队列中的位置，小的在队列前面，大的在队列后面。



设计思想和 ZooKeeper 的分布式队列是一样的。ZooKeeper 的 recipe 中使用顺序号表示队列元素的位置。etcd 的 ModRevision 和 ZooKeeper 的顺序号都是代表了数据创建顺序，都可以代表元素的入队时间。

出队操作

如果两个 agent A 和 B 进行入队操作的时候恰好使用了同样的时间戳，其中一个 agent 的入队操作就会失败。但是发生这种情况的概率是很低的，所以不用影响分布式队列的实际使用。发生这种情况的时候，入队失败的 agent 进行重试。

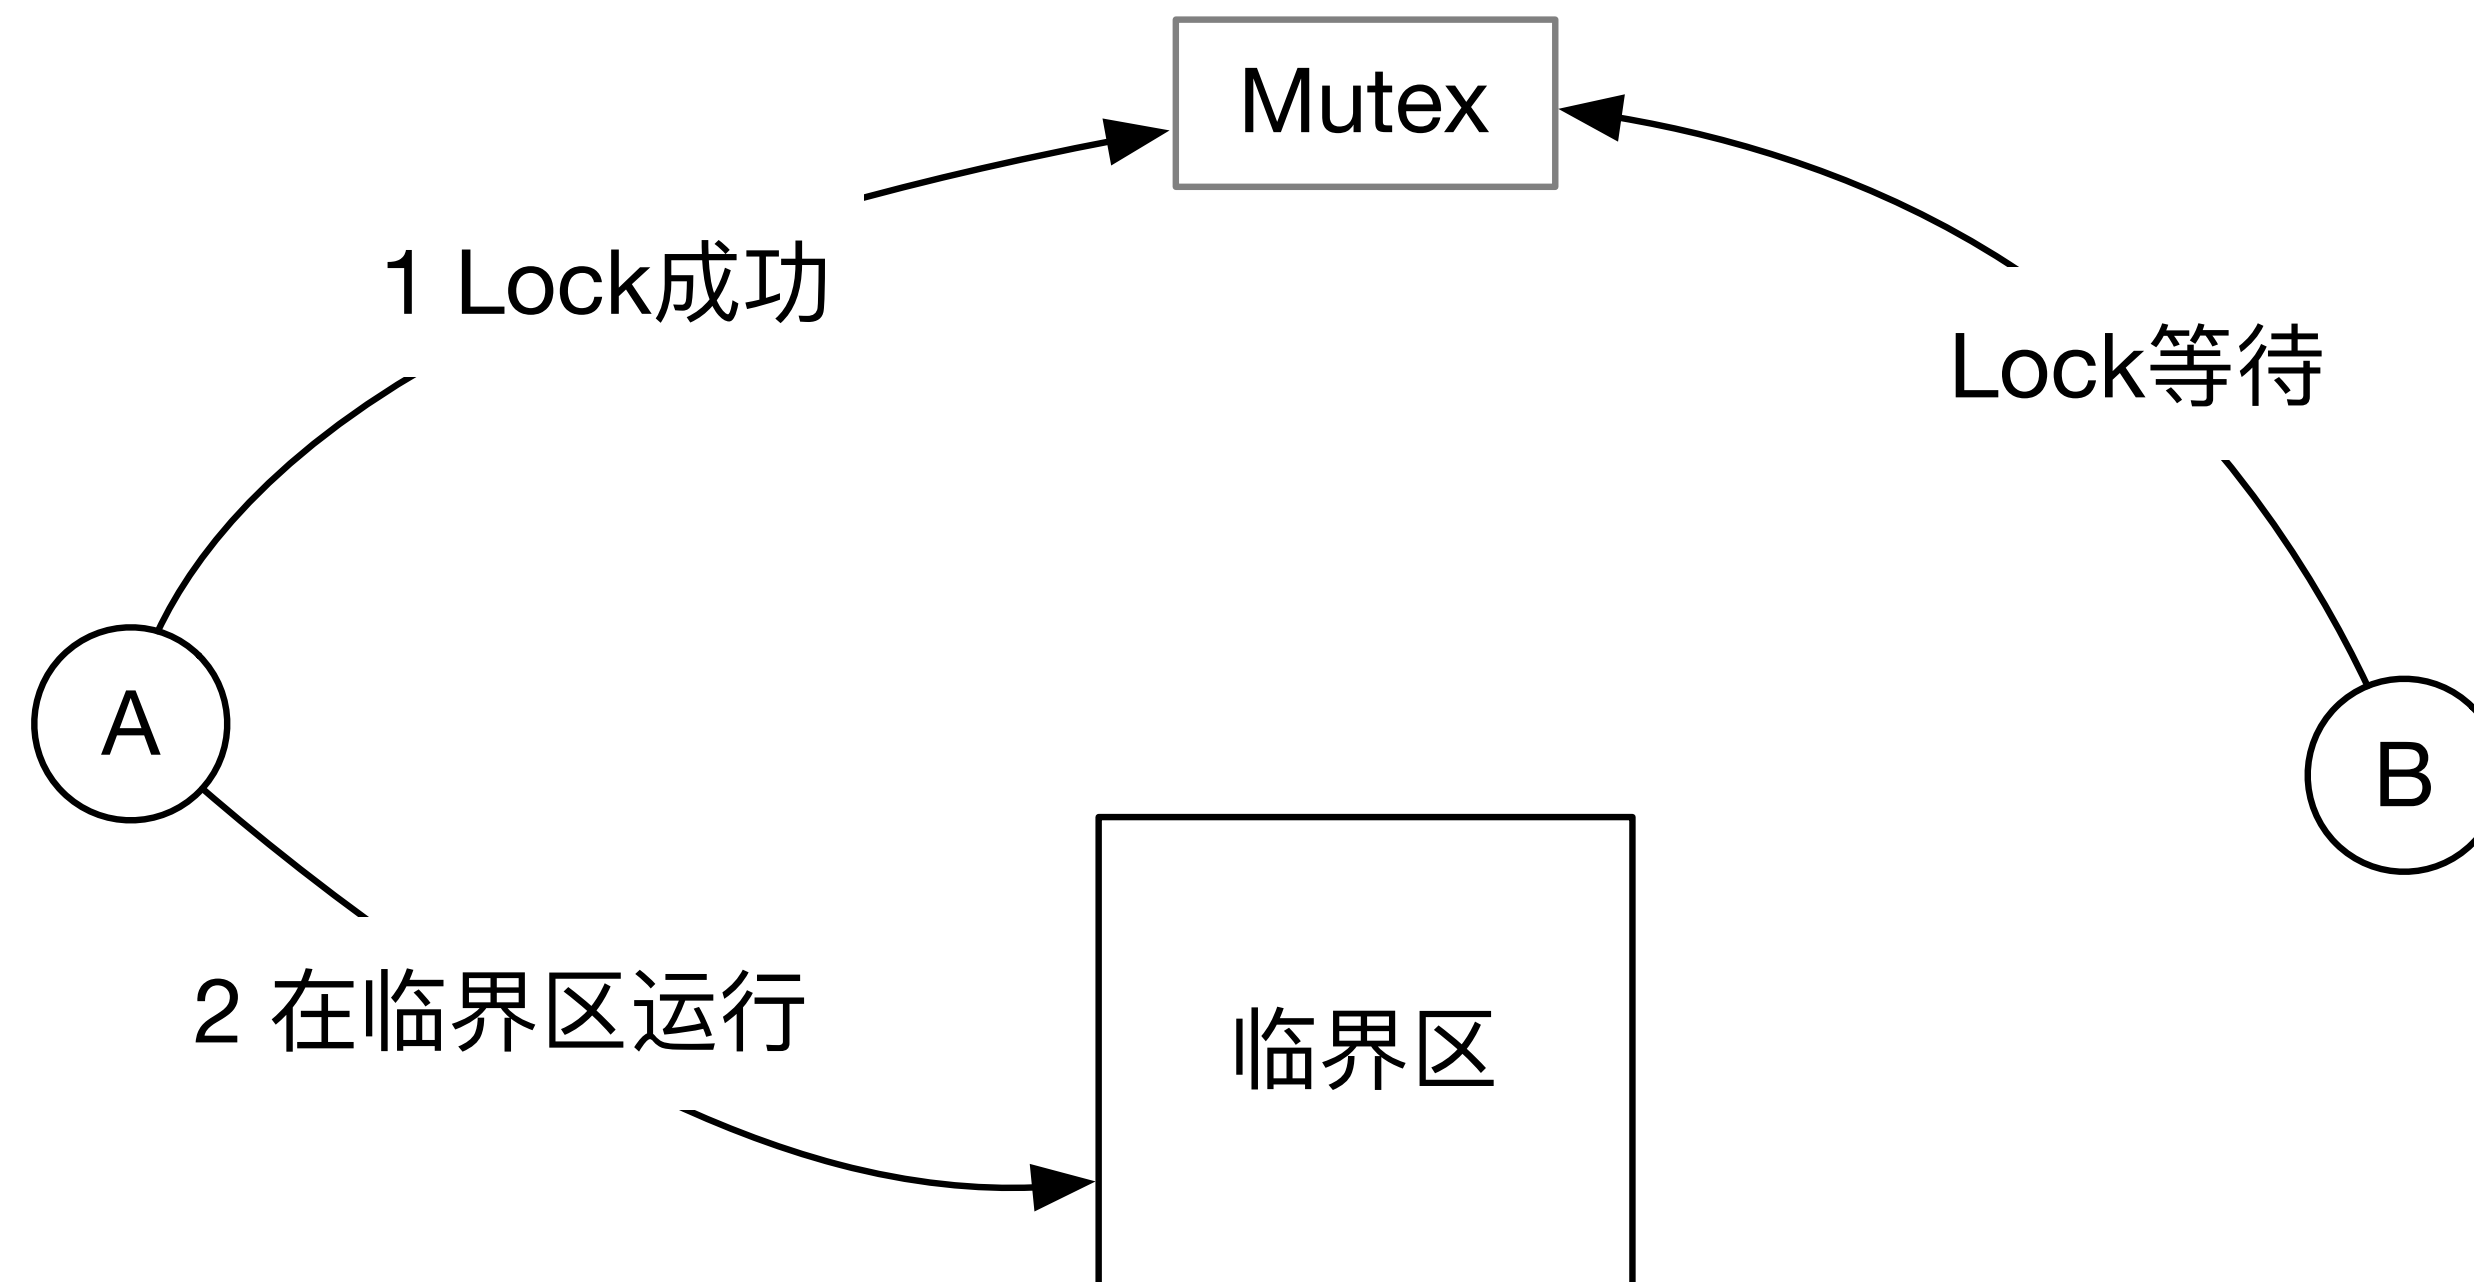
ZooKeeper 实现的队列没上述问题，原因在于它使用了 ZooKeeper 自己分配的序列号来命名队列元素。

代码展示

使用 etcd 实现分布式锁

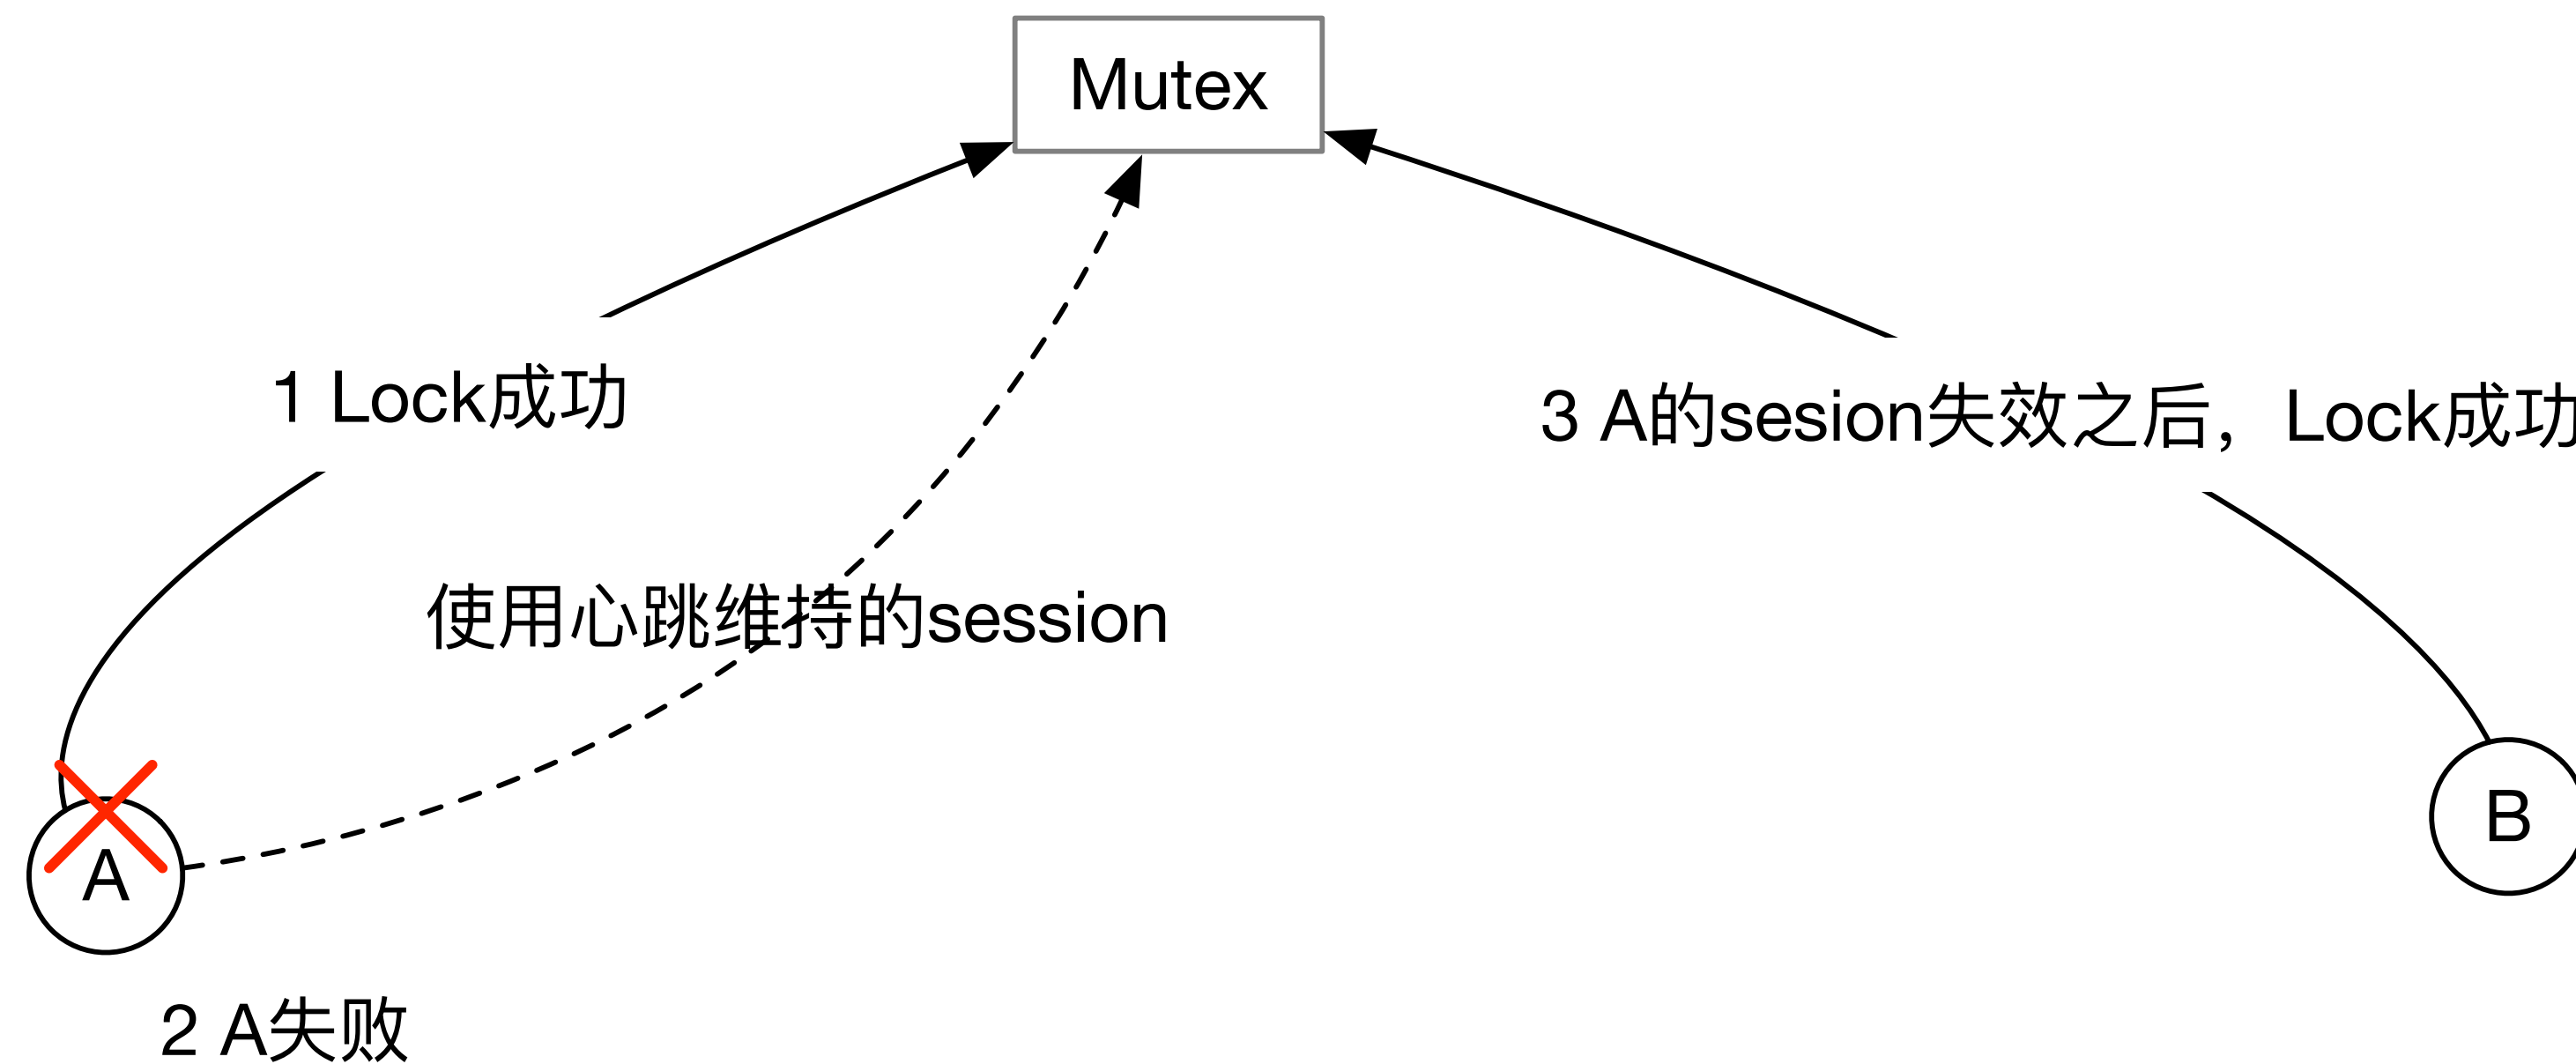
排它锁（Mutex）基础

Mutex 用来保证只有一个 agent 运行在临界区。在单机环境，可以使用 CAS 指令来实现 Mutex。



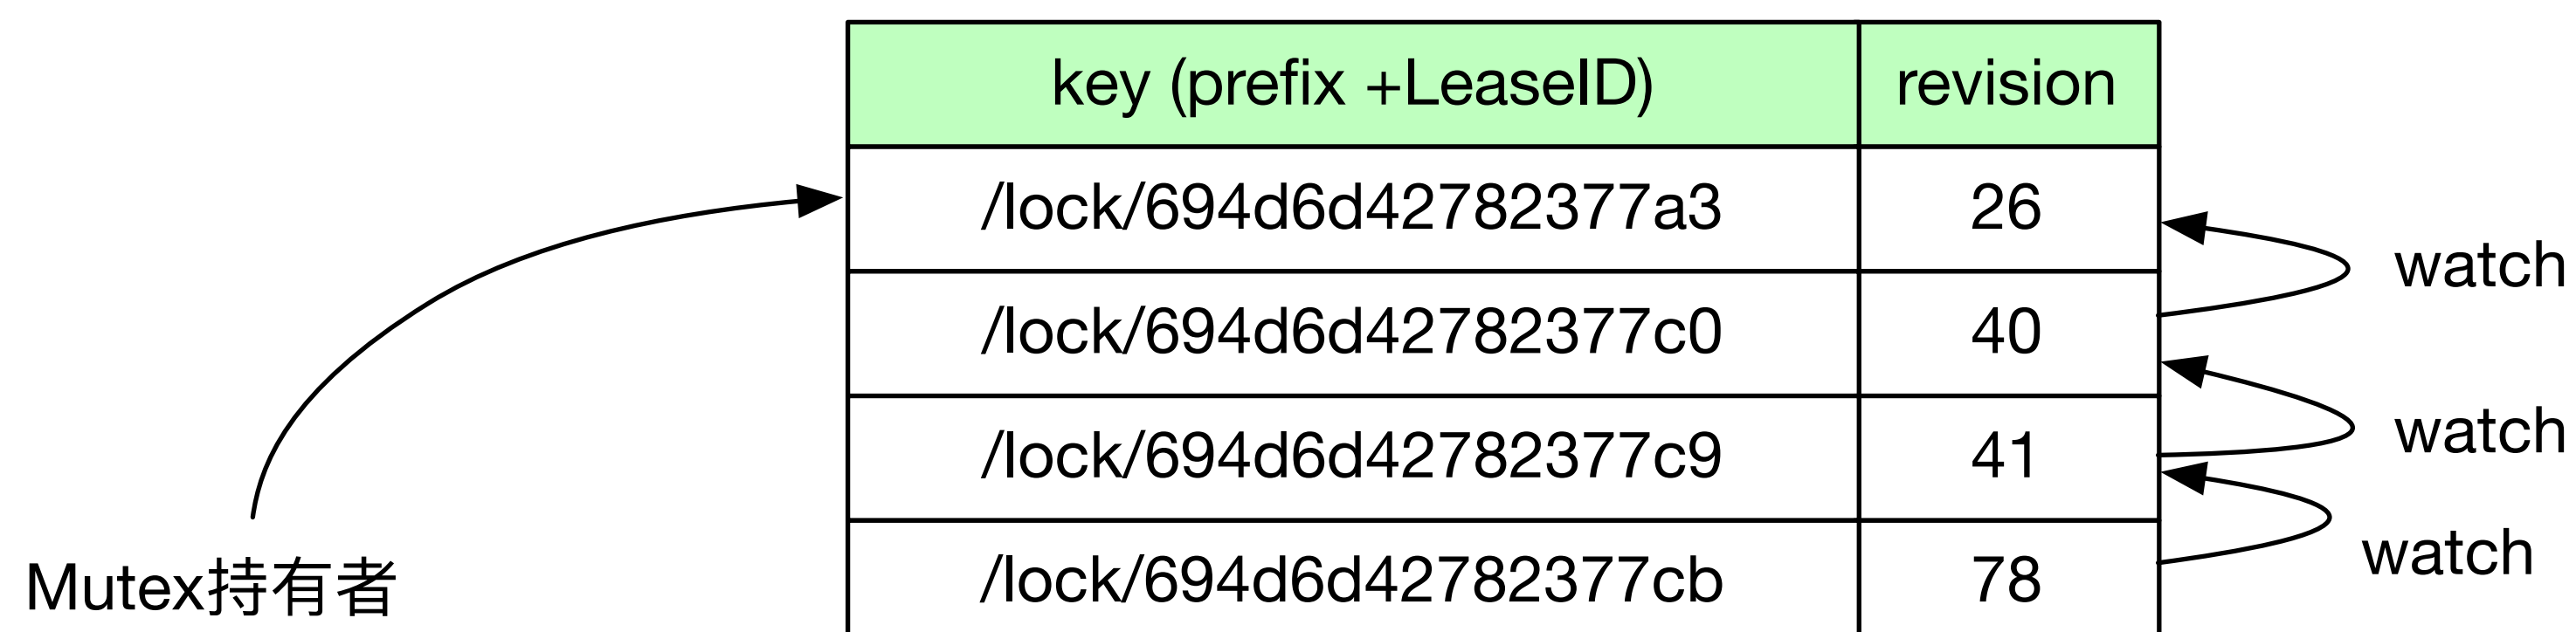
分布式排它锁

一个分布式 Mutex 除了需要类似 CAS 指令的机制以外，还需要处理持有锁的 agent 失败的情况。如果持有者的 agent 失败了，需要一个心跳机制自动释放 Mutex。



设计

使用 key 为某一固定前缀（例如 /lock/）的 key-value 来表示锁请求。每个表示锁请求的 key 都和 lease 关联，这样在所持有者失败的情况下，相关的 key 会被自动删除，从而释放锁。代表锁请求的 key 的 CreateRevision 越小，越先获得锁。CreateRevision 最小的锁请求可以成功获取锁。为了避免羊群效应，每个等待的锁请求 watch 它前面的锁请求。



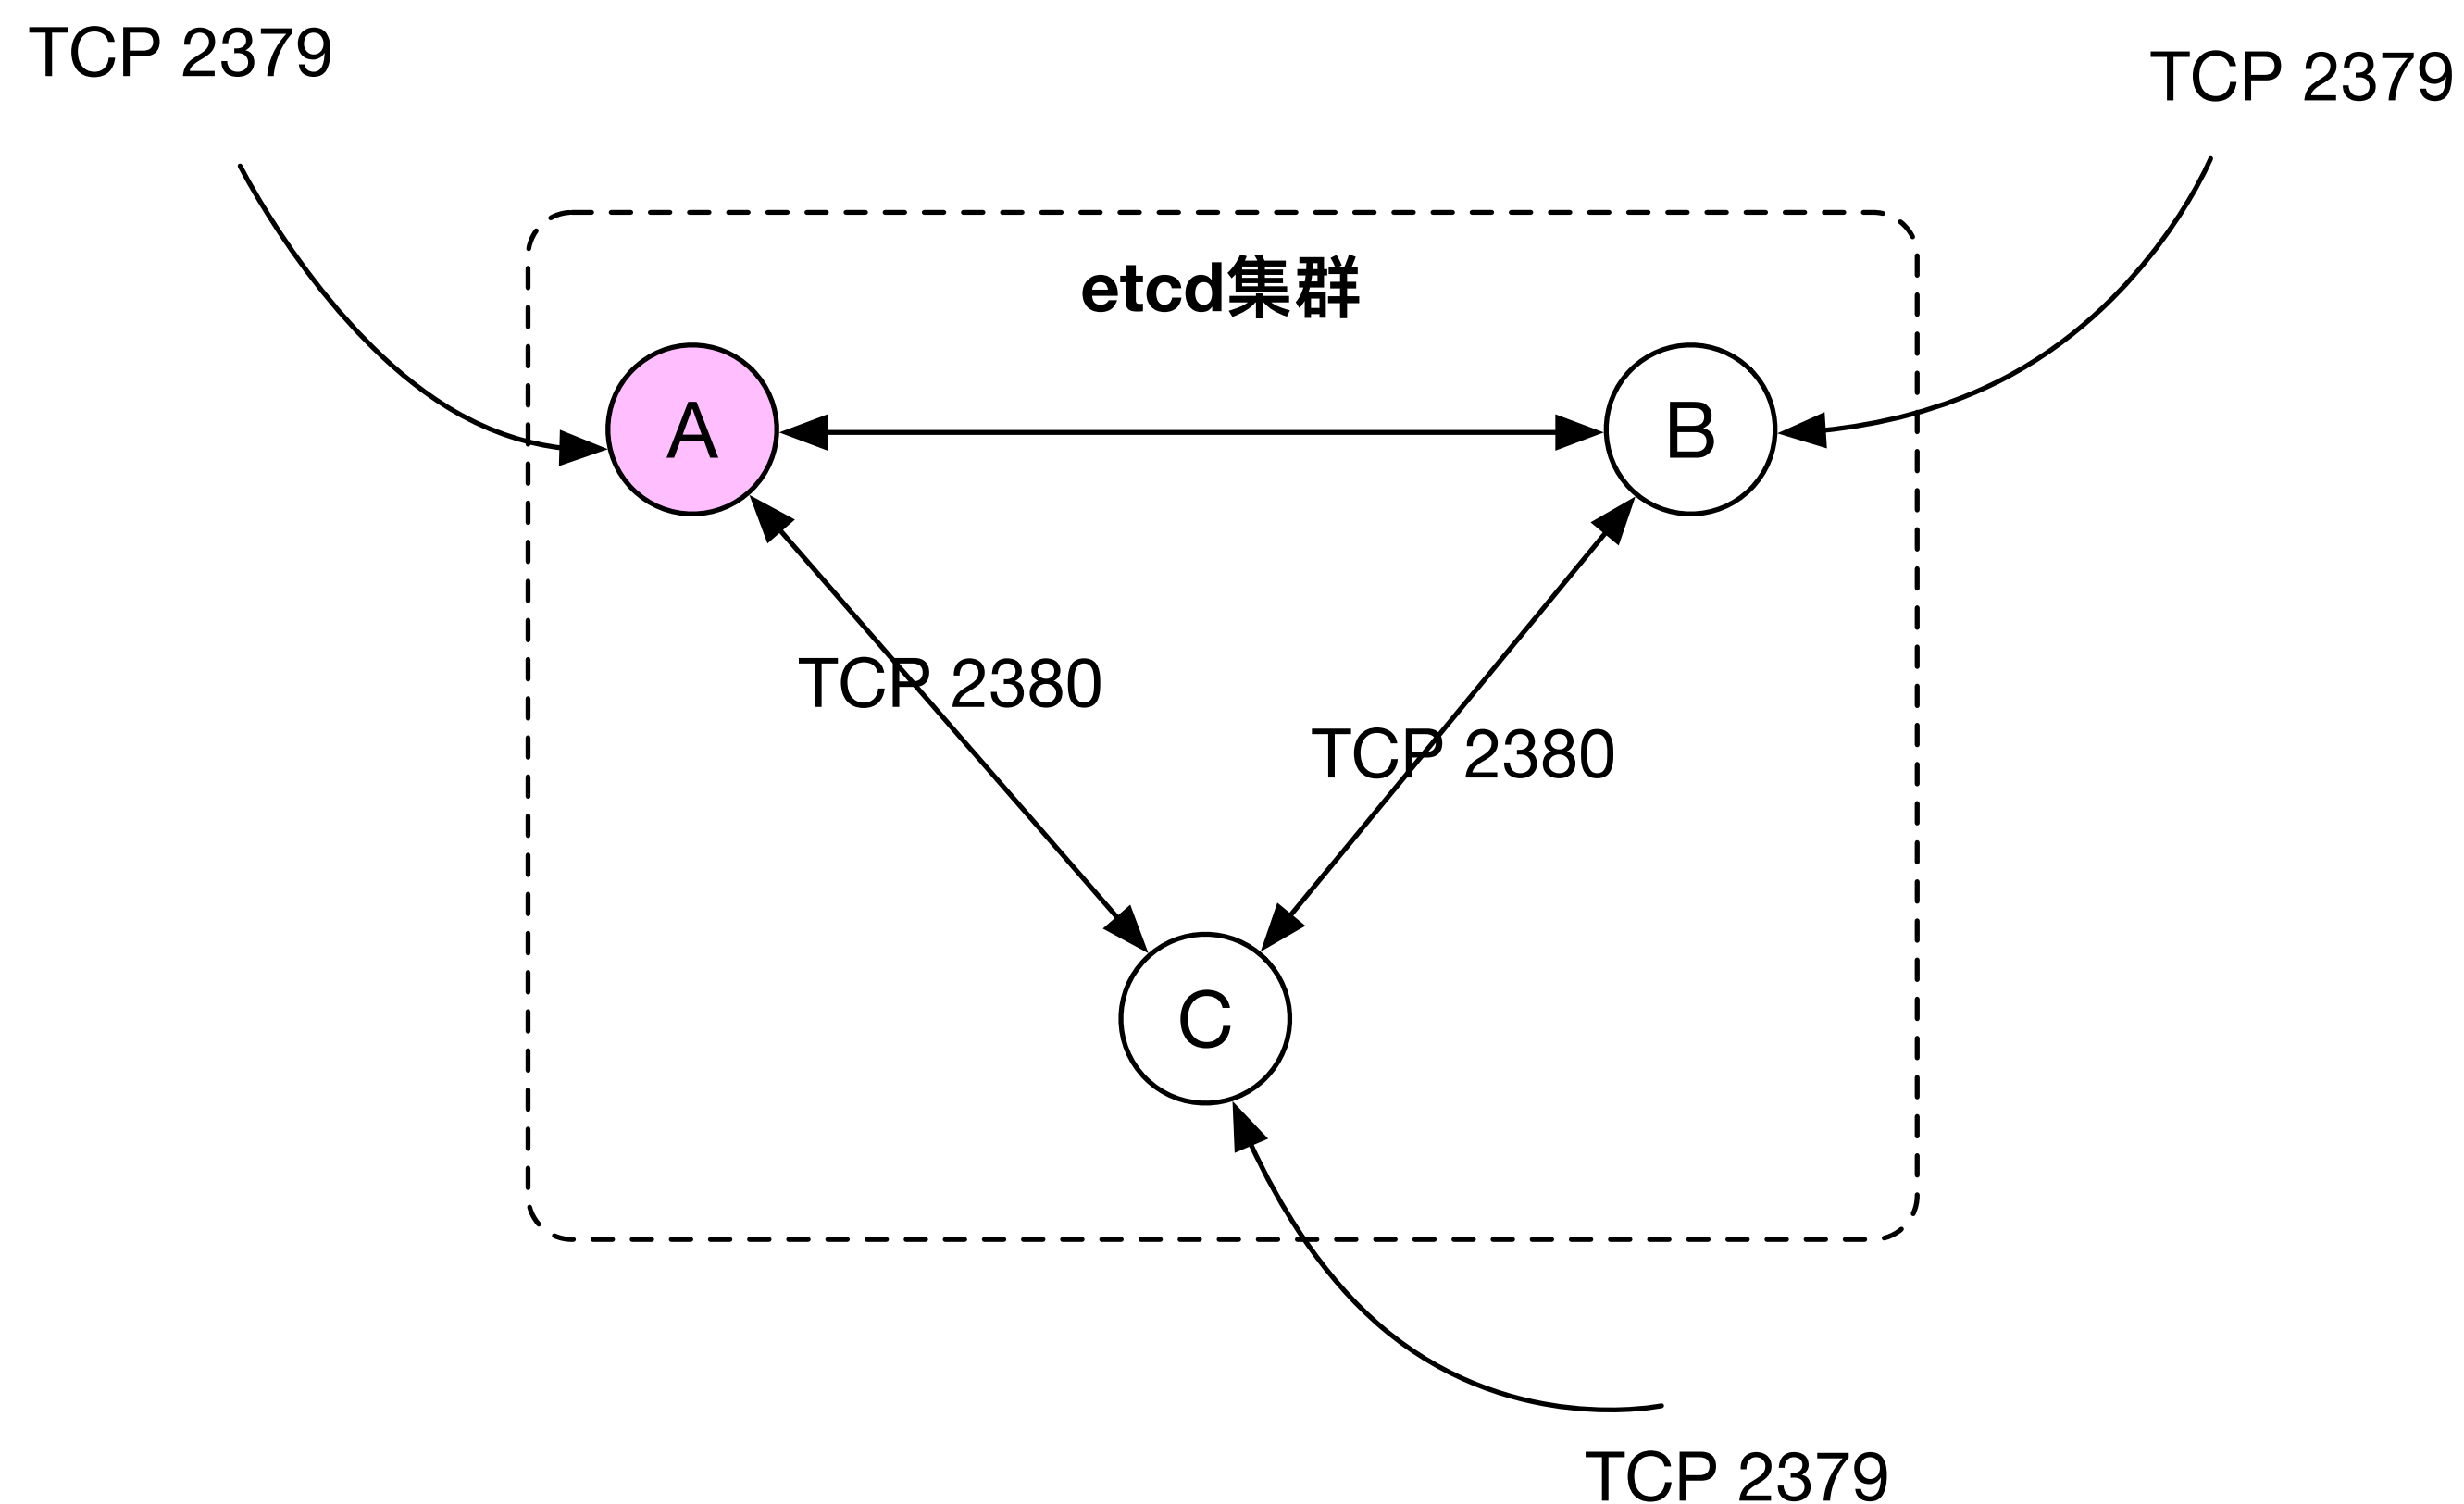
设计思想和 ZooKeeper 的分布式锁是一样的。ZooKeeper 的 recipe 中使用顺序号表示队列元素的位置。etcd 的 CreateRevision 和 ZooKeeper 的顺序号都是代表了数据创建顺序，都可以代表锁请求的先后顺序。

代码展示

如何搭建一个 etcd 生产环境


etcd 集群

一个 etcd 集群通常由奇数个节点组成。节点之间默认使用 TCP 2380 端口进行通讯，每个节点默认使用 2379 对外提供 gRPC 服务。



clientv3-grpc1.23 架构

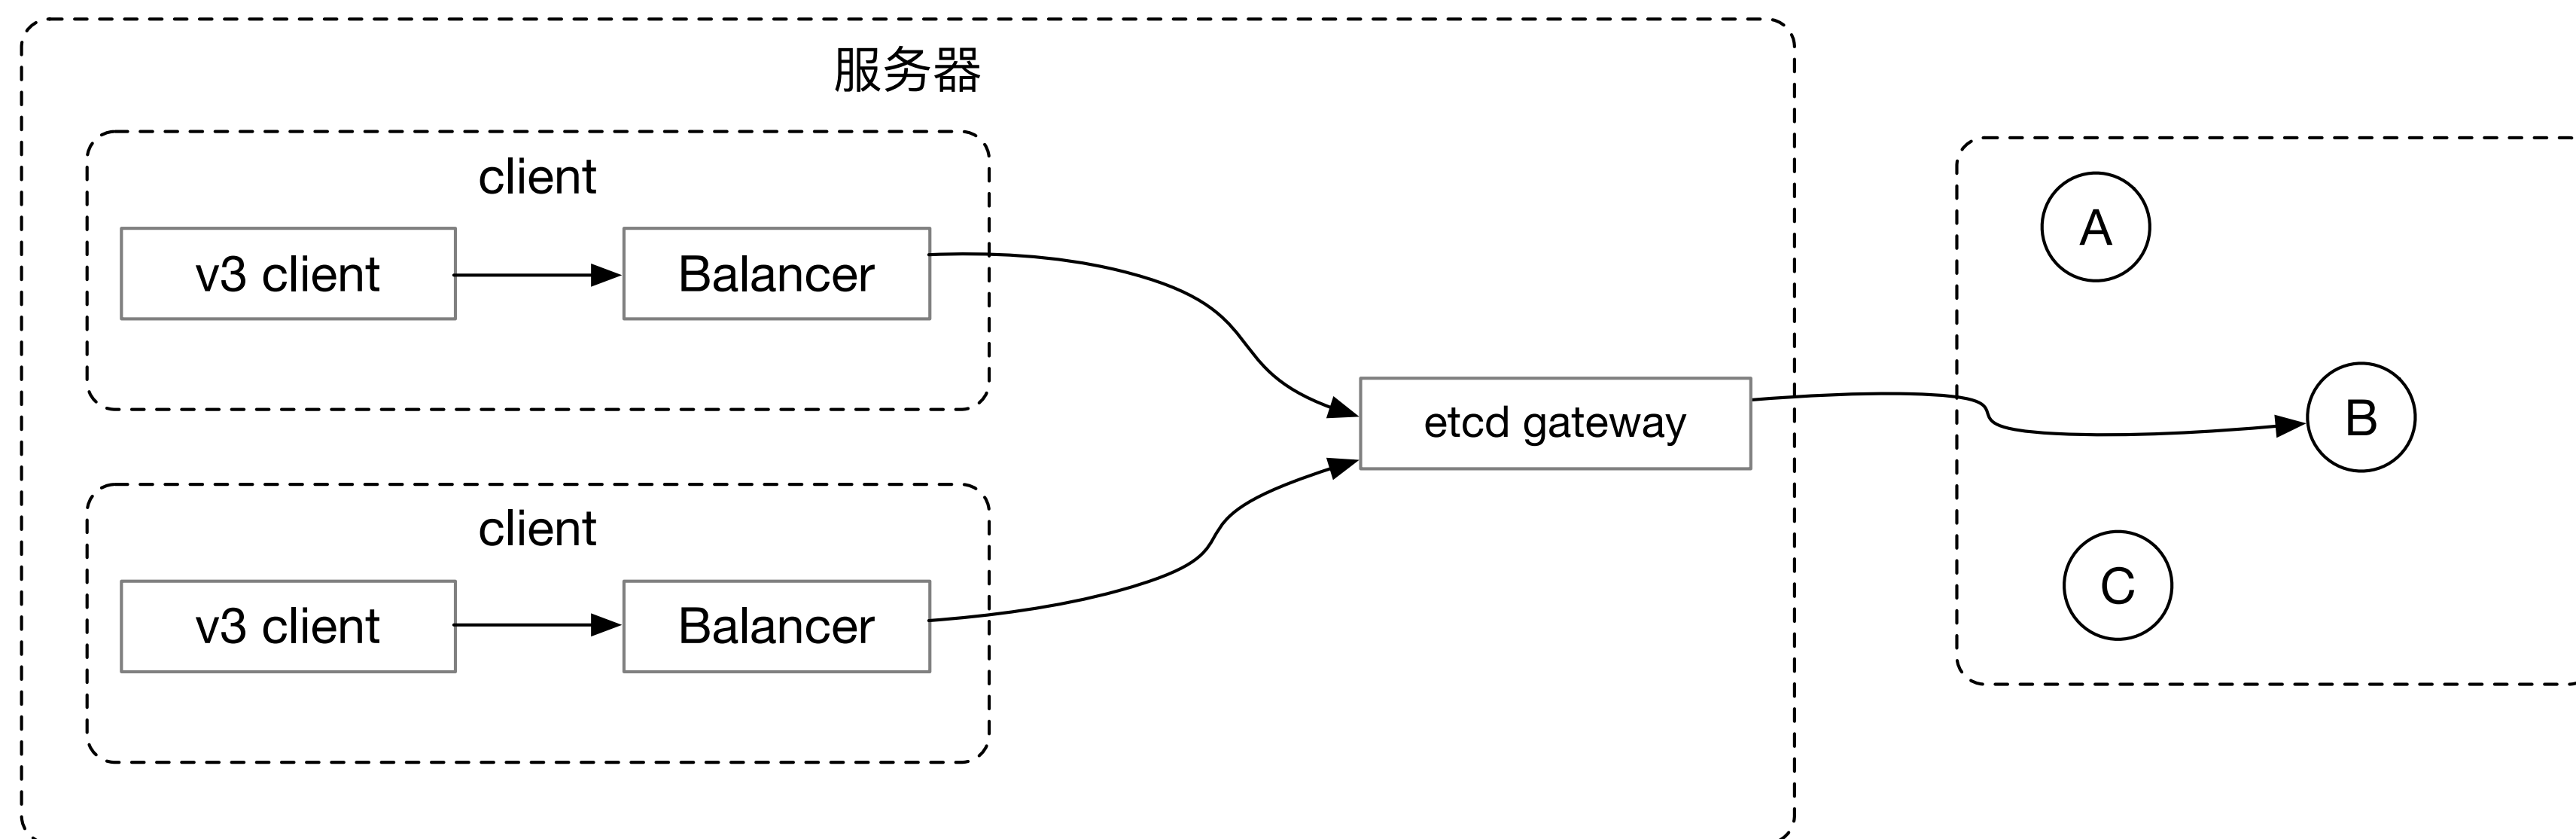
客户端有一个内置的 balancer。这个 balancer 和每一个 etcd 集群中的节点预先建立一个 TCP 连接。balancer 使用轮询策略向集群中的节点发送 RPC 请求。



etcd gateway

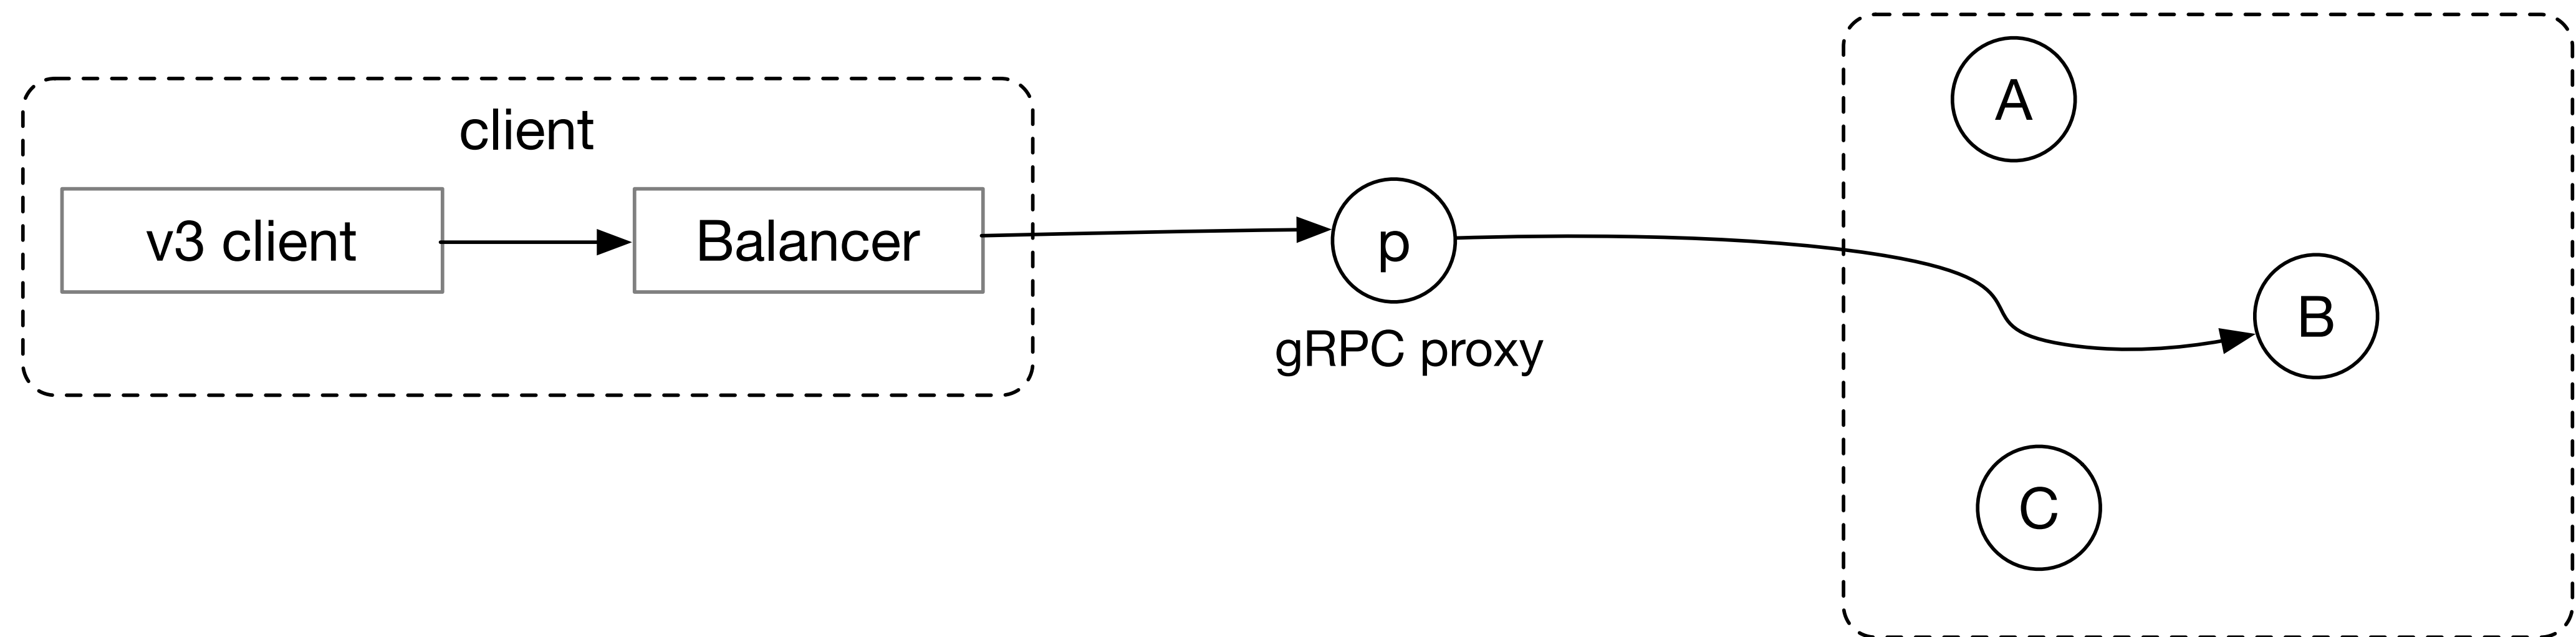
etcd gateway 是一个4层代理。客户端可以通过 etcd gateway 访问 etcd 集群中的各个节点。这样在集群中成员节点发生变化，只要在 etcd gateway 上面更新一次 etcd 集群节点访问地址就可以了，用不重要每个客户端都更新。

对于来自客户端的每一个 TCP 连接，etcd gateway 采用轮询方式的选择一个 etcd 节点，把这个 TCP 连接代理到这个节点上。



gRPC proxy

gRPC proxy 是一个7层代理，可以用来减少 etcd 集群的负载。gRPC proxy 除了合并客户端的 watch API 和 lease API 的请求,并且会 cache 来自 etcd 集群的响应。gRPC proxy 会随机的选取选取集群中的一个节点建立连接。如果当前连接的节点失败， gRPC proxy 才会切换到集群中另外一个节点。



配置一个3节点的集群

下面步骤列出了在 macOS 上启动一个3节点的 etcd 集群和一个 gPRC proxy 的步骤：

- 安装 Go 1.13
- 使用 `go get github.com/matttn/goreman` 安装 goreman
- 编辑 Procfile

动态添加删除节点

可以使用 `etcdctl member` 命令动态添加和删除节点。

比较 ZooKeeper 和 etcd

ZooKeeper 和 etcd 都是优秀的分布式协同服务平台，都有很大的生态圈。

- ZooKeeper 更成熟，系统更稳定，文档更加完备。在大数据生态，ZooKeeper 是首选。如果研发首选语言是基于 JVM 的，建议 ZooKeeper。
- etcd 的架构更先进一些。在云计算领域，etcd 是首选。如果研发首选语言是 Go，建议 etcd。



扫码试看/订阅

《ZooKeeper实战与源码剖析》视频课程